

Cross-Dataset CICIDS2017 ↔ CSE-CIC-IDS2018 — สารบัญผลการทดลอง

รวมผลทุกรอบของงาน cross-dataset แยกตามรอบที่ทำ เพื่อให้ย้อนดูและเปรียบเทียบได้

แต่ละรอบแยกเป็นสามส่วนเหมือนกันหมด

```
roundN_ /
├── report/          .md          .pdf
├── data/
└── code/            (            )
```

ทุกตัวเลขในโฟลเดอร์นี้มาจากไฟล์ผลลัพธ์จริง แต่ละรอบเก็บทั้งรายงาน ข้อมูลดิบที่ใช้สร้าง ตาราง และสคริปต์ที่รัน จึงตรวจย้อนกลับได้ทุกตัวเลข

คำเตือนก่อนเปรียบเทียบข้ามรอบ

ตัวเลขข้ามรอบเทียบกันตรง ๆ ไม่ได้ แต่ละรอบเปลี่ยนเงื่อนไขไปหลายอย่างพร้อมกัน ตารางด้านล่าง ระบุว่ารอบไหนเปลี่ยนอะไร ให้ดูคอลัมน์เงื่อนไขก่อนเสมอแล้วค่อยดูตัวเลข

	รอบ 2	รอบ 3	รอบ 4
ชุดที่ใช้เทรน	2018	2017	ทั้งสองฝั่ง
คลาสตอนเทรน	15 และ 7	9 แล้วยุบเป็น 7	7 ตั้งแต่ต้น
Features	76 และ 77	77	77
การ clean	ไม่ได้ทำ	ไม่ได้ทำ	กฎเดียวกันสองฝั่ง
การแบ่งข้อมูล	70/30 ตามเวลา	70/30 ตามเวลา	60/10/30 สองแบบ
Seeds	1	1	5
โมเดล	4	7	7

รอบ 1 — สรุปข้อเสนอแนะและ mapping

□ round1_advisor_plan/

คำถาม ต้องทำอะไรบ้าง และสอง dataset เชื่อมกันได้อย่างไร

ผลลัพธ์ mapping 77 shared features ระหว่างสอง dataset โดยจับคู่จากลำดับคอลัมน์ ไม่ใช่จาก การเดาชื่อ พบว่า 27 คอลัมน์ชื่อตรงกันอยู่แล้ว 50 คอลัมน์ต้องแปลง ในนั้นมี 12 คอลัมน์ที่สลับ ลำดับค่า และมีกับดักหนึ่งจุดคือ CWE Flag Count ที่ฝั่ง 2018 ลืมย่อ Count เป็น Cnt

ยืนยันภายหลัง mapping นี้ตรงกับ feature_columns.json และไฟล์ข้อมูลจริงของฝั่ง 2017 ทั้ง 77 ตัว เรียงตรงกันทุกตำแหน่ง

ไฟล์	เนื้อหา
report/advisor_cross_dataset_summary.pdf	สรุปข้อเสนอแนะ สถานะงาน และแผน
data/shared_features_77.json	ตารางแปลงชื่อคอลัมน์ ใช้ในโค้ดได้ทันที

รอบ 2 — ราคาของการย้ายไป shared schema (ภายในชุด 2018)

□ round2_schema_ablation_2018/

คำถาม การเปลี่ยนไปใช้ schema ร่วมทำให้ผลเปลี่ยนไปเท่าไร และเปลี่ยนเพราะอะไร

วิธี สีเงื่อนไข เปลี่ยนทีละอย่าง บนตัวอย่าง 300k ของ 2018 split เดิม seed เดิม

เงื่อนไข	feature	คลาส
A ฐานเดิม	77 (มี Protocol)	15
B shared	76	15
B+ shared + Dst Port	77	15
C shared + ยุบคลาส	76	7

ผลสำคัญ การยุบ 15 คลาสเหลือ 7 ทำให้ตัวเลขพาดหัวดีขึ้นแต่ประสิทธิภาพจริงแย่งลง

lightgbm	macro ทุกคลาส	macro เฉพาะคลาสที่วัดได้
ก่อนยุบ	0.7126	0.8575
หลังยุบ	0.7880	0.8193

ตัวเลขสองชุดขึ้นคนละทิศ เพราะการยุบคลาสเอาคลาสที่ทำได้ดีไปรวมกับคลาสที่พัง และซ่อนคลาสจิวที่เคยได้ศูนย์ออกจากการนับ

ผลอื่น: ตัด Protocol ไม่มีราคาต้องจ่าย (สามในสี่โมเดลขยับไม่ถึง 0.002) และ Destination Port ช่วย Infiltration จาก 0.1185 เป็น 0.1703

รอบ 3 — Cross-dataset ครั้งแรก ด้วยโมเดลที่มีอยู่เดิม

□ round3_transfer_handoff_models/

คำถาม ทำ cross-dataset ให้รันได้ก่อน ยังไม่เน้นผลดี

วิธี ใช้โมเดลที่เทรนไว้แล้วจากบันเดิล cicids2017_temporal_v1 (เทรนด้วย 9 คลาส) ทำนาย ข้อมูล 2018 แล้วยุบผลเป็น 7 คลาส ไม่ต้องใช้ข้อมูลดิบ 2017

ผลสำคัญ เทียบกับการเดาว่าทุกแถวเป็น Benign (macro-F1 0.1296)

โมเดล	macro-F1	กู้คืนได้
stacking	0.2428	20.3%
lightgbm	0.2298	16.2%
random_forest	0.1348	0.8%

random_forest ได้เท่าการเดาพอดี ส่วน mlp กับ logistic regression ได้ accuracy ต่ำกว่าการเดา

ตอนนั้นสรุปว่าสิ่งเดียวที่ถ่ายทอดได้คือความรู้เรื่อง traffic ปกติ (Benign 0.87–0.93) ส่วนคลาส โจมตีพังเกือบหมด ข้อสรุปนี้กว้างเกินไป รอบ 4 พบว่าในทิศ 2018 ไป 2017 ซึ่งรอบ 3 วัดไม่ได้ นั้น Bot ทำได้ 0.94 และ Brute Force ทำได้ 0.91 ส่วนในทิศที่รอบ 3 วัด ข้อสรุปเดิมยังคงถูกต้อง

การทดลองแรก บังคับให้โมเดลตอบได้แค่ 7 คลาสรวม (ตัด probability ของ Heartbleed และ PortScan ก่อน argmax) ดีขึ้นสูงสุด 0.008 และมีสองโมเดลแย่ง จึงประเมินตอนนั้นว่าการทำคลาสให้ เท่ากันมีผลราว 1% — การประเมินนี้วัดได้เพียงองค์ประกอบเดียว และยังไม่มียุบใดวัดผลรวมของการทำคลาสให้เท่ากันแบบแยกตัวแปรได้ ดูหัวข้อเทียบรอบ 3 กับรอบ 4

รอบ 4 — Protocol เดิมรูปแบบ □ รอบล่าสุด

□ round4_protocol_full/ · ผลดิบอยู่ที่ results/crossdataset/protocol_v1/

คำถาม ทำตาม protocol ให้ครบทุกข้อ แล้ววัดทั้งสี่ทิศทาง

วิธี 77 features · 7 คลาสเทรנדั้งแต่ต้น · 300k ต่อ dataset · 60/10/30 · 5 seeds · สองวิธีแบ่ง · 7 โมเดล · ไม่ทูน → 280 แถวผล

ผลที่หนึ่ง — การแบ่งแบบสุ่มทำให้เพดานเฟ้อ และเฟ้อไม่เท่ากัน

ชุด	เฟ้อขึ้นเท่าไร
2017	0.21 ถึง 0.32
2018	0.006 ถึง 0.033

ต่างกันลิบเท่า 2017 ภายใต้การแบ่งแบบสุ่มได้ 0.96–0.98 ซึ่งควรตั้งข้อสงสัยทันที

ผลที่สอง — การถ่ายทอดไม่สมมาตร และวิธีแบ่งข้อมูลปิดบังข้อนี้ไว้

วิธีแบ่ง	2017→2018	2018→2017
สุ่ม (ตาม protocol)	31.1%	25.8%
ตามลำดับเวลา	7.5%	73.9%

ถ้ารู้เฉพาะการแบ่งแบบสุ่มจะสรุปว่าสองทิศยากพอๆกัน ซึ่งไม่ตรงกับความจริง วิธีแบ่งข้อมูล เปลี่ยนข้อสรุป ไม่ใช่แค่เปลี่ยนตัวเลข

ผลที่สาม — ห้าในเจ็ดคลาสถ่ายทอดได้จริง

stacking เทรนด้วย 2018 ทดสอบกับ 2017 แบบแบ่งตามลำดับเวลา

คลาส	F1
Benign	0.951
Bot	0.936
Brute Force	0.883
DoS	0.640
DDoS	0.620
รวม 5 คลาส	0.806
Infiltration	0.000
Web Attack	0.000

เทียบรอบ 3 กับรอบ 4 ให้ถูกต้อง

รอบ 3 วัดได้ทิศเดียวคือ 2017 ไป 2018 ส่วนรอบ 4 วัดได้ทั้งสองทิศ การเทียบต้องดูทิศเดียวกัน เท่านั้น

ทิศ 2017 ไป 2018 ซึ่งเป็นทิศเดียวที่ทั้งสองรอบวัด — รอบ 4 ได้ต่ำกว่า

โมเดล	รอบ 3 Brute Force	รอบ 4 Brute Force
stacking	0.7359	0.0000
xgboost	0.3902	0.0000

โมเดล	รอบ 3 Brute Force	รอบ 4 Brute Force
lightgbm	0.2654	0.0000
logistic_regression	0.2394	0.0924

แต่สรุปไม่ได้ว่ารอบ 4 แย่กว่า เพราะเงื่อนไขต่างกันหลายอย่างพร้อมกัน

- รอบ 3 โมเดลเทรนด้วย 2017 ทั้ง corpus 1,748,579 แถว ส่วนรอบ 4 เทรนด้วย 180,000 แถว
- รอบ 3 ไม่ได้ clean ผัง 2018 ส่วนรอบ 4 ตัดแถวซ้ำออก ทำให้ Brute Force ของ 2018 เหลือ 1,798 จาก 7,039 แถว
- วิธีแบ่งข้อมูลต่างกัน

ตัวเลข 0.88 ถึง 0.91 เป็นของทิศ 2018 ไป 2017 ซึ่งรอบ 3 วัดไม่ได้

โมเดล	Brute Force ทิศ 2018 ไป 2017
mlp	0.9145
xgboost	0.9017
lightgbm	0.8888
stacking	0.8831

นี่คือของใหม่จริงของรอบ 4 ไม่ใช่การปรับปรุงตัวเลขเดิม

เรื่องผลของการทำให้ชุดคลาสเท่ากัน — ยังไม่มีการวัดที่สะอาด

รอบ 3 ประเมินไว้ราว 1% จากการบังคับให้โมเดลตอบได้แค่ 7 คลาส ซึ่งวัดได้เพียงองค์ประกอบเดียว คือคำทำนายที่เสียไปกับคลาสที่ไม่มีในเป้าหมาย

รอบ 4 เปลี่ยนหลายอย่างพร้อมกัน จึงแยกไม่ได้ว่าส่วนไหนมาจากการทำคลาสให้เท่ากัน ทั้งสองรอบ จึงยังไม่ได้ตอบคำถามนี้ ถ้าต้องการคำตอบต้องรันเงื่อนไขที่คุมทุกอย่างให้เหมือนกันแล้วเปลี่ยน เฉพาะชุดคลาส

สิ่งที่รอบ 4 เพิ่มขึ้นจริง

ข้อ	รอบ 3	รอบ 4
ทิศทางที่วัดได้	1	4 combination
Seeds	1	5 พร้อมค่าเบี่ยงเบน
วิธีแบ่งข้อมูล	1	2 และพบว่ามันเปลี่ยนข้อสรุป
การ clean	ไม่ได้ทำ	กฎเดียวกันสองฝั่ง
ที่มาของโมเดล	ของผู้อื่น ยืนยันไม่ได้	เทรนเองทั้งหมด

สองคลาสที่ไม่ถ่ายทอดในทุกรอบ

Infiltration และ Web Attack ได้ F1 เท่ากับศูนย์ในทุกรอบ ทุกทิศ ทุกโมเดล ทุก seed ด้วย เหตุผลคนละแบบ

คลาส	2017	2018	สาเหตุ
Web Attack	2,143	17	ข้อมูลไม่พอ ฝั่งหนึ่งแทบไม่มีเลย
Infiltration	36	2,946	ข้อมูลไม่พอ และ label เสีย

Infiltration น้อยกว่า เพราะแม้ทีสที่มีข้อมูลเทรน 1,700 แยกก็ยังได้ศูนย์ และแม้แต่ตอนเทรนกับทดสอบภายในชุดเดียวกันยังได้เพียง 0.05–0.13 ในทุกโมเดล

ข้อจำกัดที่ยังเหลือ

1. ผัง 2018 หลัง clean เหลือ 262,701 แยก ไม่ครบ 300,000 ตาม protocol แก้ได้โดยโหลดจาก sample_500k.parquet แทน ซึ่งทดสอบแล้วได้ครบ 300,000 พอดี
2. ช่อง calibration 10% กันไว้แล้วแต่ยังไม่ได้ใช้
3. ยังไม่ได้หุน hyperparameter
4. ยังไม่ได้ทำ adversarial validation
5. ตัวออกลำดับเวลาต่างกัน 2017 ใช้ลำดับแถวในไฟล์ 2018 ใช้ timestamp จริง

โค้ดที่ใช้

ที่อยู่	หน้าที่
src/crossdataset/schema.py	mapping 77 features
src/crossdataset/labels.py	mapping 7 คลาสรวม
src/crossdataset/cleaning.py	กฎ clean รวมสองฝั่ง
src/crossdataset/sampling.py	สุ่ม 300k รักษา rare class
src/crossdataset/splits.py	แบ่ง 60/10/30 สองแบบ
src/crossdataset/loaders.py	โหลดสองชุดให้อยู่ในรูปเดียวกัน
scripts/run_crossdataset.py	runner รอบ 4
scripts/analyze_crossdataset.py	สรุปผลรอบ 4 เป็นตาราง
tests/test_crossdataset_*.py	56 tests

สคริปต์เฉพาะกิจของรอบ 2 และ 3 เก็บไว้ในโฟลเดอร์ code/ ของรอบนั้น ๆ