

สรุปข้อเสนอแนะจากอาจารย์ และแผนงาน Cross-Dataset

เอกสารนี้รวบรวมทุกอย่างที่อาจารย์แนะนำมาระหว่างวันที่ 6 ถึง 8 สิงหาคม 2569 พร้อมสถานะงาน ผังเรา และแผนการเปรียบเทียบผลเท่ากับผลใหม่

ทุกตัวเลขในเอกสารนี้ดึงมาจากไฟล์ผลลัพธ์จริงในโปรเจกต์ ไม่มีการประมาณการ

1. สรุปสั้น

อาจารย์ทดลอง cross-dataset ระหว่าง CICIDS2017 กับ CSE-CIC-IDS2018 ทั้งสองทิศแล้ว พบว่า ผลไม่ดีทั้งคู่ และวิธีแก้สามอย่างที่ลองไปก็ไม่ช่วย จึงสรุปว่าการทำ generalisation ข้ามชุด ข้อมูลน่าจะยากมาก แล้วขอให้เราวางแผนของตัวเองมาเสนอ

แผนที่เราเสนอคือไม่ไปแข่งทำให้ cross-dataset เวิร์ค แต่แยกให้ได้ว่าช่องว่างของผลลัพธ์ ประกอบด้วยอะไรบ้าง และแต่ละส่วนกินสัดส่วนเท่าไร เพราะข้อมูลที่เราใช้อยู่ที่ส่วนหนึ่งของปัญหาไม่ได้อยู่ที่โมเดล แต่อยู่ที่คุณภาพของชุดข้อมูลเอง

ล่าสุดอาจารย์ขอผลเบื้องต้นก่อน โดยระบุว่าไม่ต้องได้ผลดี ขอแค่ให้รันข้ามชุดข้อมูลได้

2. สิ่งที่อาจารย์แนะนำมาทั้งหมด

2.1 วันที่ 6 สิงหาคม เวลา 12:04

- ให้ตรวจสอบเรื่อง tuning ของแต่ละโมเดล เพราะสงสัยว่าบางโมเดลของเราไม่แฟร์
- แจ้งว่าลอง cross-dataset แล้วทั้งสองทิศ คือเทรนด้วย 2017 ทดสอบกับ 2018 และเทรนด้วย 2018 ทดสอบกับ 2017 ผลไม่ดีทั้งคู่
- ตอนนั้นใช้ข้อมูล 7 คลาส จำนวนสามแสนแถว
- ขอให้เราไปวางแผนของตัวเองมาว่าจะไปทางไหน

2.2 วันที่ 6 สิงหาคม เวลา 12:13

แจ้งว่าลองหลายวิธีแล้วไม่ช่วยให้ดีขึ้น บางวิธีแยกลงด้วยซ้ำ วิธีที่ลองไปแล้วมีสามอย่าง

1. ลดปัญหาจาก multiclass ให้เหลือ binary
2. ลบ features ที่บ่งบอกว่า record มาจาก dataset ไหน
3. Distribution alignment

2.3 วันที่ 8 สิงหาคม เวลา 16:55

- ชื่อฟิลด์ระหว่าง 2017 กับ 2018 ไม่เหมือนกัน ต้องทำ mapping เอง
- ในข้อมูลจะมีค่าแปลก ๆ ต้องทำความสะอาดเอง

2.4 ข้อความล่าสุด

ขอผลเบื้องต้น ไม่จำเป็นต้องได้ผลดี ขอแค่ให้ cross-dataset รันได้ก่อน

3. Protocol ข้อมูลที่อาจารย์กำหนด

หัวข้อ	ค่าที่กำหนด
การทำความสะอาด	แยกทำทีละชุด แก้อีพ็อกซ์สัมน์ แก่ชนิดข้อมูล ตัดค่าที่ใช้ไม่ได้
จำนวนคลาส	7 classes ที่มีร่วมกัน
จำนวน features	77 shared features
ขนาดตัวอย่าง	300,000 แยกต่อ dataset รักษา rare classes ให้มากที่สุด
การแบ่งข้อมูล	train 60% calibration 10% test 30%
การทำซ้ำ	5 random seeds

4. สถานะงานเทียบกับที่อาจารย์ขอ

สิ่งที่อาจารย์ขอ	สถานะ
ตรวจ tuning ว่าแฟร์หรือไม่	เสร็จแล้ว
ส่งแผนของตัวเอง	ตอบไปบางส่วนทางแชท ยังไม่ได้ส่งเป็นก่อน
ทำ mapping ชื่อฟิลด์เอง	เสร็จแล้ว ยังไม่ได้ย้ายเข้าโปรเจกต์
ทำความสะอาดข้อมูลเอง	สำรวจแล้วว่ามีปัญหาอะไรบ้าง ยังไม่ได้เขียน cleaner
ยุบเหลือ 7 classes	ยังไม่เริ่ม
ใช้ 77 shared features	เสร็จแล้วในส่วน mapping
300,000 แยกต่อ dataset	ฝั่ง 2018 มีแล้ว ฝั่ง 2017 ยังไม่มี
แบ่ง 60/10/30	ช่อง calibration มีในโค้ดแต่ถูกปิดไว้
ทำซ้ำ 5 seeds	ยังเป็น 1 seed
ลด multiclass เหลือ binary	มีเฉพาะฝั่ง 2017 ฝั่ง 2018 ยังไม่มี
ลบ features ที่บ่งบอก dataset	ยังไม่เริ่ม
Distribution alignment	อาจารย์ทำเอง เราไม่แตะ
ให้ cross-dataset รันได้	ยังทำไม่ได้ ติดที่ไม่มีข้อมูล 2017

5. งานที่เสร็จแล้ว การตรวจสอบ tuning

อาจารย์สงสัยถูกต้อง ระบบเดิมให้ทุกโมเดลค้นหา 20 ชุดพารามิเตอร์เท่ากัน แต่ขนาด search space ของแต่ละโมเดลต่างกันมาก ตั้งแต่ 10 ถึง 5,184 ชุด ผลคือ logistic regression ได้ค้นหาครบทุกความเป็นไปได้ ในขณะที่ xgboost ได้ค้นเพียงเศษเสี้ยว

แก้ไขโดยปรับ search space ของทั้งหมัดโมเดลให้เท่ากันที่ 144 ชุด แล้วรันใหม่ทั้งหมดลง bundle ชื่อ 300k_temporal_tuned_fair และ 500k_temporal_tuned_fair

ผลของการรันใหม่ให้ข้อสรุปที่สำคัญกว่าตัวการแก้งัดเสียอีก คืออันดับของโมเดลเปลี่ยนไป 10 จาก 14 ตำแหน่ง แต่คะแนนบนคลาสที่วัดผลได้จริงไม่มีโมเดลไหนขยับเกิน 0.007 แปลว่าอันดับที่เห็นก่อนหน้านี้สะท้อนโชคในการค้นหาพารามิเตอร์บนคลาสหายาก มากกว่าจะสะท้อนคุณภาพของโมเดล

6. Mapping ที่ทำเสร็จแล้ว

ใช้ชื่อคอลัมน์ฝั่ง 2017 เป็นชื่อกลาง แล้วแปลงชื่อฝั่ง 2018 เข้ามาหา

6.1 คอลัมน์ที่ตัดออกก่อนจับคู่

ฝั่ง	ตัดออก	เหตุผล
2017	Fwd Header Length.1	คอลัมน์ซ้ำ เป็นนักของไฟล์ต้นฉบับ
2018	Flow ID Src IP Src Port Dst IP	เป็นข้อมูลระดับตัวตน ไม่ใช่ feature
2018	Protocol Timestamp	ฝั่ง 2017 ไม่มีในรายการ feature

หลังตัดแล้วเหลือ 77 ตรงกับ 77 พอดี ซึ่งตรงกับจำนวนที่อาจารย์ระบุไว้

6.2 วิธีจับคู่

ไม่ได้จับคู่จากการเดาชื่อ แต่เรียงคอลัมน์ตามลำดับเดิมของทั้งสองไฟล์แล้วจับคู่ตามตำแหน่ง พบว่าเรียงตรงกันทุกตำแหน่งโดยไม่มีการสลับเลย ซึ่งสมเหตุสมผลเพราะทั้งสองชุดถูกสกัด feature ด้วย CICFlowMeter เหมือนกัน ต่างกันแค่เวอร์ชัน

ผลการจับคู่คือ 27 คอลัมน์ที่ชื่อเหมือนกันอยู่แล้ว และ 50 คอลัมน์ที่ต้องแปลงชื่อ

6.3 คอลัมน์ที่สลับลำดับคำ ต้องระวังเป็นพิเศษ

ส่วนใหญ่ของ 50 คอลัมน์เป็นการย่อคำตรงไปตรงมา แต่มี 12 คอลัมน์ที่สลับลำดับคำด้วย ถ้าเขียนกฎแปลงชื่ออัตโนมัติจะพลาดกลุ่มนี้ทั้งหมด

ชื่อฝั่ง 2017	ชื่อฝั่ง 2018
Min Packet Length	Pkt Len Min
Max Packet Length	Pkt Len Max
Average Packet Size	Pkt Size Avg
Avg Fwd Segment Size	Fwd Seg Size Avg
Avg Bwd Segment Size	Bwd Seg Size Avg
Fwd Avg Bytes/Bulk	Fwd Byts/b Avg
Fwd Avg Packets/Bulk	Fwd Pkts/b Avg
Fwd Avg Bulk Rate	Fwd Blk Rate Avg
Bwd Avg Bytes/Bulk	Bwd Byts/b Avg
Init_Win_bytes_forward	Init Fwd Win Byts
act_data_pkt_fwd	Fwd Act Data Pkts
min_seg_size_forward	Fwd Seg Size Min

สามแถวล่างหนักที่สุด เพราะฝั่ง 2017 ใช้ snake_case และวางทิศทางไว้ท้ายชื่อ ส่วนฝั่ง 2018 ใช้ Title Case และวางทิศทางไว้หน้าชื่อ

นอกจากนี้ยังมีกับดักอีกหนึ่งจุด คือฝั่ง 2018 ย่อคำว่า Count เป็น Cnt ทุกตัว ยกเว้น CWE Flag Count ที่ลืมนย่อ ถ้าเขียนกฎแปลงแบบเหมารวมจะพังตรงจุดนี้

7. ปัญหาในข้อมูลที่สำรวจพบ

ตรวจจากตัวอย่าง 300,000 แถวของ 2018 ที่มีอยู่ในเครื่อง

อาการ	จำนวน
Flow Byts/s เป็นค่านันต์	685 แกว
Flow Byts/s เป็นค่าว่าง	1,053 แกว
Flow Pkts/s เป็นค่านันต์	1,738 แกว
Init Fwd Win Byts เป็นค่าลบ	81,853 แกว
Init Bwd Win Byts เป็นค่าลบ	152,454 แกว
แกวที่ซ้ำกันทั้งแกว	856 แกว
คอลัมน์ที่มีค่าเดียวตลอดทั้งชุด	8 คอลัมน์

คอลัมน์ที่มีค่าเดียวตลอดทั้งชุดคือ Bwd PSH Flags Bwd URG Flags และกลุ่ม bulk ทั้งหมด หกตัว

ประเด็นสุดท้ายสำคัญกว่าที่เห็น ถ้าคอลัมน์เหล่านี้หนึ่งในชุดหนึ่งแต่ไม่ในอีกชุด มันจะทำหน้าที่สองอย่างพร้อมกัน คือเป็นตัวบ่งบอกว่า record มาจาก dataset ไหน ซึ่งตรงกับข้อกังวลของอาจารย์พอดี และเป็นตัวทำลาย transfer ด้วย เพราะโมเดลที่เรียนรู้จากชุดที่คอลัมน์นั้นมีค่าพอย้ายไปอีกชุดจะได้ศูนย์เปล่า ยังตรวจฝั่ง 2017 ไม่ได้เพราะไม่มีข้อมูลดิบในเครื่อง

8. แผนเปรียบเทียบผลเก่ากับผลใหม่

หลังทำ mapping แล้วจะเทียบผลเก่ากับผลใหม่ตรง ๆ ไม่ได้ เพราะเปลี่ยนไปพร้อมกันหลายอย่าง คือ จำนวน feature ลดจาก 79 เหลือ 77 และจำนวนคลาสยวบจาก 15 เหลือ 7 สองอย่างนี้ดันคนละทิศ ถ้ารันทีเดียวแล้วเทียบจะแยกไม่ออกว่าจะอะไรทำให้ผลเปลี่ยน

จึงต้องไล่ทีละชั้น เปลี่ยนทีละอย่าง

ชั้น	เงื่อนไข	ตอบคำถามว่า
A	79 feature และ 15 คลาส	ฐานอ้างอิง มีผลอยู่แล้ว
B	77 feature และ 15 คลาส	การตัด Protocol กับ Timestamp มีราคาเท่าไร
C	77 feature และ 7 คลาส	การยุบคลาสชื่อคะแนนมาเท่าไร
D	เงื่อนไข C แต่ข้ามชุดข้อมูล	การข้ามชุดข้อมูลมีราคาเท่าไร

ส่วนต่างระหว่างชั้น D กับชั้น C คือราคาที่แท้จริงของการข้ามชุดข้อมูล ส่วนต่าง B ลบ A และ C ลบ B เป็นราคาของการปรับ schema ซึ่งไม่ควรนำไปปนกัน

ชั้น B และ C รันได้ทันทีโดยไม่ต้องรอข้อมูล 2017 เพราะใช้ตัวอย่าง 300,000 แกวของ 2018 ที่ มีอยู่แล้ว และใช้ split เดิม seed เดิม ขณะเขียนเอกสารนี้ยังไม่ได้รัน ตัวเลขในหัวข้อ 9 จึง เป็นฝั่งของเก่าอย่างเดียว

9. ผลเก่าที่จะใช้เป็นฐานเปรียบเทียบ

bundle ที่ควรใช้เป็นฐานคือ results/ids2018/300k_temporal_tuned_fair เพราะเป็นตัวเดียวที่ทุนแบบแฟร์แล้ว ดังค่าคือ 300,000 แกว seed 42 แบ่ง 70/30 แบบ temporal จำนวน 15 คลาส

9.1 bundle ฐาน temporal split ทุนแฟร์

โมเดล	macro-F1	balanced accuracy
catboost	0.7751	0.7444
random_forest	0.7648	0.7344

โมเดล	macro-F1	balanced accuracy
mlp	0.7134	0.6920
lightgbm	0.7110	0.6882
xgboost	0.6990	0.6730
logistic_regression	0.6666	0.6352
stacking	0.6580	0.6386

9.2 bundle 300k random split ไม่ทุน

bundle นี้ใช้เทียบกับ protocol ของอาจารย์ที่ใช้การสุ่มแบ่ง

โมเดล	macro-F1	balanced accuracy
stacking	0.6886	0.6806
lightgbm	0.6870	0.6797
random_forest	0.6869	0.6850
xgboost	0.6854	0.6796
catboost	0.6763	0.6712
mlp	0.6698	0.6727
logistic_regression	0.6296	0.6220

สอง bundle นี้ต่างกันสองอย่างพร้อมกัน คือวิธี split และการทุน จึงหามนำมาเทียบกับตรง ๆ เพื่อสรุปว่า temporal split ยากกว่าหรือง่ายกว่า ต้องรันเงื่อนไขที่คุมตัวแปรอื่นให้เท่ากัน ก่อนจึงจะสรุปได้ ซึ่งเป็นเหตุผลเดียวกับที่ต้องไล่ชั้น A ถึง D ในหัวข้อ 8

10. หลักฐานที่สนับสนุนแผน

10.1 บางคลาสดันเท่ากันทุกโมเดล

จากไฟล์ per_class_f1_matrix.csv ของ bundle 500k ที่ทุนแฟร์แล้ว มีคลาสที่ทุกโมเดลได้คะแนนใกล้เคียงกันหมด ตั้งแต่ logistic regression ไปจนถึง catboost

คลาสของ 2018	ช่วง F1 จาก 7 โมเดล
Infiltration	0.00 ถึง 0.13
DoS attacks-SlowHTTPTest	0.619 ถึง 0.638
FTP-BruteForce	0.755 ถึง 0.800

ฝั่ง 2017 ก็มีอาการเดียวกัน คลาส Bot มีค่า recall อยู่ระหว่าง 0.150 ถึง 0.161 เหมือนกันทั้ง เจ็ดโมเดล

เมื่อโมเดลเชิงเส้นกับ gradient boosting ที่ทุนแล้วได้ผลเท่ากัน แปลว่าพาดานันไม่ได้อยู่ที่ โมเดล แต่อยู่ที่ข้อมูล ถ้าช่องว่างของ cross-dataset ส่วนใหญ่มาจากสาเหตุนี้ distribution alignment ก็แก้ไม่ได้ ซึ่งอาจอธิบายได้ว่าทำไมสามวิธีที่อาจารย์ลองจึงไม่ขึ้น

10.2 คลาสที่มี test flow น้อยเกินกว่าจะวัดผลได้

ที่ขนาดตัวอย่าง 500,000 แถว มีสคลาสที่มี test flow รวมกันเพียง 25 แถวจาก 150,011 แถว ได้แก่ SQL Injection 1 แถว Brute Force -XSS 2 แถว Brute Force -Web 6 แถว และ DDOS attack-LOIC-UDP 16 แถว

แต่ละคลาสก็นำหนักหนึ่งในสิบห้าของ macro-F1 เท่ากับคลาส Benign ที่มี 124,610 แถว

ผลคือช่วงความเชื่อมั่นของ macro-F1 ที่ขนาด 300k กว้างเฉลี่ยประมาณ 0.128 และการเพิ่มข้อมูลจาก 300k เป็น 500k ไม่ได้ทำให้แคบลงเลย เพราะความกว้างมาจากคลาสที่หายากที่สุด ไม่ได้มาจากขนาดข้อมูลรวม

ข้อนี้มีผลต่อการอ่านผลชั้น C ในหัวข้อ 8 โดยตรง การยุบเหลือ 7 คลาสจะทำให้ Web Attack ดุดสามในสี่คลาสนี้เข้าไป และ DoS ดุด SlowHTTPTest ที่พึ่งอยู่เข้าไป คะแนนจะกระโดดขึ้นอย่างเห็นได้ชัด แต่ไม่ได้แปลว่าโมเดลเก่งขึ้น ต้องเขียนกำกับไว้เสมอ

11. การยุบ 15 คลาสเหลือ 7 คลาส

คลาสที่มีรวมกันเจ็ดคลาสคือ Benign, Bot, Infiltration, DDoS, DoS, Brute Force และ Web Attack

สามคลาสแรกจับคู่หนึ่งต่อหนึ่ง โดย Infiltration ผัง 2018 สะกดว่า Infiltration ส่วนอีกสี่คลาสต้องยุบหลายคลาสของ 2018 เข้าด้วยกัน คลาส Heartbleed และ PortScan ของ 2017 ไม่มีคู่ในผัง 2018 จึงต้องตัดออก

12. สิ่งที่ต้องทำต่อ

12.1 รอบนี้ ให้ cross-dataset รันได้ก่อนตามที่อาจารย์ขอ

1. ย้าย mapping 77 features เข้าโปรเจกต์เป็นโมดูลจริง พร้อม test กันชื่อคอลัมน์เปลี่ยน
2. เขียน label mapping 7 คลาสรวม
3. เขียน cleaner ที่ทั้งสองชุดใช้กฎเดียวกัน
4. สุ่มตัวอย่าง 300,000 แถวจาก 2017 ด้วยวิธีเดียวกับที่ทำกับ 2018
5. รัน 2017 ไป 2018 และ 2018 ไป 2017 แบบไม่ทุน หนึ่งโมเดล หนึ่ง seed

12.2 รอบถัดไป ทำให้ครบ protocol

1. เปิดช่อง calibration 10% และรันครบ 5 seeds
2. เพิ่มโหมด binary ผัง 2018 ให้เท่ากับผัง 2017
3. ทำ adversarial validation เพื่อหา feature ที่บ่งบอก dataset
4. เพิ่มเงื่อนไข temporal split ควบคู่กับ random split

13. ตัวติดขัดและคำถามที่ยังค้าง

ตัวติดขัดเดียวที่ทำให้เริ่มไม่ได้คือไม่มีข้อมูลดิบของ CICIDS2017 อยู่ในเครื่อง โฟลเดอร์ data/raw data/processed และ data/interim วางทั้งหมด มีเพียงไฟล์ตัวอย่างของ 2018 สองไฟล์ งานข้อ 3 ถึง 5 ในหัวข้อ 12.1 ขยับไม่ได้จนกว่าจะมีไฟล์ชุดนี้

คำถามที่ยังไม่ได้คำตอบจากอาจารย์

1. เป้าหมายของงานคือต้องได้ผลที่ดีขึ้นจริง หรือได้ข้อสรุปที่อธิบายได้ก็เพียงพอ
2. ขอรายชื่อ 7 คลาสและ 77 features ที่อาจารย์ใช้จริง พร้อม seed ที่ใช้ เพื่อให้ตัวเลขของสองผังเทียบกันได้
3. ขอตัวเลข baseline ของอาจารย์ทั้งสองทิศไว้ตรวจสอบว่าผังเรารันถูกทาง
4. protocol ที่ให้มาใช้ในการสุ่มแบ่ง 60/10/30 ซึ่งทำให้ flow จากช่วงเวลาโจมตีเดียวกันไปอยู่ทั้งฝั่ง train และ test ขออนุญาตรันเงื่อนไข temporal split ควบคู่ไปด้วย