

เปรียบเทียบผลเก่ากับผลใหม่ หลังย้ายไปใช้ Shared Schema

รันเมื่อวันที่ 9 สิงหาคม 2569 บนตัวอย่าง 300,000 แถวของ CSE-CIC-IDS2018

เอกสารนี้ตอบคำถามว่า การเปลี่ยนไปใช้ schema ร่วมสำหรับงาน cross-dataset ทำให้ผลลัพธ์เปลี่ยนไปเท่าไร และความเปลี่ยนแปลงนั้นมาจากอะไร

1. ข้อสรุปสำคัญที่สุด

การยุบคลาสจาก 15 เหลือ 7 ทำให้ตัวเลขพาดหัวดีขึ้นชัดเจน แต่ ประสิทธิภาพจริงบนคลาสที่วัดผลได้กลับแย่ลง ตัวเลขสองชุดนี้ชี้คนละทิศกัน

ตัววัด	ก่อนยุบคลาส	หลังยุบคลาส	ส่วนต่าง
macro-F1 ทุกคลาส	0.7126	0.7880	เพิ่ม 0.0754
macro-F1 เฉพาะคลาสที่วัดได้	0.8575	0.8193	ลดลง 0.0382

ตัวเลขข้างบนเป็นของ lightgbm ทิศทางเดียวกันนี้เกิดกับทุกโมเดล สาเหตุคือการยุบคลาสเอาคลาสที่โมเดลทำได้ดีไปรวมกับคลาสที่พัง ทำให้คลาสดีถูกดึงลง ขณะเดียวกันก็ทำให้คลาสจืดที่เคยได้ศูนย์หายไปจากการนับ macro ผลลบสองอย่างหักกลบกันจนดูเหมือนดีขึ้น

ถ้ารายงานเฉพาะตัวเลขพาดหัว จะสรุปผิดทันทีว่าการยุบคลาสทำให้โมเดลดีขึ้น

2. วิธีทดลอง

รันสี่เงื่อนไข เปลี่ยนทีละอย่าง

เงื่อนไข	feature	คลาส
A ฐานเดิม	77 มี Protocol ไม่มี Dst Port	15
B shared schema	76 ไม่มีทั้งสอง	15
B+ shared เพิ่ม Dst Port	77 ไม่มี Protocol มี Dst Port	15
C shared ยุบคลาส	76	7

เงื่อนไขที่คุณให้เหมือนกันทุกเงื่อนไข

- ใช้ตัวอย่างชุดเดียวกัน 300,000 แถว
- คำนวณ temporal split ครึ่งเดียวจาก label 15 คลาส แล้วใช้ร่วมกันทุกเงื่อนไข ดังนั้นแถว train 209,989 แถว และ test 90,011 แถว เป็นแถวเดียวกันเป๊ะทุกเงื่อนไข
- ใช้ hyperparameter เดิมจาก tuning.json ของ bundle 300k_temporal_tuned_fair ไม่มีการ tune ใหม่
- ใช้โมเดลที่รันเร็ว คือ lightgbm, xgboost, random forest และ logistic regression

ผลที่เห็นจึงมาจากการเปลี่ยน schema อย่างเดียว ไม่ใช่จากการแบ่งข้อมูลหรือการ tune

3. การตรวจสอบความถูกต้อง

เงื่อนไข A ต้องให้ผลตรงกับ bundle เดิมถ้าสคริปต์ถูกต้อง ผลออกมาตรงทุกหลัก

โมเดล	bundle เดิม	เงื่อนไข A
lightgbm	0.7110	0.7110
xgboost	0.6990	0.6990
random forest	0.7648	0.7648
logistic regression	0.6666	0.6666

ตัวความคุมผ่าน ส่วนต่างที่เหลือในเอกสารนี้จึงเชื่อถือได้

4. ผลรวม macro-F1 ทุกคลาส

โมเดล	A	B	B+	C
lightgbm	0.7110	0.7126	0.7164	0.7880
xgboost	0.6990	0.6990	0.6860	0.7883
random forest	0.7648	0.7642	0.7763	0.7813
logistic regression	0.6666	0.6797	0.6713	0.6496

5. ผลรวม macro-F1 เฉพาะคลาสที่วัดผลได้

นับเฉพาะคลาสที่มี test flow ตั้งแต่ 10 แถวขึ้นไป เหลือ 12 คลาสในกรอบ 15 คลาส และเหลือ 6 คลาสในกรอบ 7 คลาส

โมเดล	A	B	B+	C
lightgbm	0.8554	0.8575	0.8622	0.8193
xgboost	0.8404	0.8404	0.8575	0.8196
random forest	0.8528	0.8521	0.8672	0.8207
logistic regression	0.7777	0.7941	0.7836	0.7208

ตารางนี้กับตารางที่ 4 ชัดคนละทิศในคอลัมน์ C ทุกแถว

6. ส่วนต่างที่ละชั้น

6.1 ชั้น A ไปหา B คือการตัด Protocol ออก

โมเดล	ส่วนต่าง macro ทุกคลาส	ส่วนต่าง macro คลาสที่วัดได้
lightgbm	เพิ่ม 0.0016	เพิ่ม 0.0021
xgboost	เท่าเดิม	เท่าเดิม
random forest	ลด 0.0006	ลด 0.0007
logistic regression	เพิ่ม 0.0131	เพิ่ม 0.0164

ตัด Protocol ทิ้งไม่มีราคาต้องจ่าย ทั้งสี่โมเดลขยับไม่เกิน 0.017 และสามในสี่ขยับไม่ถึง 0.002 แปลว่าการทำให้ schema เข้ากันได้กับ 2017 ไม่ได้ทำให้เสียอะไรเลย

6.2 ชั้น B ไปหา B+ คือการเพิ่ม Dst Port กลับเข้ามา

โมเดล	ส่วนต่าง macro ทุกคลาส	ส่วนต่าง macro คลาสที่วัดได้
lightgbm	เพิ่ม 0.0038	เพิ่ม 0.0047
xgboost	ลด 0.0130	เพิ่ม 0.0171
random forest	เพิ่ม 0.0121	เพิ่ม 0.0151
logistic regression	ลด 0.0084	ลด 0.0105

กรณี xgboost น่าสนใจที่สุด ตัวเลขขาดห้วงกว่าแยลง 0.0130 แต่คะแนนบนคลาสที่วัดได้ดีขึ้น 0.0171

สาเหตุคือคลาส Brute Force -Web ที่มี test flow แค่ 4 แกวตจาก 0.40 เป็น 0.00

คลาสเดียวที่นำหนักหนึ่งในสิบห้า จึงกลบผลบวกของคลาสที่เหลือทั้งหมด

ที่ Dst Port ช่วยจริงคือคลาสที่ยากที่สุด

คลาส	B ไม่มี Dst Port	B+ มี Dst Port
Infiltration lightgbm	0.1185	0.1703
Infiltration random forest	0.1262	0.1782
Bot lightgbm	0.9925	0.9994
DoS Slowloris random forest	0.7647	0.8850

6.3 ชั้น B ไปหา C คือการยุบ 15 คลาสเหลือ 7 คลาส

โมเดล	ส่วนต่าง macro ทุกคลาส	ส่วนต่าง macro คลาสที่วัดได้
lightgbm	เพิ่ม 0.0754	ลด 0.0382
xgboost	เพิ่ม 0.0893	ลด 0.0208
random forest	เพิ่ม 0.0171	ลด 0.0314
logistic regression	ลด 0.0301	ลด 0.0733

ทุกโมเดลแยลงบนคลาสที่วัดผลได้ แต่สามในสี่ดูเหมือนดีขึ้นถ้าดูตัวเลขขาดห้วง

7. ผลรายคลาสหลังยุบเหลือ 7 คลาส

ตัวเลขของ lightgbm

คลาส	test flow	F1
Benign	74,769	0.9935
DDoS	7,009	0.9996
Bot	1,587	0.9925
DoS	3,629	0.9269
Brute Force	2,112	0.8860
Web Attack	7	0.6000
Infiltration	898	0.1173

8. ข้อค้นพบที่สำคัญ

8.1 การยุบคลาสไม่ได้แก้คลาสที่พังจริง

Infiltration เป็นคลาสเดียวที่ปรากฏเหมือนกันทั้งก่อนและหลังยุบ เพราะจับคู่หนึ่งต่อหนึ่ง ค่า F1 ของมันแทบไม่ขยับเลย

เงื่อนไข	Infiltration F1 lightgbm
B ก่อนยุบคลาส	0.1185
C หลังยุบคลาส	0.1173

คลาสที่พังยังพังเท่าเดิม สิ่งที่การยุบคลาสทำคือย้ายคลาสจิวที่ทำคะแนนไม่ได้ไปซ่อนไว้ในคลาสใหญ่ ไม่ใช่การทำให้โมเดลเรียนรู้ได้ดีขึ้น

8.2 การยุบคลาสทำให้คลาสที่ดีอยู่แล้วแย่ลง

คลาสต้นทาง	F1 ก่อนยุบ	คลาสปลายทาง	F1 หลังยุบ
SSH-Bruteforce	1.0000	Brute Force	0.8860
FTP-BruteForce	0.7946	Brute Force	0.8860
DoS attacks-Hulk	1.0000	DoS	0.9269
DoS SlowHTTPTest	0.6281	DoS	0.9269

การรวมคลาสที่ทำให้ได้สมรรถนะเข้ากับคลาสที่ทำไม่ได้ ทำให้ผลลัพธ์ไปกองอยู่ตรงกลาง ข้อมูลว่า โมเดลแยก SSH-Bruteforce ได้สมรรถนะหายไปจากรายงาน

8.3 ปัญหาคลาสจิวไม่ได้หายไปหลังยุบเหลือ 7 คลาส

คลาส Web Attack หลังยุบรวมสามคลาสเข้าด้วยกันแล้ว ยังมี test flow เพียง 7 แถว ยังไม่ถึง เกณฑ์ที่วัดผลได้ ปัญหาลดจากสี่คลาสจิวเหลือหนึ่งคลาสจิว แต่ไม่ได้หมดไป

ข้อนี้แก้ความเข้าใจเดิมที่เคยประเมินว่าการยุบเหลือ 7 คลาสจะทำให้ปัญหาคลาสจิวหมดไป

8.4 logistic regression ตอบสนองกลับทิศกับโมเดลต้นไม้

การยุบคลาสทำให้ logistic regression แย่ลงทั้งสองตัววัด ต่างจากอีกสามโมเดลที่ตัวเลขพาดหัว ดีขึ้น สาเหตุคือ DDos ตกจาก 0.97 เหลือ 0.895 และ DoS ตกเหลือ 0.913 เพราะโมเดลเชิงเส้นเคยแยกคลาสน้อยเหล่านี้ออกจากกันได้ พอถูกบังคับให้รวมเป็นก้อนเดียว ขอบเขตการตัดสินใจที่เคยใช้ได้ก็ใช้ไม่ได้อีก

9. ผลต่อแผนงาน cross-dataset

- การย้ายไป shared schema ปลอดภัย การตัด Protocol ออกไม่มีราคาต้องจ่าย เงินหน้าใช้ 77 features รวมได้เลย
- ต้องตัดสินใจเรื่อง Dst Port ก่อนรัน cross-dataset ตอนนี้ pipeline 2017 เก็บไว้ แต่ pipeline 2018 ตัดทิ้ง ทั้งสองฝั่งต้องทำเหมือนกัน ผลข้างบนบอกว่ามันช่วยคลาสที่ยากจริง โดยเฉพาะ Infiltration ที่ขึ้นจาก 0.12 เป็น 0.17 แต่มันก็เป็น feature ที่ผูกกับ lab มากที่สุดตัวหนึ่ง จึงเป็นตัวต้องสงสัยอันดับต้นในการทำ adversarial validation
- ต้องรายงาน macro-F1 สองแบบเสมอ
ผลชุดนี้แสดงให้เห็นว่าการรายงานแบบเดียวนำไปสู่ข้อสรุปที่กลับทิศกับความจริง
- ต้องระวังการอ่านผลของอาจารย์ ถ้าอาจารย์รายงานผล 7 คลาสด้วยตัวเลขพาดหัวอย่างเดียว ตัวเลขนั้นจะสูงกว่าความเป็นจริง และเมื่อนำไปเทียบกับผล cross-dataset จะทำให้ช่องว่างดูใหญ่เกินจริง

10. สิ่งที่ยังทำไม่ได้

ยังไม่ได้รันเงื่อนไข D คือการข้ามชุดข้อมูลจริง เพราะไม่มีข้อมูลดิบของ CICIDS2017 อยู่ในเครื่อง

ผลชุดนี้ทั้งหมดเป็นฝั่ง 2018 อย่างเดียว จึงยังตอบไม่ได้ว่าการข้ามชุดข้อมูลมีราคาเท่าไร
ตอบได้แค่ว่าการเตรียม schema ให้พร้อมสำหรับการข้ามชุดข้อมูลมีราคาเท่าไร ซึ่งคำตอบคือ
แทบไม่มีราคาเลยในส่วนของ feature แต่มีราคาแฝงที่มองไม่เห็นในส่วนของการยุบคลาส

11. ไฟล์ผลลัพธ์

- ablation_summary.csv ตารางสรุป 16 แถว
- ablation_per_class_15.csv F1 รายคลาสของเงื่อนไข A B และ B+
- ablation_per_class_7.csv F1 รายคลาสของเงื่อนไข C
- ablation_schema.py สคริปต์ที่ใช้รัน