

Cross-Dataset: macro-F1 (ค่าเฉลี่ย $\pm$ SD)

ควบคู่กับ Recovery %

เอกสารนี้ทำตามทีขอ ณ วันที่ 3 ตุลาคม 2569: นอกจาก Recovery % ให้รายงาน macro-F1 ค่าเฉลี่ย $\pm$ SD ด้วย เพื่อให้เห็นคะแนนจริงควบคู่กัน

ตัวเลขทั้งหมดอ่านมาจาก results.csv ของ protocol_v2 (รอบ 5 ตัวล่าสุด) และ protocol_v1 (รอบ 4) ผ่าน scripts/analyze_crossdataset.py ซึ่งเพิ่มตาราง summary_macro_f1.csv ไม่ได้เทรนโมเดลหรือรันการทดลองใหม่ และตารางเดิมทั้งสี่ (summary_gap, summary_leakage, summary_per_class, summary_support) ได้ค่าเท่าเดิมทุกตำแหน่ง

สรุปสั้น

1. Recovery % กับคะแนนจริงจัดอันดับไม่ตรงกัน ตัวอย่างชัดที่สุดคือโมเดล chronological ทิศ 2018 ไป 2017 (รอบ 5)

โมเดล	Recovery %	อันดับตาม Recovery	macro-F1 จริง (เฉลี่ย $\pm$ SD)	อันดับตามคะแนนจริง
logistic_regression	79.8%	1	0.3493 $\pm$ 0.0000	4
lightgbm	52.8%	2	0.4480 $\pm$ 0.0079	1

logistic_regression ได้ Recovery สูงสุดเพราะ Recovery คิดเทียบ ceiling ของโมเดลนั่นเอง และ ceiling ของ logistic_regression บน 2017 ต่ำมาก (0.4050) ตัวหารจึงเล็ก ส่วน lightgbm ที่ได้คะแนนจริงสูงสุดมี ceiling 0.7325

2. คะแนนจริงต่ำในทั้งสองทิศ ทิศ 2018 ไป 2017 ดีที่สุดคือ 0.4480 $\pm$ 0.0079 เทียบ ceiling 0.7325 และ baseline 0.1294 ส่วนทิศ 2017 ไป 2018 ทุกโมเดลอยู่ที่ 0.1508 ถึง 0.2058 เทียบ baseline 0.1337

3. SD เล็กพอจะแยกโมเดลได้ในทิศ 2018 ไป 2017 แต่ไม่ใช่ทิศ 2017 ไป 2018 lightgbm ชนะทุก seed ในทิศแรก (seed ที่แย่ที่สุดของ lightgbm ได้ 0.4396 ยังสูงกว่า seed ที่ดีที่สุดของทุกโมเดลอื่น ซึ่งสูงสุดคือ stacking 0.4188) ส่วนทิศหลัง ค่าเฉลี่ย 0.2058 $\pm$ 0.0641 ของ lightgbm ถูกดึงขึ้นโดย seed 42 เพียงค่าเดียว (0.3204) อีก 4 seeds อยู่ที่ 0.1766 ถึง 0.1776

4. SD ในโมเดล chronological วัดได้เฉพาะความสับสนของโมเดล การแบ่งข้อมูลและการสุ่ม 300,000 แถวไม่เปลี่ยนตาม seed โมเดลที่ไม่มีส่วนสับสน (logistic_regression) จึงได้ SD = 0.0000 พอดี ซึ่งหมายถึง "ไม่มีอะไรเปลี่ยน" ไม่ใช่ "เสถียรมาก" ดูหัวข้อ 1

5. ข้อควรระวังเรื่อง ceiling ของ 2017 ceiling แบบ chronological ของ 2017 ถูกกดโดยคลาส Brute Force ที่ได้ F1 0.0000 ถึง 0.0043 ในทุกโมเดล (แบบสุ่มได้ 0.9678 ถึง 0.9997) เพราะ train ไม่มี SSH-Patator เลย ตัวหารของ Recovery จึงเล็กลงและ Recovery ของทิศ 2018 ไป 2017 สูงขึ้นตามไปด้วย ดูหัวข้อ 6 และรายงานการแบ่งข้อมูล docs/experiments/ids2017/report/chronological_split_explained.md

1. วิธีอ่านตาราง

คอลัมน์	ความหมาย
baseline	macro-F1 ของการเดาว่าทุกแถวเป็น Benign ทุกโมเดลได้ค่าเดียวกัน: 0.1337 บน test ของ 2018, 0.1294 บน test ของ 2017

คอลัมน์	ความหมาย
ceiling	macro-F1 ของโมเดลเดียวกันที่เทรนและทดสอบบน dataset ปลายทาง (เฉลี่ย $\pm$ SD)
macro-F1 ข้ามชุด	คะแนนจริงของโมเดลที่เทรนกับอีก dataset แล้วทดสอบกับ dataset ปลายทาง เฉลี่ย $\pm$ SD ของ 5 seeds (42 ถึง 46)
ต่ำสุด-สูงสุด	ค่าต่ำสุดและสูงสุดของ 5 seeds ใช้ดูว่าค่าเฉลี่ยมาจากหลาย seed หรือเพียงค่าเดียว
Recovery %	$(\text{ข้ามชุด} - \text{baseline}) / (\text{ceiling} - \text{baseline}) \times 100$ คิดจากค่าเฉลี่ย ตรงกับตัวเลขในรายงานรอบ 4 และ 5 ทุกตัว
อันดับ F1 / Recovery	อันดับของโมเดลในตารางนั้นตามคะแนนจริง และตาม Recovery

macro-F1 ในตารางหลักคือ f1_macro_all เฉลี่ยทุกคลาสที่ปรากฏใน test ซึ่งเป็นตัวเดียวกับที่ Recovery ใช้ค่าที่นับเฉพาะคลาสที่มี test อย่างน้อย 30 แถวอยู่ในหัวข้อ 5

SD อ่านอย่างไร

- ค่า SD คือ sample SD ของ 5 seeds (หารด้วย $n - 1$) ช่วงเชื่อมั่น 95% ของค่าเฉลี่ยประมาณ $\pm 1.24 \times \text{SD}$ (t ที่ 4 องศาอิสระ)
- โหมด chronological ตัวอย่าง 300,000 แถวถูกสุ่มครั้งเดียว (seed 42) และการแบ่ง train/test ไม่ใช่ seed seed ทั้งห้าจึงต่างกันที่ค่าเริ่มต้นของโมเดลอย่างเดียวน SD ที่ได้คือความผันผวนจากโมเดล ไม่ใช่ความผันผวนจากข้อมูลหรือจากการเลือกช่วงเวลา โมเดลที่ไม่มีส่วนสุ่มได้ SD = 0.0000 พอดี
- โหมด random seed เปลี่ยนการแบ่งด้วย SD จึงรวมความผันผวนจากการแบ่งข้อมูลเข้าไปด้วย
- ทั้งสองโหมดไม่รวมความผันผวนจากการสุ่ม 300,000 แถว ออกจาก corpus เดิม เพราะสุ่มครั้งเดียว SD ที่เห็น จึงน่าจะต่ำกว่าความไม่แน่นอนจริง

2. ผลหลัก: protocol_v2, โหมด chronological

โหมดที่ข้อสรุปของรอบ 4 และ 5 ยืนยันอยู่ เรียงตามคะแนนจริงจากมากไปน้อย

2.1 เทรนด้วย 2018 ทดสอบกับ 2017 (baseline 0.1294)

โมเดล	ceiling (เทรนและทดสอบบน 2017)	macro-F1 ข้ามชุด (เฉลี่ย $\pm$ SD)	ต่ำสุด-สูงสุดของ 5 seeds	Recovery %	อันดับ F1 / Recovery
lightgbm	0.7325 $\pm$ 0.0008	0.4480 $\pm$ 0.0079	0.4396–0.4575	52.8%	1 / 2
stacking	0.7219 $\pm$ 0.0036	0.3674 $\pm$ 0.0386	0.3312–0.4188	40.2%	2 / 3
xgboost	0.7172 $\pm$ 0.0050	0.3615 $\pm$ 0.0182	0.3427–0.3831	39.5%	3 / 5
logistic_regression	0.4050 $\pm$ 0.0000	0.3493 $\pm$ 0.0000	0.3493–0.3493	79.8%	4 / 1
mlp	0.5860 $\pm$ 0.0321	0.3107 $\pm$ 0.0248	0.2936–0.3535	39.7%	5 / 4
catboost	0.7161 $\pm$ 0.0050	0.2226 $\pm$ 0.0041	0.2181–0.2290	15.9%	6 / 6
random_forest	0.6652 $\pm$ 0.0109	0.1680 $\pm$ 0.0007	0.1672–0.1689	7.2%	7 / 7

- อันดับต่างกัน 5 จาก 7 โมเดล ต่างมากที่สุดคือ logistic_regression: อันดับ 1 โดย Recovery แต่อันดับ 4 โดยคะแนนจริง (0.3493 $\pm$ 0.0000) ต่ำกว่า lightgbm (0.4480 $\pm$ 0.0079) อยู่ 0.0987
- lightgbm ชนะทุก seed ค่าต่ำสุดของ lightgbm (0.4396) สูงกว่าค่าสูงสุดของโมเดลอื่นทุกตัว

- stacking ผันผวนที่สุด SD 0.0386 (0.3312 ถึง 0.4188) ในรอบ 4 stacking เคยเป็นผลดีที่สุดของงาน ดูหัวข้อ 4

2.2 เทรนด้วย 2017 ทดสอบกับ 2018 (baseline 0.1337)

โมเดล	ceiling (เทรนและทดสอบบน 2018)	macro-F1 ข้ามชุด (เฉลี่ย $\pm$ SD)	ต่ำสุด-สูงสุดของ 5 seeds	Recovery %	อันดับ F1 / Recovery
lightgbm	0.8596 $\pm$ 0.0006	0.2058 $\pm$ 0.0641	0.1766–0.3204	9.9%	1 / 1
mlp	0.8228 $\pm$ 0.0115	0.1755 $\pm$ 0.0014	0.1735–0.1773	6.1%	2 / 2
catboost	0.8480 $\pm$ 0.0036	0.1726 $\pm$ 0.0009	0.1711–0.1734	5.4%	3 / 3
random_forest	0.8412 $\pm$ 0.0018	0.1717 $\pm$ 0.0001	0.1716–0.1719	5.4%	4 / 3
stacking	0.8283 $\pm$ 0.0021	0.1715 $\pm$ 0.0007	0.1706–0.1725	5.4%	5 / 3
xgboost	0.8539 $\pm$ 0.0026	0.1712 $\pm$ 0.0001	0.1711–0.1713	5.2%	6 / 6
logistic_regression	0.7511 $\pm$ 0.0000	0.1508 $\pm$ 0.0000	0.1508–0.1508	2.8%	7 / 7

- ทุกโมเดลอยู่ใกล้ baseline คะแนนจริง 0.1508 ถึง 0.2058 ส่วนที่เพิ่มจาก baseline ไม่เกิน 0.0721 ขณะที่ ceiling อยู่ที่ 0.7511 ถึง 0.8596
- lightgbm ถูกดึงขึ้นโดย seed เดียว ค่าเฉลี่ย 0.2058 $\pm$ 0.0641 (Recovery 9.9%) ประกอบด้วย seed 42 = 0.3204 (Recovery 25.7%) และอีก 4 seeds = 0.1766 ถึง 0.1776 (Recovery 5.9% ถึง 6.0%) ถ้าไม่นับ seed 42 lightgbm ใกล้เคียงโมเดลอื่น (มีฐาน 0.1775 เทียบ 0.1508 ถึง 0.1755 ของห้าโมเดลที่ไม่ใช่ logistic_regression) ตัวเลข "lightgbm ดีที่สุดของทีศนี้" ในรายงานรอบ 4 และ 5 จึงควรอ่านพร้อมข้อนี้

3. protocol_v2, โหมด random

โหมดที่ protocol ของอาจารย์กำหนด เรียงตามคะแนนจริง

3.1 เทรนด้วย 2018 ทดสอบกับ 2017 (baseline 0.1294)

โมเดล	ceiling (เทรนและทดสอบบน 2017)	macro-F1 ข้ามชุด (เฉลี่ย $\pm$ SD)	ต่ำสุด-สูงสุดของ 5 seeds	Recovery %	อันดับ F1 / Recovery
stacking	0.9745 $\pm$ 0.0096	0.3071 $\pm$ 0.0360	0.2738–0.3673	21.0%	1 / 2
lightgbm	0.9775 $\pm$ 0.0117	0.2924 $\pm$ 0.0594	0.2305–0.3744	19.2%	2 / 3
xgboost	0.9716 $\pm$ 0.0171	0.2661 $\pm$ 0.0241	0.2283–0.2914	16.2%	3 / 4
logistic_regression	0.6107 $\pm$ 0.0158	0.2544 $\pm$ 0.0265	0.2073–0.2702	26.0%	4 / 1
catboost	0.9694 $\pm$ 0.0108	0.2327 $\pm$ 0.0204	0.2054–0.2524	12.3%	5 / 6
mlp	0.8744 $\pm$ 0.0127	0.2280 $\pm$ 0.0168	0.2121–0.2471	13.2%	6 / 5
random_forest	0.9566 $\pm$ 0.0209	0.1508 $\pm$ 0.0013	0.1490–0.1525	2.6%	7 / 7

3.2 เทรนด้วย 2017 ทดสอบกับ 2018 (baseline 0.1337)

โมเดล	ceiling (เทรนและทดสอบบน 2018)	macro-F1 ข้ามชุด (เฉลี่ย $\pm$ SD)	ต่ำสุด-สูงสุดของ 5 seeds	Recovery %	อันดับ F1 / Recovery
lightgbm	0.8696 $\pm$ 0.0050	0.3018 $\pm$ 0.0312	0.2690–0.3531	22.8%	1 / 1
stacking	0.8388 $\pm$ 0.0030	0.2841 $\pm$ 0.0106	0.2660–0.2929	21.3%	2 / 2
xgboost	0.8674 $\pm$ 0.0022	0.2731 $\pm$ 0.0649	0.1649–0.3354	19.0%	3 / 3
mlp	0.8206 $\pm$ 0.0127	0.1748 $\pm$ 0.0354	0.1476–0.2351	6.0%	4 / 4
catboost	0.8590 $\pm$ 0.0016	0.1728 $\pm$ 0.0050	0.1663–0.1775	5.4%	5 / 5
random_forest	0.8624 $\pm$ 0.0046	0.1718 $\pm$ 0.0095	0.1588–0.1835	5.2%	6 / 6
logistic_regression	0.7775 $\pm$ 0.0088	0.1380 $\pm$ 0.0007	0.1371–0.1389	0.7%	7 / 7

- ceiling ของ 2017 สูงมาก (0.9566 ถึง 0.9775 ในโมเดลที่ไม่ใช่ logistic_regression/mlp) Recovery ของทิศ 2018 ไป 2017 จึงเล็ก (2.6% ถึง 26.0%) เทียบกับ 7.2% ถึง 79.8% ในโหมด chronological
- คะแนนข้ามชุดเองก็เปลี่ยนตามโหมด ไม่ใช่เฉพาะ ceiling ทิศ 2018 ไป 2017: lightgbm 0.4480 (chronological) เป็น 0.2924 (random), stacking 0.3674 เป็น 0.3071, xgboost 0.3615 เป็น 0.2661 ส่วนต่างส่วนใหญ่อยู่ที่ Brute Force ในทั้งสามโมเดล (lightgbm 0.965 เป็น 0.586) และที่ Bot ใน lightgbm (0.883 เป็น 0.273) ซึ่งสอดคล้องกับองค์ประกอบของ test: ของ 2017 แบบ chronological Brute Force เป็น SSH-Patator ล้วน ส่วนแบบสุ่มมีทั้ง FTP-Patator (1,766 แถว) และ SSH-Patator (979 แถว) ยังไม่ได้ทดสอบราย sub-attack ว่าเป็นสาเหตุโดยตรง ข้อความในรายงานรอบ 5 หัวข้อ 4.3 ที่ว่า "แม้ transfer จริงจะไม่ได้เปลี่ยน" จึงไม่ตรงกับตัวเลขเหล่านี้ (ทั้ง ceiling และคะแนนข้ามชุดเปลี่ยน)
- SD ใหญ่กว่าโหมด chronological เพราะรวมความผันผวนจากการแบ่ง เช่น xgboost ทิศ 2017 ไป 2018 ได้ 0.2731 $\pm$ 0.0649 (0.1649 ถึง 0.3354) และ lightgbm ทิศ 2018 ไป 2017 ได้ 0.2924 $\pm$ 0.0594
- logistic_regression ทิศ 2018 ไป 2017 อันดับ 1 โดย Recovery (26.0%) แต่อันดับ 4 โดยคะแนนจริง (0.2544 $\pm$ 0.0265) เหมือนกับโหมด chronological

4. เทียบ protocol_v1 กับ protocol_v2 (ทิศ 2018 ไป 2017, chronological)

สิ่งเดียวที่เปลี่ยนคือลำดับการเตรียมข้อมูลของคลัง 2018 (clean ก่อน sample) ดูรายงานรอบ 5 หัวข้อ 4

โมเดล	v1 (รอบ 4) macro-F1 $\pm$ SD	v1 Recovery	v2 (รอบ 5) macro-F1 $\pm$ SD	v2 Recovery	v2 – v1 (macro-F1)
lightgbm	0.5006 $\pm$ 0.0204	61.5%	0.4480 $\pm$ 0.0079	52.8%	-0.0526
stacking	0.5756 $\pm$ 0.0352	73.9%	0.3674 $\pm$ 0.0386	40.2%	-0.2082
xgboost	0.4376 $\pm$ 0.0255	51.2%	0.3615 $\pm$ 0.0182	39.5%	-0.0761
logistic_regression	0.2762 $\pm$ 0.0000	53.3%	0.3493 $\pm$ 0.0000	79.8%	+0.0731
mlp	0.3049 $\pm$ 0.0349	40.3%	0.3107 $\pm$ 0.0248	39.7%	+0.0058
catboost	0.2830 $\pm$ 0.0075	26.3%	0.2226 $\pm$ 0.0041	15.9%	-0.0604
random_forest	0.1615 $\pm$ 0.0046	6.0%	0.1680 $\pm$ 0.0007	7.2%	+0.0065

stacking ที่เคยเป็นผลดีที่สุดของงาน (0.5756 $\pm$ 0.0352, Recovery 73.9%) เหลือ 0.3674 $\pm$ 0.0386 (Recovery 40.2%) และ lightgbm กลายเป็นอันดับ 1 ตรงกับที่รายงานรอบ 5 สรุปว่าตัวเลข 73.9%

เป็นผลของคลัง 2018 เวอร์ชันเดิม ตาราง v1 และ v2 ครบทั้งสองทิศและสองโหมดอยู่ในภาคผนวก

5. macro-F1 เฉพาะคลาสที่วัดได้ (protocol_v2, chronological, ทิศ 2018 ไป 2017)

คลาสที่มี test น้อยกว่า 30 แถวมีน้ำหนักเท่าคลาสที่มีหมื่นแถวในค่าเฉลี่ย ในการทดสอบกับ 2017 คลาส Infiltration มี test เพียง 10 แถว จึงถูกตัดออกจากค่านี้ (เหลือ 6 คลาส) ส่วนการทดสอบกับ 2018 ครบ 7 คลาส ค่าทั้งสองแบบจึงเท่ากัน

โมเดล	macro-F1 ทุกคลาส (7)	macro-F1 เฉพาะคลาสที่วัดได้ (6)
lightgbm	0.4480 ± 0.0079	0.5226 ± 0.0093
stacking	0.3674 ± 0.0386	0.4286 ± 0.0451
xgboost	0.3615 ± 0.0182	0.4217 ± 0.0212
logistic_regression	0.3493 ± 0.0000	0.4075 ± 0.0000
mlp	0.3107 ± 0.0248	0.3624 ± 0.0289
catboost	0.2226 ± 0.0041	0.2597 ± 0.0048
random_forest	0.1680 ± 0.0007	0.1960 ± 0.0008

อันดับของโมเดลไม่เปลี่ยน คะแนนสูงขึ้น 0.028 ถึง 0.075 เพราะ Infiltration ได้ F1 เป็นศูนย์ในทุกโมเดล

6. ข้อควรระวัง: ceiling ของ 2017 แบบ chronological

Recovery หารด้วย (ceiling – baseline) ถ้า ceiling ต่ำผิดปกติ Recovery จะสูงขึ้นโดยที่คะแนนข้ามชุดไม่เปลี่ยน

ceiling ของ 2017 แบบ chronological ต่ำเพราะคลาส Brute Force ได้ F1 0.0000 ถึง 0.0043 ในทุกโมเดล (แบบสุ่มได้ 0.9678 ถึง 0.9997) สาเหตุอยู่ที่ลำดับแถว: Brute Force ของ 2017 ประกอบด้วย FTP-Patator ตามด้วย SSH-Patator ตามลำดับในไฟล์ การแบ่ง 60/10/30 จึงได้ train เป็น FTP-Patator ล้วน (5,490 แถว) ส่วน SSH-Patator 474 แถวแรกตกอยู่ในช่อง calibration ที่ไม่ได้ใช้ และ test (2,745 แถว) เป็น SSH-Patator ทั้งหมด โมเดลจึงไม่เคยเห็น SSH-Patator ตอนเทรน รายละเอียดและตัวเลขอยู่ใน docs/experiments/ids2017/report/chronological_split_explained.md หัวข้อ 5

ผลต่อ Recovery ของ lightgbm ทิศ 2018 ไป 2017 (เลขคณิตเพื่อดูขนาด ไม่ใช่ผลการทดลอง): ถ้า Brute Force ได้ 0.9995 เท่ากับโหมดสุ่ม ceiling จะเป็นราว 0.8753 แทน 0.7325 และ Recovery จะลดจาก 52.8% เป็นราว 42.7% ส่วนคะแนนข้ามชุด 0.4480 ± 0.0079 ไม่เปลี่ยน นี่คือเหตุผลที่ควรอ่านคะแนนจริงควบคู่กับ Recovery

7. ข้อจำกัด

1. SD วัดความสุ่มของโมเดลเป็นหลัก ไม่รวมการสุ่ม 300,000 แถวและไม่รวมการเลือกช่วงเวลา ดูหัวข้อ 1
2. n = 5 seeds SD จาก 5 ค่าเองก็ไม่แน่นอนมาก และค่าเฉลี่ยของบางเซลล์มาจาก seed เดียว (หัวข้อ 2.2) คอลัมน์ต่ำสุด-สูงสุดมีไว้ให้เห็นกรณีนี้
3. Recovery คิดจากค่าเฉลี่ย ไม่ใช่ค่าเฉลี่ยของ Recovery ราย seed ซึ่งต่างกันได้เมื่อ seed กระจาย (lightgbm 2017 ไป 2018: 9.9% จากค่าเฉลี่ย เทียบ 5.9% ถึง 25.7% ราย seed)
4. ไม่ได้หุน hyperparameter และไม่ได้ใช้ช่อง calibration ตามรอบ 4

8. ไฟล์และวิธีสร้างซ้ำ

ไฟล์	เนื้อหา
results/crossdataset/protocol_v2/summary_macro_f1.csv	ตารางต้นทางของเอกสารนี้ (รอบ 5) ทั้ง 56 เซลล์: ceiling และข้ามชุด, เฉลี่ย, SD, ต่ำสุด, สูงสุด, ทั้งสองนิยาม macro-F1, baseline, Recovery %
results/crossdataset/protocol_v1/summary_macro_f1.csv	ตารางเดียวกันของรอบ 4
docs/experiments/crossdataset/round5_reliability_audit/data/summary_macro_f1_v2.csv	สำเนาของตาราง v2
docs/experiments/crossdataset/round4_protocol_full/data/summary_macro_f1.csv	สำเนาของตาราง v1

```
python scripts/analyze_crossdataset.py --run-name protocol_v2
python scripts/analyze_crossdataset.py --run-name protocol_v1
```

สคริปต์เขียน summary_macro_f1.csv เพิ่มจากตารางเดิมสี่ไฟล์ ซึ่งยังเหมือนเดิมทุกตำแหน่ง

ภาคผนวก ก. protocol_v1 (รอบ 4)

chronological, 2018 ไป 2017 (baseline 0.1294)

โมเดล	ceiling (เทรนและทดสอบบน 2017)	macro-F1 ข้ามชุด (เฉลี่ย $\pm$ SD)	ต่ำสุด-สูงสุดของ 5 seeds	Recovery %	อันดับ F1 / Recovery
stacking	0.7329 $\pm$ 0.0042	0.5756 $\pm$ 0.0352	0.5169–0.6112	73.9%	1 / 1
lightgbm	0.7325 $\pm$ 0.0008	0.5006 $\pm$ 0.0204	0.4717–0.5277	61.5%	2 / 2
xgboost	0.7314 $\pm$ 0.0009	0.4376 $\pm$ 0.0255	0.4021–0.4717	51.2%	3 / 4
mlp	0.5652 $\pm$ 0.0507	0.3049 $\pm$ 0.0349	0.2598–0.3577	40.3%	4 / 5
catboost	0.7143 $\pm$ 0.0038	0.2830 $\pm$ 0.0075	0.2765–0.2943	26.3%	5 / 6
logistic_regression	0.4050 $\pm$ 0.0000	0.2762 $\pm$ 0.0000	0.2762–0.2762	53.3%	6 / 3
random_forest	0.6652 $\pm$ 0.0109	0.1615 $\pm$ 0.0046	0.1553–0.1650	6.0%	7 / 7

chronological, 2017 ไป 2018 (baseline 0.1320)

โมเดล	ceiling (เทรนและทดสอบบน 2018)	macro-F1 ข้ามชุด (เฉลี่ย $\pm$ SD)	ต่ำสุด-สูงสุดของ 5 seeds	Recovery %	อันดับ F1 / Recovery
lightgbm	0.7739 $\pm$ 0.0016	0.1799 $\pm$ 0.0581	0.1539–0.2838	7.5%	1 / 1
logistic_regression	0.6810 $\pm$ 0.0000	0.1562 $\pm$ 0.0000	0.1562–0.1562	4.4%	2 / 2
mlp	0.7047 $\pm$ 0.0062	0.1532 $\pm$ 0.0005	0.1524–0.1538	3.7%	3 / 3
stacking	0.7039 $\pm$ 0.0014	0.1529 $\pm$ 0.0008	0.1522–0.1540	3.6%	4 / 4
random_forest	0.7146 $\pm$ 0.0010	0.1528 $\pm$ 0.0003	0.1522–0.1530	3.6%	5 / 4

โมเดล	ceiling (เทรนแล ะทดสอบบน 2018)	macro-F1 ข้ามชุด (เฉลี่ย $\pm$ SD)	ต่ำสุด-สูงสุดของ 5 seeds	Recovery %	อันดับ F1 / Recovery
xgboost	0.7719 $\pm$ 0.0005	0.1523 $\pm$ 0.0009	0.1514–0.1536	3.2%	6 / 7
catboost	0.7150 $\pm$ 0.0007	0.1518 $\pm$ 0.0003	0.1515–0.1523	3.4%	7 / 6

random, 2018 ไป 2017

โมเดล	ceiling (เทรนแล ะทดสอบบน 2017)	macro-F1 ข้ามชุด (เฉลี่ย $\pm$ SD)	ต่ำสุด-สูงสุดของ 5 seeds	Recovery %	อันดับ F1 / Recovery
lightgbm	0.9775 $\pm$ 0.0117	0.3480 $\pm$ 0.0115	0.3293–0.3597	25.8%	1 / 1
xgboost	0.9725 $\pm$ 0.0169	0.3197 $\pm$ 0.0169	0.3013–0.3374	22.6%	2 / 2
stacking	0.9730 $\pm$ 0.0126	0.3101 $\pm$ 0.0266	0.2706–0.3356	21.4%	3 / 3
catboost	0.9695 $\pm$ 0.0108	0.2175 $\pm$ 0.0049	0.2131–0.2259	10.5%	4 / 6
mlp	0.8815 $\pm$ 0.0181	0.2109 $\pm$ 0.0108	0.2015–0.2283	10.8%	5 / 5
logistic_regression	0.6127 $\pm$ 0.0169	0.2018 $\pm$ 0.0020	0.1999–0.2042	15.0%	6 / 4
random_forest	0.9566 $\pm$ 0.0209	0.1602 $\pm$ 0.0183	0.1470–0.1922	3.7%	7 / 7

random, 2017 ไป 2018

โมเดล	ceiling (เทรนแล ะทดสอบบน 2018)	macro-F1 ข้ามชุด (เฉลี่ย $\pm$ SD)	ต่ำสุด-สูงสุดของ 5 seeds	Recovery %	อันดับ F1 / Recovery
lightgbm	0.8019 $\pm$ 0.0251	0.3278 $\pm$ 0.0357	0.2957–0.3889	29.2%	1 / 2
stacking	0.7103 $\pm$ 0.0004	0.3121 $\pm$ 0.0075	0.3041–0.3232	31.1%	2 / 1
xgboost	0.7918 $\pm$ 0.0424	0.3105 $\pm$ 0.0159	0.2828–0.3223	27.1%	3 / 3
catboost	0.7423 $\pm$ 0.0270	0.1927 $\pm$ 0.0139	0.1757–0.2097	9.9%	4 / 4
random_forest	0.7420 $\pm$ 0.0276	0.1554 $\pm$ 0.0217	0.1429–0.1940	3.8%	5 / 5
mlp	0.7344 $\pm$ 0.0236	0.1517 $\pm$ 0.0081	0.1403–0.1620	3.3%	6 / 6
logistic_regression	0.7143 $\pm$ 0.0221	0.1340 $\pm$ 0.0007	0.1333–0.1347	0.3%	7 / 7