ผล SHAP รอบ 2-3 แบบแบ่ง 70/30

ฉบับก่อนใช้ผลที่ train 60% (โปรโตคอลเดิมกัน calibration 10% ไว้แต่ไม่เคยใช้) ฉบับนี้รันรอบ 2-3 ใหม่ทั้งหมดบน split 70/30 ด้วยสคริปต์และเกณฑ์เดิม ไม่แก้ F ไม่แก้เกณฑ์
ตัวเลขทุกตัวในเอกสารนี้อ่านจากไฟล์ผลโดยตรง ผลที่ train 60% เทียบไว้ในหัวข้อสุดท้าย

เอกสารนี้เอาผลรอบ 2 (LightGBM) กับรอบ 3 (RF, XGBoost, CatBoost) มาจัดเป็น 4 ส่วน ใช้ค่า SHAP รายแถวที่เก็บไว้ตอนรันจริง แล้วสุ่มกลุ่ม feature 2,000 ชุดใหม่ด้วย seed เดิม ได้ค่า G และ p ตรงกับผลรอบ 2-3 ที่รันใหม่ทุกค่า (สคริปต์หยุดถ้าไม่ตรง)

สคริปต์: `scripts/shap_evidence_pack.py`

ไฟล์ผล: `results/crossdataset/importance_comparison/shap_evidence/`

สรุป

ทิศ 2017 -> 2018 (ทิศที่ใช้ตัดสิน) มี 17 กรณีที่จำนวนแถวพอ ไม่ผ่านเลยสักกรณี และไม่มีกรณีไหนได้ $p < 0.05$ ที่ใกล้สุดคือ catboost DoS $p = 0.063$ และ xgboost DoS $p = 0.065$ ซึ่งต้องต่ำกว่า 0.010 (CatBoost, 5 class) หรือ 0.017 (XGBoost, 3 class) ถึงจะผ่าน RF ได้ G ติดลบ 4 จาก 5 class (Brute Force ได้ +0.004 ซึ่งใกล้ศูนย์)

ทิศ 2018 -> 2017 มี 2 กรณีที่ $p < 0.05$ คือ lightgbm Bot ($G = +0.320$, $p = 0.024$), lightgbm Web Attack ($G = +0.331$, $p = 0.030$) แต่ไม่ผ่าน Bonferroni ($0.05 / 4 = 0.0125$) และ random_forest, catboost ในทิศนี้ได้ G ติดลบทุก class

กลุ่ม feature สุ่ม 13 ตัวก็ได้ G กว้างพอสมควร (95th percentile อยู่ราว 0.11 ถึง 0.35) แปลว่าแถวที่ทายพลาดกับแถวที่ทายถูกต่างกันหลาย feature ไม่ได้ต่างแค่ที่กลุ่ม F

ผมจึงสรุปว่าการทายพลาดตอนข้าม dataset ไม่น่าเกิดจากกลุ่ม fingerprint กลุ่มเดียว น่าจะมาจากหลาย feature ที่ความสัมพันธ์กับ class เปลี่ยนไปเมื่อย้าย dataset ผลนี้เข้ากับคำอธิบายนี้ แต่ยังไม่ได้ทดสอบตรงๆ

ข้อสรุปเหมือนฉบับ 60% ที่เปลี่ยนคือจำนวนกรณีที่นับได้ (จาก 13 เป็น 17 ในทิศตัดสิน) เพราะ SSH-Patator ของ 2017 เข้ามาอยู่ใน train ทำให้โมเดลทาย Brute Force ใน 2018 ถูกบางส่วนและมีแถว caught ให้เทียบได้

1. รายชื่อ feature ในกลุ่ม dataset-specific (F)

F มี 13 ตัว เลือกจาก 60 feature (77 column รวม column ที่ซ้ำกันแล้วเหลือ 60) โดยใช้โมเดล adversarial คือ LightGBM ที่เทรนให้ทายว่าแถวมาจาก 2017 หรือ 2018 แล้ววัดความสำคัญของ feature 2 วิธี การเลือก F ไม่ได้ใช้ split 60/10/30 หรือ 70/30 ของโปรโตคอล (ใช้การแบ่งสุ่ม 70/30 ภายในของงาน adversarial) F จึงเป็นชุดเดิมทุกตัว

- permutation importance: นับว่าผ่านถ้าค่าเฉลี่ยเป็นบวกและมากกว่า 2 เท่าของ SD ระหว่าง seed ได้ 18 ตัว
- SHAP: นับว่าผ่านถ้า share ไม่ต่ำกว่า 1/60 ทั้งค่าเฉลี่ยและใน 4 จาก 5 seed ได้ 26 ตัว

F คือ feature ที่ผ่านทั้งสองวิธี ได้ 13 ตัว ใช้ชุดนี้ตัดสินตั้งแต่รอบ 2

feature	permutation (adversarial)	AUC ตัวเดียว	SHAP share สูงสุด
min_seg_size_forward	0.04821	0.685	0.731
RST Flag Count	0.04133	0.693	0.698
Init_Win_bytes_forward	0.00580	0.716	0.194

feature	permutation (adversarial)	AUC ตัวเดียว	SHAP share สูงสุด
Destination Port	0.00077	0.594	0.068
Max Packet Length	0.00026	0.805	0.063
act_data_pkt_fwd	0.00020	0.766	0.471
Fwd IAT Min	0.00014	0.706	0.046
Init_Win_bytes_backward	0.00010	0.766	0.300
Flow IAT Min	0.00010	0.694	0.042
Bwd IAT Min	0.00006	0.675	0.028
Min Packet Length	0.00006	0.605	0.059
Bwd Packet Length Min	0.00004	0.580	0.051
Bwd Packet Length Std	0.00000	0.763	0.052

AUC ตัวเดียว คือ AUC ตอนใช้ feature นั้นตัวเดียวแยก 2017 กับ 2018 ส่วน SHAP share สูงสุด คือ share ที่สูงสุดในบรรดา class ทั้งหมด ค่า permutation ของหลายตัวเล็กมาก เพราะ feature ที่คล้ายกันแบ่งข้อมูลกันไป (เจอแล้วในรอบ 1) แต่ยังผ่านเกณฑ์ 2 SD ได้เพราะค่าแต่ละ seed ใกล้กัน

ไฟล์: `feature_group.csv` (มีครบ 60 ตัว ดูคอลัมน์ `in_F`)

2. ค่า SHAP ของแต่ละโมเดลและแต่ละรอบ (seed)

ทุกโมเดลตั้งค่าเหมือนกัน ใช้ split แบบ chronological 70/30 และ seed 42-46

- missed คือ attack ใน test ของ dataset ปลายทางที่โมเดลทายเป็น Benign
- caught คือ attack ใน test ของ dataset ต้นทางที่โมเดลทายถูก
- ใช้ไม่เกิน 1,000 แถวต่อ class ต่อกลุ่มต่อ seed
- ดูเฉพาะ SHAP ของ output Benign ที่เป็นบวก
- s คือสัดส่วนของ SHAP บวกที่มาจาก F เฉลี่ยทุกแถว
- gap = s(missed) - s(caught) ของแต่ละ seed และ G คือค่าเฉลี่ย gap ของ 5 seed
- นับเฉพาะ class ที่มี missed อย่างน้อย 100 แถว และ caught อย่างน้อย 30 แถว ทุก seed

ถ้า F เป็นตัวที่ทำให้ทายเป็น Benign จริง gap ควรเป็นบวกทุก seed

ทิศ 2017 -> 2018 (ใช้ตัดสิน)

model	class	seed 42	43	44	45	46	G	s(missed)	s(caught)
lightgbm	DDoS	-0.040	-0.047	-0.004	+0.025	+0.007	-0.012	0.475	0.487
lightgbm	DoS	+0.035	-0.001	+0.019	+0.069	-0.012	+0.022	0.369	0.347
lightgbm	Brute Force	-0.111	-0.112	-0.133	-0.088	-0.038	-0.097	0.208	0.304
lightgbm	Web Attack	+0.004	+0.067	+0.034	+0.034	+0.014	+0.031	0.476	0.445

model	class	seed 42	43	44	45	46	G	s(missed)	s(caught)
random_forest	DDoS	-0.235	-0.227	-0.163	-0.184	-0.159	-0.194	0.247	0.441
random_forest	DoS	-0.162	-0.138	-0.199	-0.244	-0.155	-0.180	0.182	0.362
random_forest	Brute Force	-0.247	+0.036	+0.113	+0.043	+0.076	+0.004	0.093	0.088
random_forest	Bot	-0.350	-0.148	-0.342	-0.393	-0.337	-0.314	0.215	0.529
random_forest	Web Attack	-0.299	-0.173	-0.219	-0.298	-0.177	-0.233	0.305	0.538
xgboost	DDoS	-0.076	-0.120	-0.070	-0.098	-0.024	-0.078	0.540	0.618
xgboost	DoS	+0.122	+0.152	+0.103	+0.092	+0.157	+0.125	0.546	0.421
xgboost	Web Attack	-0.040	-0.065	-0.159	-0.100	-0.133	-0.100	0.495	0.595
catboost	DDoS	+0.070	-0.038	+0.076	+0.173	+0.095	+0.075	0.586	0.510
catboost	DoS	+0.202	+0.122	+0.223	+0.167	+0.227	+0.188	0.478	0.290
catboost	Brute Force	-0.212	-0.123	-0.227	-0.298	-0.290	-0.230	0.233	0.464
catboost	Bot	-0.080	+0.017	-0.075	-0.086	-0.100	-0.065	0.374	0.439
catboost	Web Attack	-0.004	-0.186	-0.115	-0.113	-0.184	-0.120	0.564	0.685

s(missed) และ s(caught) ในตารางเป็นค่าเฉลี่ย 5 seed

Infiltration นับไม่ได้ในทุกโมเดล (caught ไม่ถึง 30 แถว) Bot นับได้เฉพาะ RF กับ CatBoost และ Brute Force นับได้ใน LightGBM, RF, CatBoost ส่วน XGBoost ยังไม่ถึงเกณฑ์ ที่ Brute Force นับได้เพราะการแบ่ง 70/30 ทำให้ SSH-Patator ของ 2017 มี 474 แถวอยู่ใน train (ที่ train 60% มี 0 แถว) โมเดลจึงทาย Brute Force ใน 2018 ถูกบางส่วน ค่าทุก class อยู่ในไฟล์

DoS: gap เป็นบวกทุก seed ใน xgboost, catboost และเป็นลบทุก seed ใน random_forest ส่วน class อื่นแต่ละโมเดลได้เครื่องหมายไม่เหมือนกัน

ทิศ 2018 -> 2017 (รายงานอย่างเดียว)

model	class	seed 42	43	44	45	46	G	s(missed)	s(caught)
lightgbm	DDoS	+0.025	+0.079	+0.095	+0.121	+0.036	+0.071	0.294	0.223
lightgbm	DoS	-0.042	-0.054	-0.053	-0.067	-0.022	-0.048	0.317	0.364
lightgbm	Bot	+0.409	+0.315	+0.400	+0.238	+0.240	+0.320	0.447	0.126

model	class	seed 42	43	44	45	46	G	s(missed)	s(caught)
lightgbm	Web Attack	+0.343	+0.411	+0.352	+0.242	+0.306	+0.331	0.625	0.295
random_forest	DDoS	-0.165	-0.106	-0.120	-0.100	-0.141	-0.126	0.405	0.532
random_forest	DoS	-0.083	-0.048	-0.074	+0.014	-0.096	-0.057	0.464	0.522
random_forest	Brute Force	+0.044	-0.223	-0.150	-0.141	-0.159	-0.126	0.108	0.234
random_forest	Bot	-0.039	-0.227	-0.142	-0.475	-0.194	-0.215	0.454	0.669
random_forest	Web Attack	-0.334	-0.276	-0.337	-0.315	-0.274	-0.307	0.265	0.572
xgboost	DDoS	+0.139	+0.165	+0.162	+0.179	+0.150	+0.159	0.404	0.245
xgboost	DoS	+0.044	-0.029	+0.100	+0.038	-0.080	+0.015	0.411	0.397
xgboost	Bot	+0.091	+0.171	+0.099	-0.002	+0.242	+0.120	0.511	0.391
xgboost	Web Attack	+0.189	+0.194	+0.244	+0.084	+0.087	+0.160	0.424	0.264
catboost	DDoS	-0.042	-0.135	-0.113	-0.116	-0.115	-0.104	0.409	0.513
catboost	DoS	-0.021	-0.027	-0.028	-0.027	-0.065	-0.034	0.312	0.345
catboost	Brute Force	-0.099	+0.051	-0.131	-0.131	-0.098	-0.082	0.222	0.304
catboost	Bot	-0.131	-0.175	-0.310	+0.142	-0.309	-0.157	0.406	0.563
catboost	Web Attack	-0.134	-0.074	-0.030	-0.051	-0.030	-0.064	0.404	0.468

ทิศนี้ random_forest, catboost ได้ gap ติดลบเกือบทุกช่อง ส่วน LightGBM กับ XGBoost มี G เป็นบวกใน class ส่วนใหญ่

ไฟล์: `per_seed_stats.csv` (ทุกโมเดล ทุก class ทุก seed ทั้งสองทิศ มีจำนวนแถว missed ทั้งหมด จำนวนแถวที่ใช้คำนวณ และค่าเฉลี่ยของ SHAP บวกไป Benign ด้วย)

3. วิธีสร้างกลุ่ม feature สุ่ม 2,000 ชุด

สุ่มจาก 60 feature ชุดเดียวกับที่ใช้เลือก F ชุดละ 13 ตัวเท่ากับ F ในชุดเดียวกันไม่ซ้ำกัน (`rng.choice(60, size=13, replace=False)`) ใช้ `numpy.random.default_rng(2026)` สุ่มไปจนครบ 2,000 ชุด ทุกโมเดลเริ่มจาก seed เดียวกัน จึงได้ 2,000 ชุดเดียวกัน (และเป็นชุดเดียวกับฉบับ 60% เพราะ seed เหมือนกัน)

แต่ละชุดคำนวณ G แบบเดียวกับ F ทุกขั้น คือคิดทั้ง 5 seed แล้วเฉลี่ย ได้เป็น G_null 2,000 ค่า แล้วคิด p ด้านเดียวจาก

p = (1 + จำนวน G_null ที่ >= G) / (1 + 2000)

ตอนสุ่มไม่ได้เอา F ออก ชุดสุ่มจึงมี feature ของ F ปนอยู่ได้ เฉลี่ย 2.83 ตัวต่อชุด (0 ถึง 7 ตัว) ผมเช็กด้วยว่าแต่ละ feature ถูกสุ่มได้ใกล้เคียงกัน ควรได้ประมาณ 433 ครั้ง ได้จริง 390 ถึง 478 ครั้ง

ไฟล์: `random_sets.csv` (รายชื่อ feature ของทั้ง 2,000 ชุด และจำนวนที่ซ้ำกับ F), `random_set_feature_counts.csv` (แต่ละ feature ถูกสุ่มกี่ครั้ง)

4. ตำแหน่งของผลจริงเทียบกับ 2,000 กลุ่มสุ่ม

percentile คือร้อยละของกลุ่มสุ่มที่ได้ G ต่ำกว่า F ถ้า F มีผลจริง ค่านี้ควรสูงประมาณ 98 ถึง 99 ขึ้นไป (ขึ้นกับจำนวน class ที่ใช้หาร Bonferroni)

เกณฑ์ที่เขียนไว้ก่อนรัน: ผ่านถ้า G > 0 และ p < 0.05 / จำนวน class ที่นับ ถ้า p >= 0.05 ถือว่าไม่สนับสนุน

ทิศ 2017 -> 2018 (ใช้ตัดสิน)

model	class	G	null mean	null p95	percentile	p	ผล
lightgbm	DDoS	-0.012	-0.001	0.169	43.9	0.561	ไม่สนับสนุน
lightgbm	DoS	+0.022	+0.003	0.211	54.3	0.457	ไม่สนับสนุน
lightgbm	Brute Force	-0.097	-0.002	0.181	16.8	0.832	ไม่สนับสนุน
lightgbm	Web Attack	+0.031	-0.004	0.228	48.4	0.516	ไม่สนับสนุน
random_forest	DDoS	-0.194	-0.001	0.206	6.3	0.937	ไม่สนับสนุน
random_forest	DoS	-0.180	+0.002	0.195	9.2	0.907	ไม่สนับสนุน
random_forest	Brute Force	+0.004	+0.007	0.302	41.2	0.588	ไม่สนับสนุน
random_forest	Bot	-0.314	-0.001	0.240	4.4	0.956	ไม่สนับสนุน
random_forest	Web Attack	-0.233	-0.007	0.252	20.9	0.791	ไม่สนับสนุน
xgboost	DDoS	-0.078	+0.001	0.191	19.0	0.810	ไม่สนับสนุน
xgboost	DoS	+0.125	+0.003	0.139	93.6	0.065	ไม่สนับสนุน
xgboost	Web Attack	-0.100	-0.001	0.234	26.8	0.732	ไม่สนับสนุน
catboost	DDoS	+0.075	+0.003	0.154	78.2	0.218	ไม่สนับสนุน
catboost	DoS	+0.188	+0.003	0.199	93.8	0.063	ไม่สนับสนุน
catboost	Brute Force	-0.230	-0.004	0.158	4.3	0.957	ไม่สนับสนุน
catboost	Bot	-0.065	-0.002	0.111	23.3	0.767	ไม่สนับสนุน
catboost	Web Attack	-0.120	-0.005	0.212	23.0	0.770	ไม่สนับสนุน

ไม่มีกรณีไหนเกิน null p95 (percentile สูงสุด 93.8) และ RF อยู่ต่ำกว่า percentile 41 ทุก class

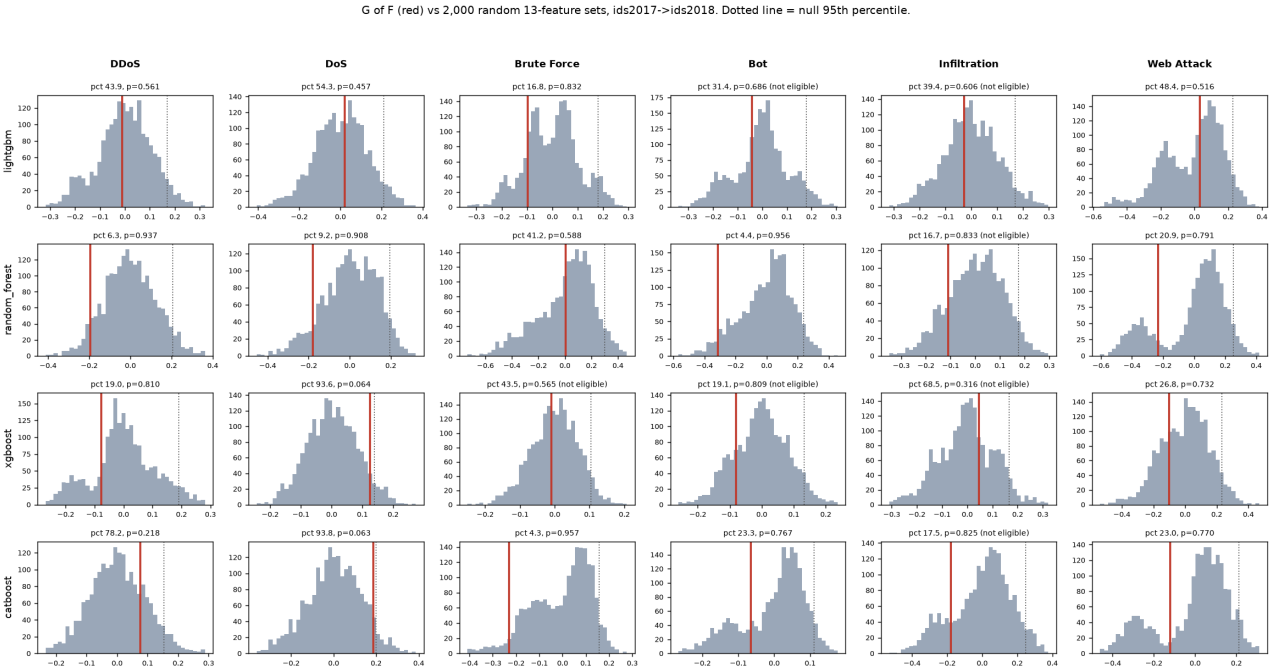
ทิศ 2018 -> 2017 (รายงานอย่างเดียว)

model	class	G	null mean	null p95	percentile	p
lightgbm	DDoS	+0.071	+0.003	0.224	73.7	0.264
lightgbm	DoS	-0.048	+0.003	0.221	33.4	0.666
lightgbm	Bot	+0.320	+0.002	0.274	97.7	0.024
lightgbm	Web Attack	+0.331	-0.003	0.298	97.0	0.030
random_forest	DDoS	-0.126	-0.001	0.164	15.5	0.845
random_forest	DoS	-0.057	-0.001	0.249	35.9	0.641
random_forest	Brute Force	-0.126	+0.007	0.290	25.6	0.744
random_forest	Bot	-0.215	-0.000	0.350	21.8	0.782
random_forest	Web Attack	-0.307	-0.001	0.180	6.6	0.934
xgboost	DDoS	+0.159	+0.004	0.166	94.0	0.061
xgboost	DoS	+0.015	+0.005	0.164	55.2	0.448
xgboost	Bot	+0.120	+0.000	0.253	80.0	0.201
xgboost	Web Attack	+0.160	-0.003	0.168	94.2	0.059
catboost	DDoS	-0.104	-0.002	0.140	14.8	0.852
catboost	DoS	-0.034	+0.001	0.172	36.5	0.635
catboost	Brute Force	-0.082	+0.005	0.164	25.2	0.748
catboost	Bot	-0.157	+0.000	0.246	18.9	0.811
catboost	Web Attack	-0.064	-0.002	0.128	21.4	0.786

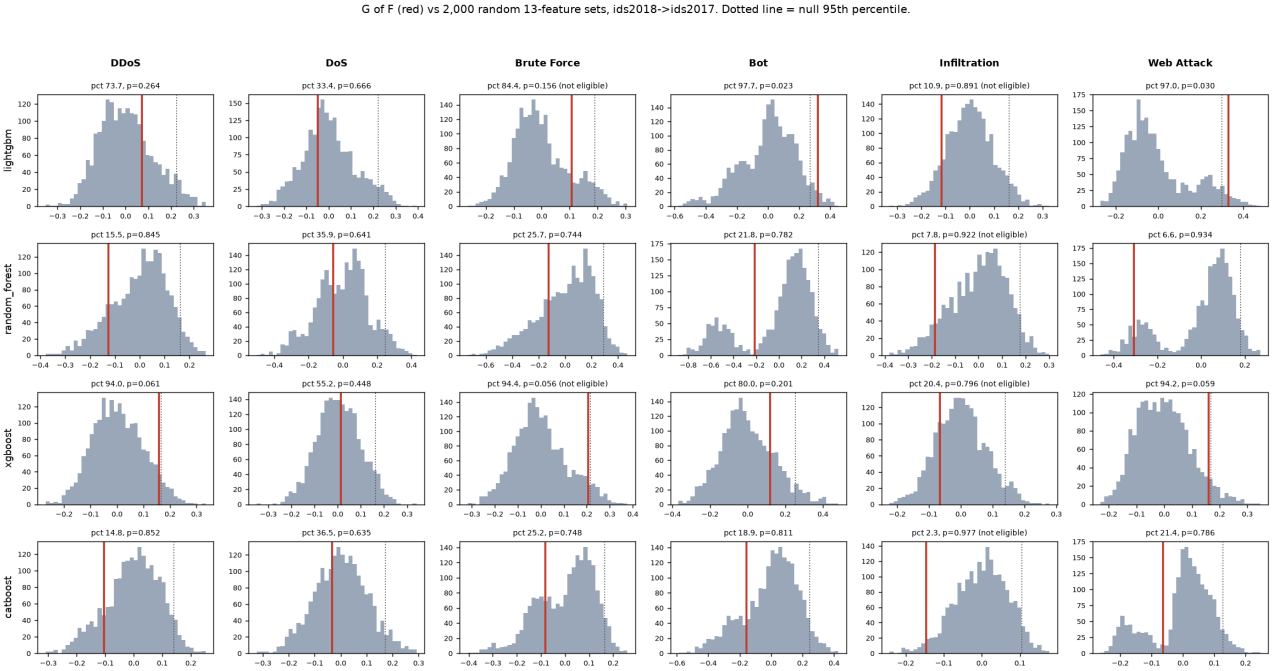
มี 2 กรณีที่ $p < 0.05$ คือ lightgbm Bot ($G = +0.320$, $p = 0.024$), lightgbm Web Attack ($G = +0.331$, $p = 0.030$) แต่ยังสูงกว่าเกณฑ์ Bonferroni ($0.05 / 4 = 0.0125$) ส่วน RF กับ CatBoost อยู่ต่ำกว่าค่ากลางของ null เกือบทั้งหมด ทิศนี้ไม่ได้ใช้ตัดสินตั้งแต่แรก

รูป

แต่ละช่องคือโมเดล 1 ตัวกับ class 1 class แท่งสีเทาคือ histogram ของ G จากกลุ่มสุ่ม 2,000 ชุด เส้นแดงคือ G ของ F เส้นประคือ 95th percentile ของกลุ่มสุ่ม หัวช่องเขียน percentile กับ p ช่องที่เขียนว่า no caught rows คือไม่มีแถว caught ให้คำนวณ



รูป 1 ทิศ 2017 -> 2018



รูป 2 ทิศ 2018 -> 2017

ไฟล์: `null_position.csv` (ตารางด้านบน มี SD, z และ percentile 5/25/50/75/99 เพิ่ม), `null_distribution.csv` (G_null ครบ 2,000 ค่าของทุกโมเดล ทุก class ทั้งสองทิศ)

สรุปและข้อจำกัด

ทั้ง 4 โมเดลไม่มีหลักฐานว่า F ทำให้ attack ถูกทายเป็น Benign ตอนข้าม dataset ค่า G ของ F อยู่ในช่วงเดียวกับกลุ่มสุ่ม และแต่ละโมเดลได้เครื่องหมายไม่ตรงกัน กลุ่มสุ่มเองก็ได้ G กว้าง แสดงว่า SHAP ที่ดันไปทาง Benign ในแถวที่ทายพลาดกระจายอยู่หลาย feature

ข้อจำกัดคืองานนี้ทดสอบแค่ F กลุ่มเดียว จึงตัดคำอธิบายว่าเกิดจาก fingerprint กลุ่มเดียวออกได้ แต่ยังไม่ได้ทดสอบโดยตรงว่าความสัมพันธ์ระหว่าง feature กับ decision boundary เปลี่ยนไป และใช้แค่ tree model ไม่มี MLP กับ LR

ผลรอบ 1-3 เก็บไว้ตามที่ได้ ไม่ได้แก้ F หรือเกณฑ์

เทียบกับฉบับ train 60%

รายการ	train 60%	train 70% (ฉบับนี้)
กรณีที่นับได้ ทิศ 2017 -> 2018	13	17
กรณีที่ผ่านเกณฑ์	0	0
p ต่ำสุดในทิศตัดสิน	0.064 (CatBoost DoS)	0.063 (catboost DoS)
กรณี p < 0.05 ทิศ 2018 -> 2017	3 (ไม่ผ่าน Bonferroni)	2 (ไม่ผ่าน Bonferroni)
Brute Force ทิศ 2017 -> 2018	ไม่มีแถว caught นับไม่ได้	นับได้ใน LightGBM, RF, CatBoost ไม่สนับสนุนทั้งหมด

ข้อสรุปไม่เปลี่ยน ส่วนที่เปลี่ยนเกิดจากการที่ SSH-Patator เข้ามาอยู่ใน train ของ 2017 ไม่ได้เกิดจากโมเดลหรือเกณฑ์

ไฟล์ที่เกี่ยวข้อง

- เกณฑ์ที่เขียนก่อนรัน: `results/crossdataset/importance_comparison/SHAP_ROUND2_PREREGISTRATION.md`, `SHAP_ROUND3_PREREGISTRATION.md`
- ผลที่ใช้: `shap_round2/null_test.csv`, `shap_round3/null_test.csv`
- รายงานเต็มรอบ 1-3: `docs/experiments/crossdataset/round5_shap/report/shap_progress.md`