

ผล SHAP รอบ 2-3 (ข้อมูลที่อาจารย์ขอ)

วันที่ 1 ตุลาคม 2569

เอกสารนี้อาจารย์ขอ 2 (LightGBM) กับรอบ 3 (RF, XGBoost, CatBoost) ที่เซฟไว้ มาจัดเป็น 4 ส่วนตามที่อาจารย์ขอ ผมไม่ได้เทรนใหม่ ใช้ค่า SHAP รายแถวที่เก็บไว้ตอนรันจริง แล้วสุ่มกลุ่ม feature 2,000 ชุดใหม่ด้วย seed เดิม ได้ค่า G และ p ตรงกับผลเดิมทุกค่า

สคริปต์: scripts/shap_evidence_pack.py

ไฟล์ผล: results/crossdataset/importance_comparison/shap_evidence/

สรุป

ทิศ 2017 -> 2018 (ทิศที่ใช้ตัดสิน) มี 13 กรณีที่จำนวนแถวพอ ไม่ผ่านเลยสักกรณี ตัวที่ใกล้สุดคือ CatBoost DoS ได้ $p = 0.064$ แต่ต้องต่ำกว่า 0.017 ถึงจะผ่าน ส่วน RF ได้ G ติดลบทุก class

ทิศ 2018 -> 2017 มี 3 กรณีที่ $p < 0.05$ แต่ไม่ผ่าน Bonferroni และ RF กับ CatBoost ในทิศนี้ได้ G ติดลบทุก class

กลุ่ม feature สุ่ม 13 ตัวที่ได้ G กว้างพอสมควร (95th percentile อยู่ราว 0.14 ถึง 0.25) แปลว่าแถวที่ทายพลาดกับแถวที่ทายถูกต่างกันหลาย feature ไม่ได้ต่างแค่ที่กลุ่ม F

ผมจึงสรุปว่าการทายพลาดตอนข้าม dataset ไม่น่าเกิดจากกลุ่ม fingerprint กลุ่มเดียว น่าจะมาจากหลาย feature ที่ความสัมพันธ์กับ class เปลี่ยนไปเมื่อย้าย dataset ผลนี้เข้ากับคำอธิบายนี้ แต่ยังไม่ได้ทดสอบตรงๆ

1. รายชื่อ feature ในกลุ่ม dataset-specific (F)

F มี 13 ตัว เลือกจาก 60 feature (77 column รวม column ที่ซ้ำกันแล้วเหลือ 60) โดยใช้โมเดล adversarial คือ LightGBM ที่เทรนให้ทายว่าแถวมาจาก 2017 หรือ 2018 แล้ววัดความสำคัญของ feature 2 วิธี

- permutation importance: นับว่าผ่านถ้าค่าเฉลี่ยเป็นบวกและมากกว่า 2 เท่าของ SD ระหว่าง seed ได้ 18 ตัว
- SHAP: นับว่าผ่านถ้า share ไม่ต่ำกว่า 1/60 ทั้งค่าเฉลี่ยและใน 4 จาก 5 seed ได้ 26 ตัว

F คือ feature ที่ผ่านทั้งสองวิธี ได้ 13 ตัว ใช้ชุดนี้ตัดสินตั้งแต่รอบ 2

feature	permutation (adversarial)	AUC ตัวเดียว	SHAP share สูงสุด
min_seg_size_forward	0.04821	0.685	0.731
RST Flag Count	0.04133	0.693	0.698
Init_Win_bytes_forward	0.00580	0.716	0.194
Destination Port	0.00077	0.594	0.068
Max Packet Length	0.00026	0.805	0.063
act_data_pkt_fwd	0.00020	0.766	0.471
Fwd IAT Min	0.00014	0.706	0.046
Init_Win_bytes_backward	0.00010	0.766	0.300
Flow IAT Min	0.00010	0.694	0.042

feature	permutation (adversarial)	AUC ตัวเดียว	SHAP share สูงสุด
Bwd IAT Min	0.00006	0.675	0.028
Min Packet Length	0.00006	0.605	0.059
Bwd Packet Length Min	0.00004	0.580	0.051
Bwd Packet Length Std	0.0000011	0.763	0.052

AUC ตัวเดียว คือ AUC ตอนใช้ feature นั้นตัวเดียวแยก 2017 กับ 2018 ส่วน SHAP share สูงสุด คือ share ที่สูงสุดในบรรดา class ทั้งหมด ค่า permutation ของหลายตัวเล็กมาก เพราะ feature ที่คล้ายกันแบ่งข้อมูลกันไป (เจอแล้วในรอบ 1) แต่ยังไม่ผ่านเกณฑ์ 2 SD ได้เพราะค่าแต่ละ seed ใกล้เคียงกัน

ไฟล์: feature_group.csv (มี CSV 60 ตัว ดูคอลัมน์ in_F)

2. ค่า SHAP ของแต่ละโมเดลและแต่ละรอบ (seed)

ทุกโมเดลตั้งค่าเหมือนกัน ใช้ split แบบ chronological และ seed 42-46

- missed คือ attack ใน test ของ dataset ปลายทางที่โมเดลทายเป็น Benign
- caught คือ attack ใน test ของ dataset ต้นทางที่โมเดลทายถูก
- ใช้ไม่เกิน 1,000 แถวต่อ class ต่อกลุ่มต่อ seed
- ดูเฉพาะ SHAP ของ output Benign ที่เป็นบวก
- s คือสัดส่วนของ SHAP บวกที่มาจาก F เฉลี่ยทุกแถว
- $gap = s(\text{missed}) - s(\text{caught})$ ของแต่ละ seed และ G คือค่าเฉลี่ย gap ของ 5 seed
- นับเฉพาะ class ที่มี missed อย่างน้อย 100 แถว และ caught อย่างน้อย 30 แถว ทุก seed

ถ้า F เป็นตัวที่ทำให้ทายเป็น Benign จริง gap ควรเป็นบวกทุก seed

ปี 2017 -> 2018 (ใช้ตัดสิน)

model	class	seed 42	43	44	45	46	G	s(missed)	s(caught)
lightgbm	DDoS	-0.018	-0.048	-0.047	-0.025	+0.032	-0.021	0.445	0.466
lightgbm	DoS	+0.097	+0.005	+0.050	+0.091	+0.088	+0.066	0.383	0.317
lightgbm	Web Attack	-0.232	+0.090	+0.067	+0.030	-0.017	-0.012	0.451	0.463
random_forest	DDoS	-0.212	-0.155	-0.146	-0.233	-0.191	-0.188	0.241	0.429
random_forest	DoS	-0.127	-0.088	-0.142	-0.070	-0.106	-0.107	0.184	0.291
random_forest	Bot	-0.424	-0.274	-0.271	-0.402	-0.353	-0.345	0.186	0.531
random_forest	Web Attack	-0.254	-0.136	-0.280	-0.265	-0.243	-0.236	0.302	0.538
xgboost	DDoS	-0.066	-0.060	-0.067	-0.089	-0.086	-0.074	0.508	0.582
xgboost	DoS	+0.120	+0.148	+0.038	+0.079	+0.099	+0.097	0.461	0.364

model	class	seed 42	43	44	45	46	G	s(missed)	s(caught)
xgboost	Web Attack	-0.082	-0.039	+0.038	-0.047	+0.071	-0.012	0.495	0.507
catboost	DDoS	+0.054	+0.012	+0.140	+0.078	+0.153	+0.087	0.553	0.466
catboost	DoS	+0.199	+0.103	+0.203	+0.146	+0.237	+0.177	0.446	0.269
catboost	Web Attack	-0.267	-0.055	-0.164	-0.180	+0.097	-0.114	0.543	0.657

s(missed) และ s(caught) ในตารางเป็นค่าเฉลี่ย 5 seed

ทศนี้ Brute Force ไม่มีแถว caught เลย เพราะพอแบ่งตามเวลา Brute Force ของ 2017 ไปอยู่ใน train เกือบหมด ส่วน Bot กับ Infiltration บางโมเดลมี missed ไม่ถึง 100 แถว จึงไม่ได้ใส่ในตาราง แต่มีค่าอยู่ในไฟล์

DoS เป็น class เดียวที่ gap เป็นบวกทุก seed ใน LightGBM, XGBoost และ CatBoost แต่ใน RF ติดลบทุก seed ส่วน DDoS กับ Web Attack แต่ละโมเดลได้เครื่องหมายไม่เหมือนกัน

ทศ 2018 -> 2017 (รายงานอย่างเดียว)

model	class	seed 42	43	44	45	46	G	s(missed)	s(caught)
lightgbm	DDoS	+0.248	+0.138	+0.205	+0.225	+0.132	+0.190	0.384	0.194
lightgbm	DoS	+0.162	-0.033	+0.092	+0.077	-0.122	+0.035	0.384	0.349
lightgbm	Web Attack	+0.210	+0.370	+0.262	+0.250	+0.200	+0.258	0.507	0.249
random_forest	DDoS	-0.118	-0.154	-0.121	-0.130	-0.111	-0.127	0.399	0.526
random_forest	DoS	-0.071	-0.059	-0.027	-0.020	-0.035	-0.042	0.458	0.500
random_forest	Brute Force	-0.169	-0.219	-0.074	-0.082	-0.129	-0.134	0.122	0.256
random_forest	Bot	+0.067	-0.022	-0.103	-0.435	-0.298	-0.158	0.439	0.597
random_forest	Web Attack	-0.384	-0.245	-0.244	-0.296	-0.225	-0.279	0.256	0.534
xgboost	DDoS	+0.158	+0.143	+0.024	+0.094	+0.095	+0.103	0.327	0.224
xgboost	DoS	+0.078	-0.022	-0.045	+0.022	+0.162	+0.039	0.420	0.381
xgboost	Bot	+0.207	+0.109	+0.140	+0.353	+0.315	+0.225	0.547	0.322
xgboost	Web Attack	+0.224	+0.136	+0.103	+0.170	+0.213	+0.169	0.452	0.283
catboost	DDoS	-0.047	-0.078	-0.219	-0.118	-0.179	-0.128	0.378	0.507

model	class	seed 42	43	44	45	46	G	s(missed)	s(caught)
catboost	DoS	-0.043	+0.010	-0.060	-0.052	-0.072	-0.044	0.300	0.344
catboost	Brute Force	-0.183	+0.011	-0.077	-0.205	+0.004	-0.090	0.215	0.305
catboost	Bot	-0.187	-0.312	-0.245	-0.216	-0.056	-0.203	0.351	0.554
catboost	Web Attack	-0.100	-0.154	-0.050	-0.104	-0.099	-0.101	0.393	0.495

ทึศนี้ LightGBM กับ XGBoost ได้ gap เป็นบวกเป็นส่วนใหญ่ แต่ RF กับ CatBoost ติดลบเกือบทุกช่อง

ไฟล์: per_seed_stats.csv (ทุกโมเดล ทุก class ทุก seed ทั้งสองทึศ มีจำนวนแถว missed ทั้งหมดจำนวนแถวที่ใช้คำนวณ และค่าเฉลี่ยของ SHAP บวกไป Benign ด้วย)

3. วิธีสร้างกลุ่ม feature สุ่ม 2,000 ชุด

สุ่มจาก 60 feature ชุดเดียวกับที่ใช้เลือก F ชุดละ 13 ตัวเท่ากับ F ในชุดเดียวกันไม่ซ้ำกัน (rng.choice(60, size=13, replace=False)) ใช้ numpy.random.default_rng(2026) สุ่มไปจนครบ 2,000 ชุด ทุกโมเดลเริ่มจาก seed เดียวกัน จึงได้ 2,000 ชุดเดียวกัน

แต่ละชุดคำนวณ G แบบเดียวกับ F ทุกชั้น คือคิดทั้ง 5 seed แล้วเฉลี่ย ได้เป็น G_null 2,000 ค่า แล้วคิด p ด้านเดียวจาก

$$p = (1 + \text{จำนวน } G_null \text{ ที่ } \geq G) / (1 + 2000)$$

ตอนสุ่มไม่ได้เอา F ออก ชุดสุ่มจึงมี feature ของ F ปนอยู่ได้ เฉลี่ย 2.83 ตัวต่อชุด (0 ถึง 7 ตัว) ผมเช็กด้วยว่าแต่ละ feature ถูกสุ่มได้ใกล้เคียงกัน ควรได้ประมาณ 433 ครั้ง ได้จริง 390 ถึง 478 ครั้ง

ไฟล์: random_sets.csv (รายชื่อ feature ของทั้ง 2,000 ชุด และจำนวนที่ซ้ำกับ F), random_set_feature_counts.csv (แต่ละ feature ถูกสุ่มกี่ครั้ง)

4. ตำแหน่งของผลจริงเทียบกับ 2,000 กลุ่มสุ่ม

percentile คือร้อยละของกลุ่มสุ่มที่ได้ G ต่ำกว่า F ถ้า F มีผลจริง ค่านี้ควรสูงประมาณ 98 ถึง 99 ขึ้นไป (ขึ้นกับจำนวน class ที่ใช้หา Bonferroni)

เกณฑ์ที่เขียนไว้ก่อนรัน: ผ่านถ้า $G > 0$ และ $p < 0.05$ / จำนวน class ที่นับ ถ้า $p \geq 0.05$ ถือว่าไม่สนับสนุน

ทึศ 2017 -> 2018 (ใช้ตัดสิน)

model	class	G	null mean	null p95	percentile	p	ผล
lightgbm	DDoS	-0.021	-0.002	0.179	42.5	0.575	ไม่สนับสนุน
lightgbm	DoS	+0.066	+0.002	0.209	68.0	0.320	ไม่สนับสนุน
lightgbm	Web Attack	-0.012	-0.005	0.243	41.5	0.586	ไม่สนับสนุน
random_forest	DDoS	-0.188	-0.001	0.203	5.8	0.942	ไม่สนับสนุน
random_forest	DoS	-0.107	+0.002	0.183	19.4	0.806	ไม่สนับสนุน

model	class	G	null mean	null p95	percentile	p	ผล
random_forest	Bot	-0.345	-0.002	0.246	3.0	0.970	ไม่สนับสนุน
random_forest	Web Attack	-0.236	-0.008	0.249	21.1	0.789	ไม่สนับสนุน
xgboost	DDoS	-0.074	+0.001	0.140	17.9	0.821	ไม่สนับสนุน
xgboost	DoS	+0.097	+0.002	0.161	83.3	0.167	ไม่สนับสนุน
xgboost	Web Attack	-0.012	-0.003	0.195	46.2	0.538	ไม่สนับสนุน
catboost	DDoS	+0.087	+0.002	0.153	83.0	0.170	ไม่สนับสนุน
catboost	DoS	+0.177	+0.003	0.197	93.7	0.064	ไม่สนับสนุน
catboost	Web Attack	-0.114	-0.007	0.219	23.9	0.762	ไม่สนับสนุน

ไม่มีกรณีไหนเกิน null p95 และ RF อยู่ต่ำกว่า percentile 22 ทุก class

กศ 2018 -> 2017 (รายงานอย่างเดียวย)


model	class	G	null mean	null p95	percentile	p
lightgbm	DDoS	+0.190	+0.004	0.184	95.5	0.045
lightgbm	DoS	+0.035	+0.005	0.196	63.0	0.370
lightgbm	Web Attack	+0.258	-0.003	0.253	95.2	0.049
random_forest	DDoS	-0.127	-0.000	0.158	15.2	0.848
random_forest	DoS	-0.042	-0.000	0.232	38.2	0.618
random_forest	Brute Force	-0.134	+0.006	0.287	24.8	0.753
random_forest	Bot	-0.158	+0.001	0.347	23.4	0.766
random_forest	Web Attack	-0.279	+0.000	0.180	8.1	0.919
xgboost	DDoS	+0.103	+0.002	0.151	86.0	0.140
xgboost	DoS	+0.039	+0.003	0.130	68.8	0.312
xgboost	Bot	+0.225	+0.000	0.249	93.0	0.070
xgboost	Web Attack	+0.169	-0.001	0.159	95.7	0.044
catboost	DDoS	-0.128	-0.001	0.137	11.8	0.882
catboost	DoS	-0.044	+0.003	0.191	33.4	0.666
catboost	Brute Force	-0.090	+0.005	0.178	22.6	0.774
catboost	Bot	-0.203	-0.001	0.229	11.7	0.884
catboost	Web Attack	-0.101	-0.001	0.145	18.8	0.813

มี 3 กรณีที่ $p < 0.05$ คือ LightGBM DDoS, LightGBM Web Attack และ XGBoost Web Attack แต่ยิ่งสูงกว่าเกณฑ์ Bonferroni ($0.05/3 = 0.017$ และ $0.05/4 = 0.0125$) ส่วน RF กับ CatBoost ใน class เดียวกันอยู่ต่ำกว่าค่ากลางของ null ทั้งหมด ทักษะไม่ได้ใช้ตัดสินตั้งแต่แรก

สรุป


แต่ละช่องคือโมเดล 1 ตัวกับ class 1 class แท่งสีเทาคือ histogram ของ G จากกลุ่มสุ่ม 2,000 ชุด เส้นแดงคือ G ของ F เส้นประคือ 95th percentile ของกลุ่มสุ่ม หัวช่องเขียน percentile กับ p ช่องที่เขียนว่า no caught rows คือไม่มีแถว caught ให้คำนวณ

G of F (red) vs 2,000 random 13-feature sets, ids2017->ids2018. Dotted line = null 95th percentile.



สรุป 1 ทศ 2017 -> 2018

G of F (red) vs 2,000 random 13-feature sets, ids2018->ids2017. Dotted line = null 95th percentile.



สรุป 2 ทศ 2018 -> 2017

ไฟล์: null_position.csv (ตารางด้านบน มี SD, z และ percentile 5/25/50/75/99 เพิ่ม),
null_distribution.csv (G_null คำนวณ 2,000 ค่าของทุกโมเดล ทุก class ทั้งสองทิศ)

สรุปและข้อจำกัด

ทั้ง 4 โมเดลไม่มีหลักฐานว่า F ทำให้ attack ถูกทำนายเป็น Benign ตอนข้าม dataset ค่า G ของ F อยู่ในช่วงเดียวกับกลุ่มสุ่ม และแต่ละโมเดลได้เครื่องหมายไม่ตรงกัน กลุ่มสุ่มเองก็ไม่ได้ G กว้าง แสดงว่า SHAP ที่ดันไปทาง Benign ในแถวที่ทายพลาดกระจายอยู่หลาย feature

ข้อจำกัดคืองานนี้ทดสอบแค่ F กลุ่มเดียว จึงตัดคำอธิบายว่าเกิดจาก fingerprint กลุ่มเดียวออกได้ แต่ยังไม่ได้ทดสอบโดยตรงว่าความสัมพันธ์ระหว่าง feature กับ decision boundary เปลี่ยนไป และใช้แค่ tree model ไม่มี MLP กับ LR

ผลรอบ 1-3 เก็บไว้ตามที่ได้ ไม่ได้แก้ F หรือเกณฑ์

ไฟล์ที่เกี่ยวข้อง

- เกณฑ์ที่เขียนก่อนรัน:
results/crossdataset/importance_comparison/SHAP_ROUND2_PREREGISTRATION.md,
SHAP_ROUND3_PREREGISTRATION.md
- ผลเดิม: shap_round2/null_test.csv, shap_round3/null_test.csv
- รายงานเต็มรอบ 1-3: docs/experiments/crossdataset/round5_shap/report/shap_progress.md