SHAP บน protocol แบบแบ่ง 70/30: ผลที่เพิ่มและสิ่งที่เปลี่ยน

เอกสารนี้มีเฉพาะผลของ SHAP ที่รันใหม่บน split train 70% / test 30% และส่วนที่ต่างจากผลเดิมที่ train 60% วิธีทำ เกณฑ์ที่ตั้งไว้ก่อนรัน และเหตุผลการออกแบบเหมือนเดิมทุกอย่าง (ดู `shap_progress.md`) สคริปต์ ชุด feature F (13 ตัว) จำนวน seed (5) และจำนวนการสุ่ม null (2,000 ชุด) ไม่เปลี่ยน
สิ่งเดียวที่เปลี่ยนคือสัดส่วนการแบ่งข้อมูล

ผลทุกส่วนใช้ split ของโปรโตคอล cross-dataset ยกเว้น Part A ของรอบ 1 ที่ใช้การแบ่งสุ่ม 70/30 ภายในของตัวเอง จึงเหมือนเดิม

1. สรุป

ขั้น	train 60% (เดิม)	train 70% (ใหม่)
รอบ 1 Part A kappa (LightGBM / LR)	0.366 / 0.334	0.366 / 0.334 (เท่าเดิม)
รอบ 1 Part B ตาราง SHAP	partial (3 คลาส)	partial (4 คลาส)
รอบ 1 Part B ตาราง permutation	ไม่สนับสนุน (3 คลาส)	partial (4 คลาส)
รอบ 2 กลุ่มหลัก (consensus)	ไม่สนับสนุน (3 คลาส)	ไม่สนับสนุน (4 คลาส)
รอบ 3 กลุ่มหลัก (3 โมเดล)	ไม่สนับสนุน ทั้ง 3	ไม่สนับสนุน ทั้ง 3
รอบ 3 กลุ่ม SHAP (26) รายคลาส	ไม่มีคลาสที่ผ่าน	ผ่าน 2 คลาส (xgboost DoS (G = +0.228, p = 0.0045) และ catboost DDoS (G = +0.246, p = 0.0090))
within-target (กรณีที่นับได้)	ไม่ผ่านทั้ง 9 กรณี	ไม่ผ่านทั้ง 11 กรณี
เฉพาะ evidence ทิศ 2017 -> 2018 (กรณีที่นับได้)	13 กรณี ผ่าน 0	17 กรณี ผ่าน 0

ข้อสรุปหลักไม่เปลี่ยน คือไม่มีหลักฐานว่ากลุ่ม feature ที่บอก dataset (F) เป็นสาเหตุให้การโจมตีถูกทายเป็น Benign หลังย้าย dataset สิ่งที่เปลี่ยนมี 2 อย่าง อย่างแรกคือจำนวนคลาสที่ตัดสินได้เพิ่มขึ้น (Brute Force เข้ามา) เพราะที่ train 70% SSH-Patator ของ 2017 มี 474 แถวใน train (ที่ 60% มี 0 แถว) โมเดลที่เทรนจาก 2017 จึงทาย Brute Force ใน 2018 ถูกบางส่วนและมีแถว caught ให้เทียบ อย่างที่สองคือรอบ 3 กลุ่ม SHAP 26 ตัวมี 2 คลาสที่ผ่านเกณฑ์รายคลาสซึ่งฉบับ 60% ไม่มี (ดูหัวข้อ 4)

2. รอบ 1 Part B: การโจมตีที่ถูกทายพลาด (ทิศ 2017 -> 2018)

ค่าคือ s(missed) - s(caught) เฉลี่ย 5 seeds ในวงเล็บคือคำตัดสินรายคลาสตามเกณฑ์ของรอบ 1

คลาส	SHAP เดิม (60%)	SHAP ใหม่ (70%)	permutation เดิม	permutation ใหม่
DDoS	+0.139 (สนับสนุน)	+0.144 (สนับสนุน)	-0.076 (ไม่สนับสนุน)	-0.050 (ไม่สนับสนุน)
DoS	+0.135 (กลาง ๆ)	+0.080 (กลาง ๆ)	+0.054 (กลาง ๆ)	+0.037 (กลาง ๆ)
Brute Force	ไม่มีแถว caught	-0.188 (ไม่สนับสนุน)	ไม่มีแถว caught	-0.094 (ไม่สนับสนุน)
Web Attack	-0.054 (ไม่สนับสนุน)	-0.063 (ไม่สนับสนุน)	-0.098 (ไม่สนับสนุน)	+0.023 (กลาง ๆ)
Bot	+0.050 (นับไม่ได้)	+0.017 (นับไม่ได้)	-0.065 (นับไม่ได้)	-0.057 (นับไม่ได้)
Infiltration	+0.224 (นับไม่ได้)	+0.156 (นับไม่ได้)	+0.000 (นับไม่ได้)	-0.057 (นับไม่ได้)

คำตัดสินรวม: ตาราง SHAP partial (สนับสนุน 1, ไม่สนับสนุน 2 จาก 4 คลาส) และตาราง permutation partial (สนับสนุน 0, ไม่สนับสนุน 2 จาก 4 คลาส)

ตาราง permutation เปลี่ยนจากไม่สนับสนุนเป็น partial เพราะ 2 เหตุรวมกัน Brute Force เข้ามาเป็นคลาสที่ตัดสินได้ (ไม่สนับสนุน) และ Web Attack ในตาราง permutation ขยับจากไม่สนับสนุนเป็นกลาง ๆ ตาราง SHAP ยังเป็น partial ส่วน DDoS ในตาราง SHAP ยังได้ส่วนต่างเกิน 0.10 ทุก seed เหมือนเดิม

3. รอบ 2 (LightGBM): เทียบกับกลุ่มสุ่ม

ทิศ 2017 -> 2018 p ต่ำกว่า 0.0125 จึงจะผ่าน (0.05 / 4 คลาส)

กลุ่ม F	คลาส	G ใหม่	p ใหม่	G เดิม	p เดิม
consensus (13)	DDoS	-0.012	0.56	-0.021	0.57
consensus (13)	DoS	+0.022	0.46	+0.066	0.32
consensus (13)	Brute Force	-0.097	0.83	นับไม่ได้	-
consensus (13)	Web Attack	+0.031	0.52	-0.012	0.59
SHAP (26)	DDoS	+0.144	0.13	+0.139	0.14
SHAP (26)	DoS	+0.080	0.29	+0.135	0.19
SHAP (26)	Brute Force	-0.189	0.94	นับไม่ได้	-
SHAP (26)	Web Attack	-0.063	0.61	-0.054	0.60
perm (18)	DDoS	-0.050	0.65	-0.076	0.71
perm (18)	DoS	+0.037	0.39	+0.054	0.34
perm (18)	Brute Force	-0.093	0.81	นับไม่ได้	-
perm (18)	Web Attack	+0.023	0.49	-0.098	0.71

คำตัดสิน: ไม่สนับสนุน ทั้งสามกลุ่ม feature ส่วนต่าง DDoS ในตาราง SHAP ที่ดูชัดในรอบ 1 อยู่ในช่วงที่กลุ่มสุ่มก็ได้ (p = 0.13) Brute Force ได้ G ติดลบในทุกกลุ่ม feature

4. รอบ 3 (RF, XGBoost, CatBoost)

4.1 กลุ่มหลัก (consensus) ทิศ 2017 -> 2018

G (p) ใหม่

โมเดล	DDoS	DoS	Brute Force	Bot	Web Attack
lightgbm	-0.012 (0.56)	+0.022 (0.46)	-0.097 (0.83)	นับไม่ได้	+0.031 (0.52)
random_forest	-0.194 (0.94)	-0.180 (0.91)	+0.004 (0.59)	-0.314 (0.96)	-0.233 (0.79)
xgboost	-0.078 (0.81)	+0.125 (0.06)	นับไม่ได้	นับไม่ได้	-0.100 (0.73)
catboost	+0.075 (0.22)	+0.188 (0.06)	-0.230 (0.96)	-0.065 (0.77)	-0.120 (0.77)

G (p) เดิม

โมเดล	DDoS	DoS	Brute Force	Bot	Web Attack
lightgbm	-0.021 (0.57)	+0.066 (0.32)	นับไม่ได้	นับไม่ได้	-0.012 (0.59)

โมเดล	DDoS	DoS	Brute Force	Bot	Web Attack
random_forest	-0.188 (0.94)	-0.107 (0.81)	นับไม่ได้	-0.345 (0.97)	-0.236 (0.79)
xgboost	-0.074 (0.82)	+0.097 (0.17)	นับไม่ได้	นับไม่ได้	-0.012 (0.54)
catboost	+0.087 (0.17)	+0.177 (0.06)	นับไม่ได้	นับไม่ได้	-0.114 (0.76)

คลาสที่ตัดสินได้เพิ่มจากเดิม: lightgbm Brute Force, random_forest Brute Force, catboost Brute Force, catboost Bot คำตัดสินรอบ 3 ยังเป็น ไม่สนับสนุน (3 จาก 3 โมเดล เกณฑ์ต้องการ 2 จาก 3) ค่า p ที่ใกล้เกณฑ์ที่สุดคือ DoS ของ XGBoost (0.065 เดิม 0.167) และ DoS ของ CatBoost (0.063) ซึ่งยังสูงกว่า 0.05

4.2 ทุกกลุ่ม feature

โมเดล	consensus (13)	SHAP (26)	perm (18)
xgboost	ไม่สนับสนุน	ไม่สนับสนุน (รายคลาสผ่าน: DoS)	ไม่สนับสนุน
catboost	ไม่สนับสนุน	ไม่สนับสนุน (รายคลาสผ่าน: DDoS)	ไม่สนับสนุน
random_forest	ไม่สนับสนุน	ไม่สนับสนุน	ไม่สนับสนุน

รายคลาสที่ผ่านเกณฑ์ Bonferroni มี 2 กรณี คือ xgboost DoS (G = +0.228, p = 0.0045) และ catboost DDoS (G = +0.246, p = 0.0090) ทั้งสองอยู่ในกลุ่ม SHAP 26 ตัว ไม่ใช่กลุ่มหลัก และไม่ทำให้ภาพรวมของโมเดลนั้นเปลี่ยน (XGBoost ผ่าน 1 จาก 3 คลาส CatBoost ผ่าน 1 จาก 5 คลาส ต้องเกินครึ่ง) ทิศ 2017 -> 2018 มีการทดสอบที่ตัดสินได้ทั้งหมด 51 ค่า ได้ p < 0.05 จำนวน 2 ค่า ใกล้เคียงกับที่ความบังเอิญให้ได้ราว 2.6 ค่า แม้การทดสอบเหล่านี้ไม่อิสระต่อกัน

4.3 Part A ของรอบ 3 (รายงานอย่างเดียว)

kappa เทียบกับ LightGBM: XGBoost 0.876 (เดิม 0.874) CatBoost 0.770 (เท่าเดิม) RF 0.626 (เท่าเดิม) จำนวน feature ที่ใช้แยกการโจมตีของ XGBoost เปลี่ยนจาก 15 เป็น 19 ตัว ส่วน CatBoost และ RF เท่าเดิม Part A ไม่ได้ใช้ split ที่แท้ ความต่างของ XGBoost จึงไม่ได้มาจาก split ยังไม่ทราบสาเหตุแน่ชัด (น่าจะเป็นความไม่คงที่ของการเทรน แต่ไม่ได้ทดสอบ) และไม่กระทบคำตัดสินเพราะรายงานอย่างเดียว

5. within-target: เทียบแถวที่ทายพลาดกับที่ทายถูกใน dataset ปลายทางเดียวกัน

กลุ่ม consensus เฉพาะกรณีที่นับได้ (11 กรณี เดิม 9 กรณี) G_within = s(missed) - s(caught_tgt) ใช้ตัดสิน G_old คือ G ของรอบ 2-3 และ G_dataset = G_old - G_within คือส่วนที่มาจากการต่าง dataset

โมเดล	ทิศ	คลาส	G_within	G_old	G_dataset	null 95%	p
lightgbm	2017 -> 2018	DoS	-0.202	+0.022	+0.225	0.161	0.963
lightgbm	2017 -> 2018	Brute Force	+0.010	-0.097	-0.107	0.043	0.249
lightgbm	2018 -> 2017	DoS	-0.060	-0.048	+0.013	0.157	0.777
lightgbm	2018 -> 2017	Bot	-0.034	+0.320	+0.355	0.079	0.745

โมเดล	ทิศ	คลาส	G_within	G_old	G_dataset	null 95%	p
xgboost	2017 -> 2018	DoS	-0.070	+0.125	+0.196	0.101	0.831
xgboost	2018 -> 2017	DDoS	-0.135	+0.159	+0.293	0.125	0.955
xgboost	2018 -> 2017	DoS	-0.040	+0.015	+0.054	0.042	0.896
catboost	2017 -> 2018	DoS	-0.256	+0.188	+0.444	0.116	0.997
catboost	2018 -> 2017	DoS	+0.065	-0.034	-0.099	0.112	0.174
random_forest	2017 -> 2018	DoS	-0.484	-0.180	+0.305	0.217	1.000
random_forest	2018 -> 2017	DoS	-0.259	-0.057	+0.202	0.153	0.902

- ไม่ผ่านทั้ง 11 กรณี G_within ติดลบ 9 จาก 11 กรณี p ต่ำสุด 0.174
- DoS ทิศ 2017 -> 2018 ทั้ง 4 โมเดลได้ G_within ติดลบ ทั้งที่ G_old เป็นบวกใน lightgbm, xgboost, catboost แปลว่า gap บวกเดิมมาจากการต่าง dataset ไม่ได้มาจากการทายผิด
- ชุด SHAP 26 ตัว: ไม่มีกรณีไหน p < 0.05 (p ต่ำสุด 0.21) กรณี XGBoost DoS 2017 -> 2018 ที่ผ่านรายคลาสในรอบ 3 ได้ G_within = +0.073 (p = 0.21) ซึ่งไม่ผ่าน ส่วน CatBoost DDoS ตรวจในขั้นนี้ไม่ได้เพราะโมเดลทาย DDoS ใน 2018 ถูก 0 แถว
- กรณีที่ไม่ผ่านเกณฑ์จำนวนแถวแต่ได้ p < 0.05 (ไม่นับ): xgboost Brute Force 2018 -> 2017 (G_within = +0.191, p = 0.003, missed น้อยสุด 32 แถว)

6. evidence pack: ตำแหน่งของ F เทียบกับกลุ่มสุ่ม (ทิศ 2017 -> 2018)

ผลทุกกรณีที่นับได้ คำตัดสินทุกกรณีคือไม่สนับสนุน (เดิม 13 กรณี ใหม่ 17 กรณี) p ต่ำสุด 0.063 (catboost DoS) percentile สูงสุด 93.8

โมเดล	คลาส	G	null p95	percentile	p
lightgbm	DDoS	-0.012	0.169	43.9	0.561
lightgbm	DoS	+0.022	0.211	54.3	0.457
lightgbm	Brute Force	-0.097	0.181	16.8	0.832
lightgbm	Web Attack	+0.031	0.228	48.4	0.516
random_forest	DDoS	-0.194	0.206	6.3	0.937
random_forest	DoS	-0.180	0.195	9.2	0.907
random_forest	Brute Force	+0.004	0.302	41.2	0.588
random_forest	Bot	-0.314	0.240	4.4	0.956
random_forest	Web Attack	-0.233	0.252	20.9	0.791
xgboost	DDoS	-0.078	0.191	19.0	0.810
xgboost	DoS	+0.125	0.139	93.6	0.065

โมเดล	คลาส	G	null p95	percentile	p
xgboost	Web Attack	-0.100	0.234	26.8	0.732
catboost	DDoS	+0.075	0.154	78.2	0.218
catboost	DoS	+0.188	0.199	93.8	0.063
catboost	Brute Force	-0.230	0.158	4.3	0.957
catboost	Bot	-0.065	0.111	23.3	0.767
catboost	Web Attack	-0.120	0.212	23.0	0.770

ทิศ 2018 -> 2017 (รายงานอย่างเดียว): 18 กรณีที่นับได้ มี 2 กรณีที่ $p < 0.05$ คือ lightgbm Bot ($G = +0.320$, $p = 0.024$), lightgbm Web Attack ($G = +0.331$, $p = 0.030$) ไม่ผ่านเกณฑ์ Bonferroni ทั้งหมด

7. ข้อจำกัดและสิ่งที่ยังไม่ทราบ

- ตัดสินได้เฉพาะ F กลุ่มเดียวและเฉพาะโมเดลต้นไม้ ยังไม่ได้ทดสอบว่าความสัมพันธ์ระหว่าง feature กับ decision boundary เปลี่ยนไปโดยตรง
- Part A ของ XGBoost ขยับโดยไม่ทราบสาเหตุ (หัวข้อ 4.3)
- กรณีรายคลาสที่ผ่านในรอบ 3 (XGBoost DoS, CatBoost DDoS) ยังไม่มีคำอธิบายกลไก XGBoost DoS ตรวจใน within-target แล้วไม่ผ่าน CatBoost DDoS ตรวจไม่ได้
- ผลรอบ 3 และ within-target ถูกรวมจากการรันขนานแยกโมเดลด้วยโหมด `--cached` ของสคริปต์เดิม (คำนวณตารางทั้งหมดใหม่จากค่า SHAP ที่บันทึกไว้) ล็อกของแต่ละเลนอยู่ในโฟลเดอร์ผลเป็น `run_<model>.log`

8. ไฟล์ที่เกี่ยวข้อง

- ผล: `results/crossdataset/importance_comparison/` โฟลเดอร์ `shap/`, `shap_round2/`, `shap_round3/`, `shap_within_target/`, `shap_evidence/`
- รายงานฉบับเต็ม: `shap_progress.md`, `shap_evidence_for_advisor.md`, `shap_within_target.md`