SHAP เทียบใน dataset ปลายทางเดียวกัน แบบแบ่ง 70/30

เอกสารนี้เทียบ SHAP ใน dataset ปลายทางเดียวกันและ attack class เดียวกัน ระหว่างแถวที่โมเดลทายผิดเป็น Benign กับแถวที่โมเดลทายถูก เพื่อดูว่าความต่างที่เห็นในรอบก่อนมาจากการทายผิดจริง หรือแค่เพราะข้อมูลมาจากคนละ dataset

ฉบับก่อนใช้ผลที่ train 60% ฉบับนี้รันใหม่ทั้งหมดบน split 70/30 ด้วยสคริปต์และเกณฑ์เดิม ตัวเลขทุกตัวอ่านจากไฟล์ผลโดยตรง

สคริปต์: `scripts/shap_within_target.py`

กติกาเขียนไว้ก่อนรัน: `results/crossdataset/importance_comparison/SHAP_WITHIN_TARGET_PREREGISTRATION.md`

ไฟล์ผล: `results/crossdataset/importance_comparison/shap_within_target/`

สรุป

ไม่ผ่านทุกโมเดล (LightGBM, XGBoost, CatBoost, RF) และทุกชุด feature

class ที่จำนวนแถวพอให้ตัดสินมี 11 กรณี เป็น DoS 8 กรณี (ทุกโมเดลทั้งสองทิศ) ส่วนที่เหลือคือ lightgbm 2017 -> 2018 Brute Force, lightgbm 2018 -> 2017 Bot, xgboost 2018 -> 2017 DDoS ฉบับ 60% มี 9 กรณี ที่เพิ่มขึ้นเพราะ SSH-Patator เข้ามาอยู่ใน train ของ 2017 ทำให้โมเดลทาย Brute Force ใน 2018 ถูกบางส่วน ทิศ 2017 -> 2018 ที่เหลือโมเดลแทบทาย attack ใน 2018 ไม่ถูก ยกเว้น DoS กับ Brute Force

กรณี DoS ทิศ 2017 -> 2018 ตอบคำถามนี้ได้ชัดที่สุด ในรอบ 2-3 gap เป็นบวกใน lightgbm, xgboost, catboost (G_old) แต่พอเทียบกับแถวที่ทายถูกใน 2018 ด้วยกัน G_within ติดลบทั้ง 4 โมเดล และ gap ของแต่ละ seed ติดลบ 20 จาก 20 ค่า แปลว่า gap บวกที่เคยเห็นมาจากการที่ข้อมูลมาจากคนละ dataset ไม่ได้มาจากการทายผิด

G_within ติดลบ 9 จาก 11 กรณี ที่เป็นบวกมี 2 กรณีคือ lightgbm 2017 -> 2018 Brute Force (+0.010, p = 0.249), catboost 2018 -> 2017 DoS (+0.065, p = 0.174) ซึ่ง p สูงกว่า 0.17 ทั้งคู่ p ต่ำสุดของทั้ง 11 กรณีคือ 0.174 (catboost 2018 -> 2017 DoS)

ผลนี้เข้ากับข้อสรุปเดิม คือการทายพลาดตอนข้าม dataset ไม่ได้เกิดจากกลุ่ม fingerprint F กลุ่มเดียว

1. วิธีทำ

ใช้โมเดล split และแถวเดียวกับรอบ 2 (LightGBM) และรอบ 3 (RF, XGBoost, CatBoost) ทุกอย่าง แบ่งแถวเป็น 3 กลุ่ม ในแต่ละ class

- missed: แถว attack ใน test ของ dataset ปลายทางที่โมเดลทายเป็น Benign (เอามาจาก cache รอบ 2-3)
- caught_tgt: แถว attack ใน test ของ dataset ปลายทางที่โมเดลทายถูก (กลุ่มใหม่ รอบนี้คำนวณเพิ่มกลุ่มเดียว)
- caught_src: แถว attack ใน test ของ dataset ต้นทางที่โมเดลทายถูก (กลุ่ม caught เดิมของรอบ 2-3)

แถวที่โมเดลทายเป็น attack class อื่นไม่ได้ใช้

ตอนคำนวณ caught_tgt ต้องเทรนโมเดลใหม่ด้วย seed เดิม สคริปต์เช็กว่าจำนวน missed ต่อ class ตรงกับ cache ทุก seed ถ้าไม่ตรงจะหยุด ผลคือตรงทุก seed และค่า G ที่คำนวณใหม่จากกลุ่ม missed กับ caught_src ตรงกับค่า G ของรอบ 2-3 ทั้ง 144 ค่า (ต่างกันมากสุด 0.0000)

ตั้งค่าเหมือนรอบ 2

- 60 feature, split แบบ chronological 70/30, seed 42-46
- ใช้ไม่เกิน 1,000 แถวต่อ class ต่อกลุ่มต่อ seed
- ดูเฉพาะ SHAP ของ output Benign ที่เป็นบวก
- s(กลุ่ม) คือสัดส่วนของ SHAP บวกที่มาจาก F เฉลี่ยทุกแถวในกลุ่ม
- F หลักคือชุด consensus 13 ตัว (ชุดเดียวกับเอกสารผล SHAP รอบ 2-3) และรายงานชุด SHAP 26 ตัวกับ permutation 18 ตัวด้วย

ค่าที่ใช้

- G_within = s(missed) - s(caught_tgt) เฉลี่ย 5 seed ใช้ค่านี้ตัดสิน
- G_old = s(missed) - s(caught_src) คือ G ของรอบ 2-3
- G_dataset = s(caught_tgt) - s(caught_src) ใช้อธิบายอย่างเดียว

G_old = G_within + G_dataset เสมอ เลยแยกได้ว่า gap เดิมมาจากการทายผิดเท่าไหร่ และมาจากการต่าง dataset เท่าไหร่

null คือสุ่มกลุ่ม feature ขนาดเท่ากัน 2,000 ชุด seed 2026 เหมือนรอบ 3

เกณฑ์

- นับเฉพาะกรณีที่มี missed อย่างน้อย 100 แถว และ caught_tgt อย่างน้อย 30 แถว ทุก seed
- ผ่าน: G_within > 0 และ p < 0.05 / (จำนวนกรณีที่นับได้ของโมเดลนั้น)
- ไม่ผ่าน: p >= 0.05 ถ้าอยู่ระหว่างนั้นถือว่าไม่ชัด
- ตัดสินทั้งสองทิศ เพราะทิศ 2017 -> 2018 ทิศเดียวมีกรณีที่นับได้น้อยเกินไป

2. ผลกรณีที่นับได้ (F consensus 13 ตัว)

model	ทิศ	class	G_within	G_old	G_dataset	null 95%	p	ผล
lightgbm	2017 -> 2018	DoS	-0.202	+0.022	+0.225	0.161	0.963	ไม่ผ่าน
lightgbm	2017 -> 2018	Brute Force	+0.010	-0.097	-0.107	0.043	0.249	ไม่ผ่าน
lightgbm	2018 -> 2017	DoS	-0.060	-0.048	+0.013	0.157	0.777	ไม่ผ่าน
lightgbm	2018 -> 2017	Bot	-0.034	+0.320	+0.355	0.079	0.745	ไม่ผ่าน
xgboost	2017 -> 2018	DoS	-0.070	+0.125	+0.196	0.101	0.831	ไม่ผ่าน
xgboost	2018 -> 2017	DDoS	-0.135	+0.159	+0.293	0.125	0.955	ไม่ผ่าน
xgboost	2018 -> 2017	DoS	-0.040	+0.015	+0.054	0.042	0.896	ไม่ผ่าน
catboost	2017 -> 2018	DoS	-0.256	+0.188	+0.444	0.116	0.997	ไม่ผ่าน
catboost	2018 -> 2017	DoS	+0.065	-0.034	-0.099	0.112	0.174	ไม่ผ่าน

model	ทิศ	class	G_within	G_old	G_dataset	null 95%	p	ผล
random_forest	2017 -> 2018	DoS	-0.484	-0.180	+0.305	0.217	1.000	ไม่ผ่าน
random_forest	2018 -> 2017	DoS	-0.259	-0.057	+0.202	0.153	0.902	ไม่ผ่าน

เกณฑ์ผ่านคือ p < 0.0125 (LightGBM 4 กรณี), 0.0167 (XGBoost 3 กรณี) หรือ 0.025 (CatBoost และ RF 2 กรณี) ไม่มีกรณีไหนเข้าใกล้ ค่า p ต่ำสุดคือ 0.174

G_within ติดลบ 9 จาก 11 กรณี แปลว่าในแถวที่ทายถูก ส่วนแบ่ง SHAP ที่ดันไปทาง Benign มาจาก F มากกว่าในแถวที่ทายพลาดด้วยซ้ำ

ค่า gap ของแต่ละ seed (s(missed) - s(caught_tgt))

model	ทิศ	class	42	43	44	45	46
lightgbm	2017 -> 2018	DoS	-0.213	-0.183	-0.211	-0.199	-0.206
lightgbm	2017 -> 2018	Brute Force	+0.014	+0.000	+0.013	+0.007	+0.017
lightgbm	2018 -> 2017	DoS	-0.068	-0.098	-0.022	-0.057	-0.056
lightgbm	2018 -> 2017	Bot	+0.023	-0.121	-0.035	-0.031	-0.008
xgboost	2017 -> 2018	DoS	-0.054	-0.038	-0.088	-0.114	-0.059
xgboost	2018 -> 2017	DDoS	-0.185	-0.091	-0.120	-0.162	-0.114
xgboost	2018 -> 2017	DoS	-0.050	-0.066	-0.027	-0.043	-0.012
catboost	2017 -> 2018	DoS	-0.293	-0.289	-0.199	-0.349	-0.151
catboost	2018 -> 2017	DoS	+0.070	+0.032	+0.086	+0.034	+0.103
random_forest	2017 -> 2018	DoS	-0.476	-0.455	-0.482	-0.519	-0.489
random_forest	2018 -> 2017	DoS	-0.259	-0.259	-0.236	-0.265	-0.278

DoS ทิศ 2017 -> 2018 ติดลบทุกโมเดลทุก seed (20 จาก 20)

ค่า r เฉลี่ยของแต่ละกลุ่ม

model	ทิศ	class	s(missed)	s(caught_tgt)	s(caught_src)
lightgbm	2017 -> 2018	DoS	0.369	0.571	0.347
lightgbm	2017 -> 2018	Brute Force	0.208	0.197	0.304
lightgbm	2018 -> 2017	DoS	0.317	0.377	0.364

model	ทิศ	class	s(missed)	s(caught_tgt)	s(caught_src)
lightgbm	2018 -> 2017	Bot	0.447	0.481	0.126
xgboost	2017 -> 2018	DoS	0.546	0.616	0.421
xgboost	2018 -> 2017	DDoS	0.404	0.538	0.245
xgboost	2018 -> 2017	DoS	0.411	0.451	0.397
catboost	2017 -> 2018	DoS	0.478	0.734	0.290
catboost	2018 -> 2017	DoS	0.312	0.247	0.345
random_forest	2017 -> 2018	DoS	0.182	0.666	0.362
random_forest	2018 -> 2017	DoS	0.464	0.724	0.522

ดู DoS ทิศ 2017 -> 2018 ใน LightGBM, XGBoost, CatBoost จะเห็นว่า s(caught_tgt) สูงกว่า s(missed) แปลว่าแถว DoS ใน 2018 มี share จาก F สูงอยู่แล้วไม่ว่าจะทายถูกหรือผิด ค่าที่สูงจึงมากับ dataset ไม่ได้มากับการทายผิด

3. ชุด feature อื่น

ผลไม่ผ่านเหมือนกันทั้งชุด SHAP 26 ตัวและชุด permutation 18 ตัว ไม่มีกรณีไหน $p < 0.05$ (p ต่ำสุด 0.21 และ 0.18)

ชุด permutation ได้เครื่องหมายของ G_within ตรงกับชุดหลัก 11 จาก 11 กรณี

ชุด SHAP 26 ตัวได้เครื่องหมายตรงกับชุดหลัก 6 จาก 11 กรณี กรณีที่ G_within เป็นบวกมี 5 กรณี คือ lightgbm 2017 -> 2018 DoS (+0.030, p = 0.41), lightgbm 2018 -> 2017 DoS (+0.069, p = 0.27), lightgbm 2018 -> 2017 Bot (+0.020, p = 0.40), xgboost 2017 -> 2018 DoS (+0.073, p = 0.21), catboost 2018 -> 2017 DoS (+0.004, p = 0.47) แต่ p ไม่ต่ำกว่า 0.2 คือกลุ่มสุ่มขนาดเท่ากันก็ได้ค่าแบบนี้บ่อย

ไฟล์: `null_test.csv` (คอลัมน์ `set`)

4. กรณีที่นับไม่ได้

model	ทิศ	class	missed น้อยสุด	caught_tgt น้อยสุด	เหตุผล
ทุกโมเดล	2017 -> 2018	DDoS	6,081	0	ทายถูก 0 แถว
catboost, random_forest	2017 -> 2018	Brute Force	738	0	ทายถูก 0 แถว
xgboost	2017 -> 2018	Brute Force	82	317-656	missed น้อยเกิน
catboost, random_forest	2017 -> 2018	Bot	1,133	0	ทายถูก 0 แถว
lightgbm, xgboost	2017 -> 2018	Bot	5	0-1,128	ทั้งสองกลุ่มน้อยเกิน
ทุกโมเดล	2017 -> 2018	Infiltration	1,089-1,092	0	ทายถูก 0 แถว
ทุกโมเดล	2017 -> 2018	Web Attack	257	0	ทายถูก 0 แถว
catboost, lightgbm, random_forest	2018 -> 2017	DDoS	3,933-4,598	2-68	caught_tgt น้อยเกิน

model	ทิศ	class	missed น้อยสุด	caught_tgt น้อยสุด	เหตุผล
catboost, random_forest	2018 -> 2017	Brute Force	642-2,739	5-2,090	caught_tgt น้อยเกิน
lightgbm, xgboost	2018 -> 2017	Brute Force	26-32	32-2,719	missed น้อยเกิน
catboost, random_forest, xgboost	2018 -> 2017	Bot	584	0	ทายถูก 0 แถว
ทุกโมเดล	2018 -> 2017	Infiltration	11	0	ทายถูก 0 แถว
catboost, random_forest, xgboost	2018 -> 2017	Web Attack	597-598	1-27	caught_tgt น้อยเกิน
lightgbm	2018 -> 2017	Web Attack	600	0-14	ทายถูก 0 แถวอย่างน้อย 1 seed

ค่าในตารางคือค่าน้อยสุดข้าม 5 seed ของแต่ละโมเดล
ถ้ามีหลายโมเดลในแถวเดียวกันจะแสดงเป็นช่วงจากน้อยสุดถึงมากสุดของโมเดลเหล่านั้น

กรณีที่ไม่ผ่านเกณฑ์จำนวนแถวแต่ได้ $p < 0.05$ (ไม่นับ เพราะจำนวนแถวน้อยเกินจะเชื่อได้)

- xgboost Brute Force 2018 -> 2017: G_within = +0.191, p = 0.003 แต่ missed น้อยสุด 32 แถว และ caught_tgt น้อยสุด 32 แถว

ไฟล์: `counts.csv` (จำนวนแถวทุกกลุ่มทุก seed)

5. ข้อจำกัด

- ตัดสินได้แค่ 11 กรณี และ 8 ใน 11 เป็น DoS ผลนี้จึงพูดได้แน่นอนที่สุดเรื่อง DoS class อื่นมีกรณีเดียวหรือสองกรณีต่อโมเดล
- caught_tgt ของทิศ 2017 -> 2018 เป็นส่วนน้อยของ DoS ใน 2018 (ราว 236-272 แถวต่อ seed เทียบกับ missed กว่า 1,267 แถว) อาจเป็นแถว DoS แบบพิเศษที่คล้าย 2017 มากกว่าปกติ
- ยังเป็นการดู SHAP อย่างเดียว ไม่ได้ทดลองแก้ feature แล้วดูว่าการทายเปลี่ยนไหม

6. สิ่งที่ได้จากรอบนี้

คำถามคือ gap ในรอบก่อนมาจากการทายผิด หรือจากการที่ข้อมูลอยู่คนละ dataset

สำหรับ DoS คำตอบคือมาจากการต่าง dataset เมื่อเทียบใน dataset เดียวกัน แถวที่ทายผิดไม่ได้ใช้ F มากกว่าแถวที่ทายถูก

ข้อนี้เพิ่มน้ำหนักให้ข้อสรุปเดิม ว่าการทายพลาดตอนข้าม dataset ไม่ได้มาจากกลุ่ม fingerprint กลุ่มเดียว

เทียบกับฉบับ train 60%

รายการ	train 60%	train 70% (ฉบับนี้)
กรณีที่นับได้	9	11
กรณีที่ผ่านเกณฑ์	0	0

รายการ	train 60%	train 70% (ฉบับนี้)
G_within ติดลบ	7 จาก 9	9 จาก 11
p ต่ำสุด	0.160 (XGBoost DoS 2018 -> 2017)	0.174 (catboost 2018 -> 2017 DoS)
DoS 2017 -> 2018 ทุกโมเดล	G_within ติดลบทุก seed	G_within ติดลบ 20 จาก 20 seed

ข้อสรุปไม่เปลี่ยน กรณีที่เพิ่มมาเกิดจากการที่ SSH-Patator เข้ามาอยู่ใน train ของ 2017
ไม่ได้เกิดจากโมเดลหรือเกณฑ์