

SHAP เทียบใน dataset ปลายทางเดียวกัน

วันที่ 2 ตุลาคม 2569

อาจารย์ขอให้เทียบ SHAP ใน dataset ปลายทางเดียวกันและ attack class เดียวกัน
ระหว่างแอดที่โมเดลทำนายผิดเป็น Benign กับแอดที่โมเดลทำนายถูก
เพื่อดูว่าความต่างที่เห็นในรอบก่อนมาจากการทำนายผิดจริง หรือแค่เพราะข้อมูลมาจากคนละ dataset

สคริปต์: scripts/shap_within_target.py

กติกาเขียนไว้ก่อนรับ:

results/crossdataset/importance_comparison/SHAP_WITHIN_TARGET_PREREGISTRATION.md

ไฟล์ผล: results/crossdataset/importance_comparison/shap_within_target/

สรุป

ไม่ผ่านทุกโมเดล (LightGBM, XGBoost, CatBoost, RF) และทุกชุด feature

class ที่จำนวนแอดพอให้ตัดสินมีน้อยมาก มีแค่ DoS ทั้งสองทิศ (ทุกโมเดล) กับ Brute Force ทิศ 2018 -> 2017 (CatBoost) รวม 9 กรณี เพราะทิศ 2017 -> 2018 โมเดลแทบทาย attack ใน 2018 ไม่ถูกเลย ยกเว้น DoS

กรณี DoS ทิศ 2017 -> 2018 ตอบคำถามของอาจารย์ได้ชัดที่สุด รอบ 2-3 เคยเห็น gap เป็นบวกใน LightGBM, XGBoost และ CatBoost แต่พอเทียบกับแอดที่ทายถูกใน 2018 ด้วยกัน gap กลายเป็นติดลบทุกโมเดลและทุก seed แปลว่า gap บวกที่เคยเห็นมาจากการที่ข้อมูลมาจากคนละ dataset ไม่ได้มาจากการทำนายผิด

ผลนี้เข้ากับข้อสรุปเดิม คือการทายพลาดตอนข้าม dataset ไม่ได้เกิดจากกลุ่ม fingerprint F กลุ่มเดียว

1. วิธีทำ

ใช้โมเดล split และแอดเดียวกันรอบ 2 (LightGBM) และรอบ 3 (RF, XGBoost, CatBoost) ทุกอย่าง
แบ่งแอดเป็น 3 กลุ่ม ในแต่ละ class

- missed: แอด attack ใน test ของ dataset ปลายทางที่โมเดลทายเป็น Benign (เอามาจาก cache รอบ 2-3)
- caught_tgt: แอด attack ใน test ของ dataset ปลายทางที่โมเดลทายถูก (กลุ่มใหม่ รอบนี้คำนวณเพิ่มกลุ่มเดียว)
- caught_src: แอด attack ใน test ของ dataset ต้นทางที่โมเดลทายถูก (กลุ่ม caught เดิมของรอบ 2-3)

แอดที่โมเดลทายเป็น attack class อื่นไม่ได้ใช้

ตอนคำนวณ caught_tgt ต้องเทรนโมเดลใหม่ด้วย seed เดิม สคริปต์ชี้กว่าจำนวน missed ต่อ class ตรงกับ cache ทุก seed ถ้าไม่ตรงจะหยุด ผลคือตรงทุก seed และค่า G ที่คำนวณใหม่จากกลุ่ม missed กับ caught_src ตรงกับค่า G ของรอบ 2-3 ทั้ง 144 ค่า

ตั้งค่าเหมือนรอบ 2

- 60 feature, split แบบ chronological, seed 42-46
- ใช้ไม่เกิน 1,000 แอดต่อ class ต่อกลุ่มต่อ seed
- ดูเฉพาะ SHAP ของ output Benign ที่เป็นบวก
- s(กลุ่ม) คือสัดส่วนของ SHAP บวกที่มาจาก F เฉลี่ยทุกแอดในกลุ่ม
- F หลักคือชุด consensus 13 ตัว (ชุดเดียวกับเอกสารวันที่ 1 ต.ค.) และรายงานชุด SHAP 26 ตัวกับ permutation 18 ตัวด้วย

ค่าที่ใช้

- $G_within = s(\text{missed}) - s(\text{caught_tgt})$ เฉลี่ย 5 seed ใช้ค่านี้ตัดสิน
- $G_old = s(\text{missed}) - s(\text{caught_src})$ คือ G ของรอบ 2-3
- $G_dataset = s(\text{caught_tgt}) - s(\text{caught_src})$ ใช้อธิบายอย่างเดียวน

$G_old = G_within + G_dataset$ เสมอ เลยแยกได้ว่า gap เดิมมาจากการทายผิดเท่าไร และมาจากการต่าง dataset เท่าไร

null คือกลุ่มกลุ่ม feature ขนาดเท่ากัน 2,000 ชุด seed 2026 เหมือนรอบ 3

เกณฑ์

- นับเฉพาะกรณีที่ missed อย่างน้อย 100 แถว และ caught_tgt อย่างน้อย 30 แถว ทุก seed
- ผ่าน: $G_within > 0$ และ $p < 0.05$ / (จำนวนกรณีที่นับได้ของโมเดลนั้น)
- ไม่ผ่าน: $p \geq 0.05$ ถ้าอยู่ระหว่างนั้นถือว่าไม่ชัด
- ตัดสินทั้งสองทิศ เพราะทิศ 2017 -> 2018 ทิศเดียวมีกรณีที่นับได้น้อยเกินไป

2. ผลกรณีที่นับได้ (F consensus 13 ตัว)

model	ทิศ	class	G_within	G_old	G_dataset	null 95%	p	ผล
lightgbm	2017 -> 2018	DoS	-0.129	+0.066	+0.196	0.146	0.901	ไม่ผ่าน
lightgbm	2018 -> 2017	DoS	-0.043	+0.035	+0.078	0.167	0.704	ไม่ผ่าน
xgboost	2017 -> 2018	DoS	-0.087	+0.097	+0.184	0.136	0.816	ไม่ผ่าน
xgboost	2018 -> 2017	DoS	+0.024	+0.039	+0.015	0.041	0.160	ไม่ผ่าน
catboost	2017 -> 2018	DoS	-0.298	+0.177	+0.476	0.120	1.000	ไม่ผ่าน
catboost	2018 -> 2017	DoS	+0.070	-0.044	-0.114	0.127	0.185	ไม่ผ่าน
catboost	2018 -> 2017	Brute Force	-0.328	-0.090	+0.238	0.194	0.983	ไม่ผ่าน
rf	2017 -> 2018	DoS	-0.468	-0.107	+0.361	0.206	0.999	ไม่ผ่าน
rf	2018 -> 2017	DoS	-0.248	-0.042	+0.205	0.172	0.881	ไม่ผ่าน

เกณฑ์ผ่านคือ $p < 0.025$ (โมเดลที่มี 2 ทิศ) หรือ $p < 0.017$ (CatBoost มี 3 ทิศ) ไม่มีกรณีที่ไหนเข้าใกล้ ค่า p ต่ำสุดคือ 0.160

G_within ติดลบ 7 จาก 9 ทิศ แปลว่าในแถวที่ทายถูก ส่วนแบ่ง SHAP ที่ดันไปทาง Benign มาจาก F มากกว่าในแถวที่ทายพลาดด้วยซ้ำ

ค่า gap ของแต่ละ seed ($s(\text{missed}) - s(\text{caught_tgt})$)

model	ทิศ	class	42	43	44	45	46
lightgbm	2017 -> 2018	DoS	-0.173	-0.128	-0.151	-0.085	-0.110
lightgbm	2018 -> 2017	DoS	+0.039	-0.091	-0.040	-0.007	-0.115
xgboost	2017 -> 2018	DoS	-0.061	-0.055	-0.132	-0.100	-0.088
xgboost	2018 -> 2017	DoS	+0.033	+0.035	+0.019	+0.038	-0.005
catboost	2017 -> 2018	DoS	-0.314	-0.236	-0.234	-0.367	-0.340
catboost	2018 -> 2017	DoS	+0.068	+0.076	+0.088	+0.030	+0.090
catboost	2018 -> 2017	Brute Force	-0.352	-0.127	-0.458	-0.372	-0.330
rf	2017 -> 2018	DoS	-0.483	-0.448	-0.520	-0.412	-0.475
rf	2018 -> 2017	DoS	-0.251	-0.217	-0.202	-0.292	-0.277

DoS ทิศ 2017 -> 2018 ติดลบทุกโมเดลทุก seed (20 จาก 20)

CatBoost DoS ทิศ 2018 -> 2017 เป็นบวกทุก seed แต่ค่าเฉลี่ย (+0.070) และกลุ่ม feature สุ่ม 13 ตัวก็ได้อำระดับนี้บ่อย ($p = 0.185$)

ค่า s เฉลี่ยของแต่ละกลุ่ม

model	ทิศ	class	s(missed)	s(caught_tgt)	s(caught_src)
lightgbm	2017 -> 2018	DoS	0.383	0.513	0.317
lightgbm	2018 -> 2017	DoS	0.384	0.427	0.349
xgboost	2017 -> 2018	DoS	0.461	0.548	0.364
xgboost	2018 -> 2017	DoS	0.421	0.396	0.381
catboost	2017 -> 2018	DoS	0.446	0.744	0.269
catboost	2018 -> 2017	DoS	0.300	0.230	0.344
catboost	2018 -> 2017	Brute Force	0.215	0.543	0.305
rf	2017 -> 2018	DoS	0.184	0.652	0.291
rf	2018 -> 2017	DoS	0.458	0.706	0.500

ดู DoS ทิศ 2017 -> 2018 ใน LightGBM, XGBoost, CatBoost จะเห็นว่า s(missed) สูงกว่า s(caught_src) ตรงนี้คือ gap บวกที่เห็นในรอบ 2-3 แต่ s(caught_tgt) สูงกว่า s(missed) อีก แปลว่าแถว DoS ใน 2018 มี share จาก F สูงอยู่แล้วไม่ว่าจะทายถูกหรือผิด ค่าที่สูงจึงมากับ dataset ไม่ได้มาจากการทายผิด

3. ชุด feature อื่น

ผลไม่ผ่านเหมือนกันทั้งชุด SHAP 26 ตัวและชุด permutation 18 ตัว ไม่มีกรณีไหน $p < 0.05$

ชุด permutation ได้เครื่องหมายของ G_{within} ตรงกับชุดหลักทุกกรณี

ชุด SHAP 26 ตัวต่างออกไปบ้าง LightGBM กับ XGBoost ได้ G_{within} เป็นบวกใน DoS ทั้งสองทิศ (+0.013 ถึง +0.090) แต่ p อยู่ระหว่าง 0.21 ถึง 0.34 คือกลุ่มสุ่มขนาดเท่ากันก็ได้ค่าแบบนี้บ่อย CatBoost DoS ทิศ 2018 -> 2017 ได้ +0.011 ($p = 0.44$) ส่วนกรณีอื่นของ CatBoost กับ RF ยังติดลบ

ไฟล์: null_test.csv (คอลัมน์ set)

4. กรณีที่จับไม่ได้

ทิศ 2017 -> 2018 โมเดลทาย attack ใน 2018 ถูกแทบเป็นศูนย์ ยกเว้น DoS (ราว 240-280 แถวต่อ seed) จึงตอบคำถามนี้ไม่ได้สำหรับ DDoS, Brute Force, Infiltration, Web Attack และ Bot

model	ทิศ	class	missed น้อยสุด	caught_tgt น้อยสุด	เหตุผล
ทุกโมเดล	2017 -> 2018	DDoS	6,081	0	ทายถูก 0 แถว
ทุกโมเดล	2017 -> 2018	Brute Force	738	0	ทายถูก 0 แถว
ทุกโมเดล	2017 -> 2018	Infiltration	1,092-1,093	0	ทายถูก 0 แถว
ทุกโมเดล	2017 -> 2018	Web Attack	257	0	ทายถูก 0 แถว
lightgbm, xgboost, rf	2017 -> 2018	Bot	8-1,133	0	ทายถูก 0 แถวอย่างน้อย 1 seed
catboost	2017 -> 2018	Bot	9	499	missed น้อยเกิน
ทุกโมเดล	2018 -> 2017	DDoS	3,500-4,584	2-18	caught_tgt น้อยเกิน
lightgbm, xgboost	2018 -> 2017	Brute Force	18-21	111-2,280	missed น้อยเกิน
rf	2018 -> 2017	Brute Force	2,728	5	caught_tgt น้อยเกิน
ทุกโมเดล	2018 -> 2017	Bot	75-584	0-451	ไม่พออย่างใดอย่างหนึ่ง
ทุกโมเดล	2018 -> 2017	Web Attack	594-598	1-25	caught_tgt น้อยเกิน
ทุกโมเดล	2018 -> 2017	Infiltration	10	0	ทั้งสองกลุ่มน้อยเกิน

มี 2 กรณีในกลุ่มนี้ที่ $p < 0.05$ แต่จำนวนแถวน้อยเกินจะเชื่อได้ จึงไม่นับ

- xgboost Brute Force 2018 -> 2017: $G_{\text{within}} = +0.126$, $p = 0.036$ แต่ missed มีแค่ 21 แถว และ seed 46 ติดลบ (-0.209)
- catboost Bot 2017 -> 2018: $G_{\text{within}} = +0.084$, $p = 0.024$ แต่ missed มีแค่ 9 แถว

ไฟล์: counts.csv (จำนวนแถวทุกกลุ่มทุก seed)

5. ข้อจำกัด

- ตัดสินได้แค่ 9 กรณี และ 8 ใน 9 เป็น DoS ผลนี้จึงพูดได้แน่นอนแค่เรื่อง DoS class อื่นยังตอบไม่ได้

- caught_tgt ของทศ 2017 -> 2018 เป็นส่วนน้อยของ DoS ใน 2018 (ราว 240-280 แตว เทียบกับ missed กว่า 1,200 แตว) อาจเป็นแตว DoS แบบพิเศษที่คล้าย 2017 มากกว่าปกติ
- ยังเป็นการดู SHAP อย่างเดียว ไม่ได้ทดลองแก้ feature แล้วดูว่าการกายเปลี่ยนไหม

6. สิ่งที่ได้จากรอบนี้

คำถามของอาจารย์คือ gap ในรอบก่อนมาจากการกายผิด หรือจากการที่ข้อมูลอยู่คนละ dataset

สำหรับ DoS คำตอบคือมาจากการต่าง dataset เมื่อเทียบใน dataset เดียวกัน แตวที่กายผิดไม่ได้ใช้ F มากกว่าแตวที่กายถูก

ข้อนี้เพิ่มน้ำหนักให้ข้อสรุปเดิม ว่าการกายพลาดตอนข้าม dataset ไม่ได้มาจากกลุ่ม fingerprint กลุ่มเดียว