ชุดสรุปสำหรับเขียน paper: Cross-Dataset Transfer (protocol_v3, train 70% / test 30%)

ผลหลักทั้งหมดในเอกสารนี้มาจาก protocol_v3 (train 70% / test 30%) ผลของ protocol_v2 (train 60%) ใช้เฉพาะในการเปรียบเทียบความไวต่อสัดส่วนการแบ่ง (ข้อ 3 ตารางที่ 2 และข้อ 4) ไม่มีการทดลองเพิ่ม ไม่เพิ่มโมเดล ไม่ทำ target adaptation และไม่ train รวมสองชุดข้อมูล ตัวเลขทุกตัวเทียบกับไฟล์ข้อมูลแล้ว ตอนนี้จึงไม่มีจุดที่ติดป้าย "ต้องตรวจอีกครั้ง"

แหล่งข้อมูล: `docs/experiments/crossdataset/round6_split_70_30/data/` (ผลการส่งผ่านและผลรายคลาส) และ `round5_reliability_audit/data/` (adversarial validation)

1) Experimental setup

ชุดข้อมูล ใช้ CICIDS2017 (รุ่น MachineLearningCVE) และ CSE-CIC-IDS2018 (ไฟล์รายวัน 10 ไฟล์) หลังทำความสะอาด CICIDS2017 เหลือ 2,497,980 ระเบียน และเหลือ 2,407,275 ระเบียนหลังตัดคลาสที่ไม่มีคู่ใน CSE-CIC-IDS2018 ส่วน CSE-CIC-IDS2018 ลดจาก 16,232,943 เหลือ 11,445,955 ระเบียน โดยใช้กฎการทำความสะอาดชุดเดียวกัน

ขนาดตัวอย่าง สุ่มชุดข้อมูลละ 300,000 ระเบียน (seed 42) โดยเก็บทุกระเบียนของคลาสที่มีน้อยกว่า 10,000 ระเบียน แล้วแบ่งที่เหลือให้คลาสใหญ่ตามสัดส่วนเดิม Benign คิดเป็น 83–88% ทั้งสองฝั่ง ตัวอย่างชุดนี้สุ่มครั้งเดียวและใช้ร่วมกันทุกรอบ หลังแบ่ง 70/30 จะได้ train ประมาณ 210,000 และ test ประมาณ 90,000 ระเบียนต่อชุดข้อมูล

คลาส	CICIDS2017	CSE-CIC-IDS2018
Benign	248,188	263,858
DoS	23,203	5,132
DDoS	15,332	20,272
Brute Force	9,150	2,459
Web Attack	2,143	859
Bot	1,948	3,778
Infiltration	36	3,642

Features และ classes ใช้ 77 features ที่ CICFlowMeter สร้างและมีร่วมกันทั้งสองชุดข้อมูล (ถ้ารวมคอลัมน์ที่มีค่าซ้ำกันจะเหลือ 60 ตัว ซึ่งเป็นจำนวนที่ใช้ในการวิเคราะห์ SHAP) และใช้ 7 classes: Benign, DoS, DDoS, Brute Force, Bot, Web Attack, Infiltration

การ harmonize

- *Feature:* จับคู่ตามความหมายของค่าที่ CICFlowMeter สร้าง ไม่ใช่ตามชื่อคอลัมน์ เพราะ 50 จาก 77 คอลัมน์มีชื่อต่างกันระหว่างสองชุดข้อมูล ตรวจความถูกต้องด้วยความสัมพันธ์เชิงพีชคณิตระหว่างคอลัมน์ สเกลของค่า และชนิดข้อมูล
- *Class:* รวบ label ดิบเป็น 7 คลาสร่วม และตัด PortScan กับ Heartbleed ของ CICIDS2017 ออก เพราะไม่มีคลาสคู่ใน CSE-CIC-IDS2018
- *ลำดับขั้นตอน:* เปลี่ยนชื่อคอลัมน์ ⟶ รวมคลาส ⟶ ทำความสะอาด ⟶ สุ่มตัวอย่าง ใช้ลำดับเดียวกันทั้งสองชุดข้อมูล

Final protocol (protocol_v3) แบ่ง train 70% / test 30% แยก 2 แบบ:

- *Random split:* แบ่งแบบ stratified ตามคลาส และสลับลำดับแถวด้วย seed ของรอบนั้น

- *Capture-order split:* ภายในแต่ละกลุ่ม (capture group, class) เรียงแถวตามกุญแจลำดับ แล้วให้ 70% แรกเป็น train และ 30% ท้ายเป็น test
    - *CICIDS2017:* capture group คือไฟล์ต้นฉบับ (`source_file`) และกุญแจลำดับคือตำแหน่งแถวในไฟล์ CSV ต้นฉบับ (`_row_index`) เพราะรุ่น MachineLearningCVE ไม่มีคอลัมน์ Timestamp **วิธีนี้ไม่ใช่ timestamp split** แต่เป็นการแบ่งตามลำดับแถวในไฟล์ ซึ่งตรวจแล้วว่าสอดคล้องกับตารางเวลาการโจมตีที่ผู้จัดทำชุดข้อมูลเผยแพร่ และการตัดทำภายในแต่ละกลุ่ม (ไฟล์, คลาส) ไม่ได้ตัดที่จุดเวลาเดียวกันทั้งคอร์ปัส
    - *CSE-CIC-IDS2018:* capture group คือวันที่บันทึก และกุญแจลำดับคือคอลัมน์ Timestamp
    - capture-order split เป็นฟังก์ชันของข้อมูลล้วน ๆ จึงได้ train/test ชุดเดิมทุก seed

Models (7) Logistic Regression, Random Forest, XGBoost, LightGBM, CatBoost, MLP, Stacking Ensemble ทุกโมเดล train ใหม่จากศูนย์ ใช้ค่า hyper-parameter ตั้งต้นชุดเดียวกันทั้งสองทิศ และถ่วงน้ำหนักคลาสแบบผกผันตามความถี่ ตัวปรับสเกลประมาณค่าจากชุดข้อมูลต้นทางเท่านั้น

Seeds ใช้ 42, 43, 44, 45, 46 รวมทั้งหมด 280 ผลการวัด (2 split × 5 seeds × 2 train corpus × 2 test corpus × 7 models)

Metrics

- *ตัวชี้วัดหลัก:* macro-F1 ของ 7 คลาส รายงานเป็น mean ± SD จาก 5 seeds
- *Baseline (floor):* โมเดลที่ทำนาย Benign ทั้งหมด ได้ 0.1294 บน test ของ CICIDS2017 และ 0.1337 บน test ของ CSE-CIC-IDS2018
- *Ceiling:* macro-F1 ของโมเดลชนิดเดียวกันเมื่อ train และ test ภายในชุดข้อมูลปลายทาง ภายใต้ split แบบเดียวกัน
- *Recovery %* = (F1_transfer − F1_floor) / (F1_ceiling − F1_floor) × 100
- *Asymmetry* = Recovery เฉลี่ย 7 โมเดลของทิศ 2018⟶2017 ลบด้วยของทิศ 2017⟶2018 มีหน่วยเป็นจุดเปอร์เซ็นต์

2) Main results ของ protocol_v3

แต่ละช่องแสดง raw macro-F1 (mean ± SD) / Recovery % / ceiling ส่วน baseline อยู่ที่หัวคอลัมน์ ตัวหนาคือ raw macro-F1 สูงสุดในคอลัมน์นั้น

Random split

Model	2017⟶2018 (baseline 0.1337)	2018⟶2017 (baseline 0.1294)
LightGBM	**0.2850 ± 0.0181** / 20.6% / 0.8696	0.2860 ± 0.0524 / 18.4% / 0.9795
XGBoost	0.2727 ± 0.0633 / 18.9% / 0.8676	0.2446 ± 0.0179 / 13.7% / 0.9715
CatBoost	0.1692 ± 0.0073 / 4.9% / 0.8547	0.2195 ± 0.0176 / 10.7% / 0.9686
Random Forest	0.1743 ± 0.0086 / 5.6% / 0.8625	0.1492 ± 0.0024 / 2.4% / 0.9612
Stacking	0.2836 ± 0.0094 / 21.3% / 0.8383	**0.3187 ± 0.0296** / 22.4% / 0.9727
MLP	0.1489 ± 0.0068 / 2.2% / 0.8326	0.2256 ± 0.0173 / 13.0% / 0.8679
Logistic Regression	0.1381 ± 0.0007 / 0.7% / 0.7811	0.2556 ± 0.0271 / 25.5% / 0.6243
Recovery เฉลี่ย 7 โมเดล	10.6%	15.2%

Capture-order split

Model	2017⟶2018 (baseline 0.1337)	2018⟶2017 (baseline 0.1294)
LightGBM	0.3132 ± 0.0569 / 24.5% / 0.8675	**0.4435 ± 0.0041** / 42.0% / 0.8767
XGBoost	**0.3368 ± 0.0599** / 28.0% / 0.8589	0.3524 ± 0.0187 / 30.4% / 0.8617
CatBoost	0.1735 ± 0.0017 / 5.5% / 0.8516	0.2176 ± 0.0042 / 11.9% / 0.8711
Random Forest	0.1717 ± 0.0001 / 5.3% / 0.8466	0.1631 ± 0.0056 / 4.6% / 0.8550
Stacking	0.3322 ± 0.0600 / 28.6% / 0.8272	0.3567 ± 0.0217 / 30.9% / 0.8648
MLP	0.1753 ± 0.0015 / 6.1% / 0.8145	0.3005 ± 0.0219 / 27.5% / 0.7511
Logistic Regression	0.1496 ± 0.0000 / 2.6% / 0.7534	0.3506 ± 0.0000 / 50.1% / 0.5706
Recovery เฉลี่ย 7 โมเดล	14.4%	28.2%

- **raw macro-F1 สูงสุดในแต่ละทิศ**
  - *Capture-order:* 2017⟶2018 คือ XGBoost 0.3368 และ 2018⟶2017 คือ LightGBM 0.4435
  - *Random:* 2017⟶2018 คือ LightGBM 0.2850 และ 2018⟶2017 คือ Stacking 0.3187
  - ทุกค่ายังห่างจาก ceiling มาก
- **random กับ capture-order ต่างกันที่ ceiling ของ CICIDS2017** ceiling เฉลี่ย 7 โมเดลของ random คือ 0.9065 เทียบกับ 0.8073 ของ capture-order (ต่างกัน 0.099) ขณะที่ CSE-CIC-IDS2018 ต่างกันเพียง 0.012 (0.8438 เทียบกับ 0.8314) ceiling ที่สูงขึ้นทำให้ Recovery ของทิศ 2018⟶2017 ภายใต้ random ต่ำลง
- **asymmetry ยังอยู่** ทิศ 2018⟶2017 กู้คืนได้มากกว่า
  - *Capture-order:* ต่างกัน 13.8 จุด และทิศ 2018⟶2017 ดีกว่าใน 6 จาก 7 โมเดล (Random Forest ต่างกันไม่ถึง 1 จุด)
  - *Random:* ต่างกันเพียง 4.6 จุด และดีกว่าใน 4 จาก 7 โมเดล
- **อย่าจัดอันดับด้วย Recovery อย่างเดียว** Logistic Regression ได้ Recovery สูงสุดในทิศ 2018⟶2017 (50.1%) แต่ raw macro-F1 (0.3506) ต่ำกว่า LightGBM (0.4435, Recovery 42.0%) เพราะ ceiling ของ Logistic Regression ต่ำเพียง 0.5706
- **ในทิศ 2017⟶2018 มี 4 จาก 7 โมเดลที่ raw macro-F1 อยู่แค่ 0.15–0.18** ได้แก่ CatBoost, Random Forest, MLP และ Logistic Regression ซึ่งใกล้ baseline 0.1337

3) Per-class results (protocol_v3, capture-order)

ค่าในตารางคือ F1 สูงสุดจาก 7 โมเดล (ในวงเล็บคือโมเดลที่ได้) ส่วน ceiling คือค่าเฉลี่ยของ 7 โมเดลภายในชุดข้อมูลปลายทาง (ceiling ของทิศ 2017⟶2018 คือ ceiling ฝั่ง 2018 และกลับกัน)

Class	Best F1 2017⟶2018	Best F1 2018⟶2017	Ceiling 2017	Ceiling 2018	Transfer
Brute Force	0.929 (Stacking)	0.970 (XGBoost)	0.990	0.999	ดี แต่เฉพาะบางโมเดล
DoS	0.279 (MLP)	0.590 (CatBoost)	0.910	0.939	บางส่วน
DDoS	0.011 (MLP)	0.518 (LR)	0.993	0.991	แย่
Bot	0.358 (XGBoost)	0.869 (LightGBM)	0.208	0.998	ขึ้นกับโมเดล
Web Attack	0.002 (XGBoost)	0.018 (LightGBM)	0.803	0.782	แย่
Benign	0.942 (XGBoost)	0.954 (LR)	0.987	0.991	ดี
Infiltration	0.000	0.000	0.760	0.120	รายงานไม่ได้

- **Brute Force:** LightGBM, XGBoost และ Stacking ได้ 0.77–0.93 ในทิศ 2017⟶2018 แต่ CatBoost และ Random Forest ได้ไม่ถึง 0.1 ทั้งสองทิศ
- **DoS:** ได้ 0.12–0.28 ในทิศ 2017⟶2018 และ 0.19–0.59 ในทิศ 2018⟶2017 และไม่เปลี่ยนเมื่อเปลี่ยนจาก 60% เป็น 70%
- **DDoS:** ceiling เกือบสมบูรณ์ทั้งสองชุดข้อมูล แต่เป็นคลาสที่สูญเสียมากที่สุด ทิศ 2017⟶2018 ได้สูงสุด 0.011 และในทิศ 2018⟶2017 มีเพียง LR ที่ได้เกิน 0.14
- **Bot:** จำแนกยากแม้ภายใน CICIDS2017 เอง (ceiling 0.00–0.27) ในทิศ 2018⟶2017 มีเพียง LightGBM ที่ได้เกิน 0.05
- **Web Attack:** ส่งผ่านไม่ได้ทั้งสองทิศ ทั้งที่ ceiling สูง
- **Benign:** ได้ 0.88–0.95 ทุกกรณี คลาสนี้คลาสเดียวให้ macro-F1 ประมาณ 0.13 ซึ่งเท่ากับ baseline คะแนนที่สูงกว่า baseline จึงมาจาก Brute Force, DoS และ Bot ในบางโมเดล
- **Infiltration รายงานไม่ได้:**
  - CICIDS2017 มี Infiltration เพียง 36 ระเบียน (train 25 / test 11) ค่า F1 ของทิศ 2018⟶2017 จึงคำนวณจากระเบียนเพียง 11 ระเบียน
  - แม้ภายใน CSE-CIC-IDS2018 เอง โมเดลก็ได้ F1 เพียง 0.00–0.22
  - Adversarial validation ของคลาสนี้ก็ทำไม่ได้

การเปลี่ยนจาก 60% เป็น 70% แยกตามคลาส (capture-order) ใช้ข้อเท็จจริงว่า macro-F1 คือค่าเฉลี่ยของ 7 คลาส การเปลี่ยนจึงแยกได้เป็นผลรวมของ ΔF1/7 รายคลาส

สิ่งที่วัด	Δ macro-F1	Brute Force	Bot	DoS	DDoS	อื่น ๆ
Ceiling 2017 (เฉลี่ย 7 โมเดล)	+0.158	**+0.141**	0.000	0.000	0.000	+0.017
2017⟶2018 (เฉลี่ย 7 โมเดล)	+0.062	**+0.051**	+0.011	0.000	0.000	0.000
— LightGBM	+0.107	**+0.110**	0.000	−0.003	0.000	0.000
— XGBoost	+0.166	**+0.113**	+0.051	+0.001	0.000	+0.001
— Stacking	+0.161	**+0.133**	+0.027	0.000	0.000	+0.001
2018⟶2017 (เฉลี่ย 7 โมเดล)	−0.006	−0.001	0.000	0.000	−0.004	−0.001

- **Brute Force เป็นสาเหตุหลัก** อธิบาย ceiling 2017 ที่เพิ่มขึ้นได้ 89% (ส่วนที่เหลือเกือบทั้งหมดคือ Infiltration ซึ่งมี test เพียง 11 แถว) และอธิบายการเพิ่มของ 2017⟶2018 ได้ 82%

- **Bot** คิดเป็น 18% ของการเพิ่มในทิศ 2017⟶2018 โดยเกิดใน XGBoost (F1 0.000⟶0.358) และ Stacking (0.000⟶0.187) เท่านั้น แต่ส่วนนี้ไม่ใช่ผลของ split:
  - F1 ของ Bot ราย seed ออกมาแค่สองแบบ คือ ≈1.0 หรือ 0
  - XGBoost จำแนกได้ 0/5 seed (60%) ⟶ 2/5 seed (70%), Stacking 0/5 ⟶ 1/5, LightGBM 1/5 ⟶ 1/5
  - Bot 195 แถวที่เข้ามาใน train ที่ 70% ไม่ได้คล้าย Bot ของ 2018 มากกว่าแถวเดิม: 2018 Bot ที่มี nearest neighbour อยู่ในกลุ่มนี้มีแค่ 0.1% เทียบกับสัดส่วน 14.3% ของกลุ่มนี้ใน train
  - สรุป: ส่วนของ Bot สะท้อน seed instability ของโมเดล ไม่ใช่ split composition
- **DoS/DDoS** ในทิศ 2018⟶2017 ของ Stacking DDoS ลดจาก 0.324 เป็น 0.132 ขณะที่ DoS เพิ่มจาก 0.384 เป็น 0.493 สองคลาสหักล้างกัน macro-F1 จึงดูคงที่ ส่วนอีก 4 โมเดลในทิศ 2017⟶2018 เปลี่ยนไม่ถึง 0.002

4) Split sensitivity / SSH-Patator

ใน CICIDS2017 คลาส Brute Force ประกอบด้วยเครื่องมือ 2 ตัวที่ทำงานต่อเนื่องกันในไฟล์เดียว คือ FTP-Patator แล้วตามด้วย SSH-Patator เนื่องจาก capture-order split ตัดตามสัดส่วนของแถวในกลุ่ม ตำแหน่งที่ตัดจึงกำหนดว่าเครื่องมือใดอยู่ใน train

เครื่องมือ (Brute Force, CICIDS2017)	Train 60%	Train 70%	Test (เหมือนกันทั้งสองแบบ)
FTP-Patator	5,490	5,931	0
SSH-Patator	**0**	**474**	2,745

- ที่ train 60% โมเดลที่ train จาก CICIDS2017 ไม่เคยเห็น SSH-Patator เลย ขณะที่ test ของ Brute Force เป็น SSH-Patator ทั้งหมด 2,745 แถว
- ที่ train 70% มี SSH-Patator เข้ามา 474 แถว SSH-Patator เป็นเครื่องมือเดียวกับ SSH-Bruteforce ของ CSE-CIC-IDS2018

Model (2017⟶2018, capture-order)	Brute Force F1 60% ⟶ 70%	macro-F1 60% ⟶ 70%
LightGBM	0.000 ⟶ 0.773	0.2058 ⟶ 0.3132
XGBoost	0.000 ⟶ 0.790	0.1712 ⟶ 0.3368
Stacking	0.000 ⟶ 0.929	0.1715 ⟶ 0.3322
CatBoost / RF / MLP	0.000 ⟶ 0.000	0.17–0.18 ⟶ 0.17–0.18
Logistic Regression	0.002 ⟶ 0.000	0.1508 ⟶ 0.1496

- **Asymmetry ภายใต้ capture-order:** ลดจาก 33.6 จุด (60%) เป็น 13.8 จุด (70%) และ ceiling เฉลี่ยของ CICIDS2017 เพิ่มจาก 0.649 เป็น 0.807
- **Asymmetry ภายใต้ random split:** เปลี่ยนเพียงจาก 4.3 เป็น 4.6 จุด

ข้อสรุป ภายใต้ capture-order split องค์ประกอบของเครื่องมือโจมตีย่อยในชุดฝึกเปลี่ยนข้อสรุปเชิงปริมาณของ cross-dataset ได้มาก การมี SSH-Patator ในชุดฝึกเพียง 474 แถวทำให้ asymmetry ลดลงกว่าครึ่ง ขณะที่ทิศทางของ asymmetry ยังเหมือนเดิม ขนาดของ asymmetry จึงควรรายงานเป็นช่วง (14–34 จุด) พร้อมระบุองค์ประกอบของชุดฝึก ไม่ควรรายงานเป็นตัวเลขเดียว

5) Adversarial Validation / Dataset fingerprint

ใช้ LightGBM ทายว่าแต่ละระเบียนมาจากชุดข้อมูลใด แยกทำทีละคลาส ใช้ไม่เกิน 8,000 แถวต่อฝั่ง 5 seeds และวัดด้วย ROC AUC การตรวจนี้ใช้การแบ่งข้อมูลของตัวเอง จึงไม่ขึ้นกับสัดส่วน 60/70

Class	Cross-dataset AUC (LightGBM)	Logistic Regression	Decision stump	ภายในชุดข้อมูล (คนละไฟล์/ช่วงเวลา, 7 โมเดล)	Exact dup.	Near-dup.
Benign	0.9990	0.9478	0.7089	0.658–0.811	0	0.10%
DDoS	1.0000	1.0000	0.9917	0.9997–1.000 †	0	6.82%
DoS	1.0000	0.9951	0.9370	0.9952–1.000 †	0	0.16%
Brute Force	1.0000	0.9999	0.9950	0.861–0.899	0	0.20%
Bot	1.0000	0.9990	0.9959	0.758–0.937	0	0.17%
Web Attack	1.0000	1.0000	0.9992	0.710–0.840	0	2.75%

† ใน CSE-CIC-IDS2018 แต่ละฝั่งของเส้นแบ่งเป็นเครื่องมือโจมตีคนละตัว ไม่ใช่แค่คนละวัน ค่านี้จึงไม่ใช่ control ที่บริสุทธิ์ คลาส Infiltration ทดสอบไม่ได้ (CICIDS2017 มีเพียง 36 ระเบียน)

ช่วงค่าของ control แต่ละแบบ

Control	AUC
Label-shuffle (แถวจริง แต่สลับ label ชุดข้อมูล)	0.4928–0.5055 ทุกโมเดลและทุกคลาส
Null control (สุ่มแบ่งชุดข้อมูลเดียวเป็นสองครึ่ง)	0.49–0.53
ภายในชุดข้อมูล คนละไฟล์/คนละช่วงเวลา	0.66–0.94 (ไม่รวม DoS และ DDoS)
เครื่องมือเดียวกัน คนละวัน	0.75–0.83
เครื่องมือเดียวกัน คนละชุดข้อมูล	0.9999–1.0000
Cross-dataset (ทุกคลาสที่ทดสอบได้)	0.9990–1.0000

- **โมเดลความจุต่ำ:** Logistic Regression ได้ ≥ 0.948 และ decision stump (กฎเดียวบนคอลัมน์เดียว) ได้ 0.937–0.999 สำหรับคลาสโจมตี (Benign ได้ 0.709)
- **ระเบียนซ้ำ:**
  - *Exact duplicate ครอบ train/test:* 0 ใน 30 ครั้งที่สุ่ม
  - *Near-duplicate:* นิยามที่ระดับบังเอิญ = 0.10% อยู่ใกล้ระดับบังเอิญ (0.10–0.20%) ยกเว้น DDoS (6.82%) และ Web Attack (2.75%) แต่ decision stump ที่จำแถวไม่ได้ก็ยังแยกสองคลาสนี้ได้ ≥ 0.99

Conclusion Dataset fingerprint มีอยู่จริง ตัวจำแนกแยกสองชุดข้อมูลได้เกือบสมบูรณ์ (AUC ≥ 0.999) ในทุกคลาสที่ทดสอบได้ และแยกได้แรงกว่าความต่างระหว่างไฟล์หรือวันภายในชุดข้อมูลเดียวกัน (0.66–0.94) ผลนี้ไม่ใช่ leakage แบบตรง ๆ เพราะ label-shuffle ให้ค่าระดับสุ่ม (≈0.50) ไม่มีระเบียนซ้ำทุกค่าคร่อม train/test และ decision stump ที่ใช้กฎเดียวก็แยกได้ แสดงว่า fingerprint อยู่ในค่าของ features เอง

6) SHAP final summary (70/30)

- **Hypothesis:** เมื่อใช้โมเดลข้ามชุดข้อมูล ระเบียนโจมตีที่ถูกทำนายผิดเป็น Benign ถูกผลักไปทาง Benign ผ่านกลุ่ม dataset-fingerprint features (F) มากกว่าระเบียนโจมตีที่ทำนายถูก
- **Consensus fingerprint group (13 features):** เลือกจากผล adversarial validation โดยต้องผ่านทั้ง permutation importance และ SHAP กำหนดไว้ก่อนการทดสอบและไม่เปลี่ยนภายหลัง ได้แก่ min_seg_size_forward, RST Flag Count, Init_Win_bytes_forward, Destination Port, Max Packet Length, act_data_pkt_fwd, Fwd IAT Min, Init_Win_bytes_backward, Flow IAT Min, Bwd IAT Min, Min Packet Length, Bwd Packet Length Min, Bwd Packet Length Std
- **Within-target comparison:**
  - G_within = $\bar{\mathbf{S}}$(missed) − $\bar{\mathbf{S}}$(caught ในชุดข้อมูลปลายทาง) โดย s คือสัดส่วนของ SHAP บวกต่อ Benign ที่มาจาก F
  - เทียบกับระเบียนที่ทำนายถูกในชุดข้อมูลเดียวกัน จึงตัดผลของการที่ข้อมูลมาจากต่างชุดข้อมูลออก
  - เทียบกับกลุ่ม features สุ่มขนาดเท่ากัน 2,000 กลุ่ม (p ด้านเดียว)
  - เกณฑ์ผ่าน: G > 0 และ p < 0.05/จำนวนกรณีของโมเดลนั้น (Bonferroni) กำหนดเกณฑ์ไว้ล่วงหน้า
  - ใช้โมเดลต้นไม้ 4 ตัว (LightGBM, RF, XGBoost, CatBoost) บน capture-order 70/30 กับ seeds 42–46
- **กรณีที่ข้อมูลพอ:** 11 กรณี (ต้องมี missed ≥ 100 และ caught_tgt ≥ 30 ทุก seed) ได้แก่ DoS 8 กรณี, LightGBM Brute Force (2017⟶2018), LightGBM Bot และ XGBoost DDoS (2018⟶2017)
- **ผล:** ผ่าน **0 จาก 11** กรณี G_within ติดลบ 9 จาก 11 กรณี และ p ต่ำสุด 0.174
- **DoS 2017⟶2018:**
  - ถ้าเทียบกับระเบียนที่ทำนายถูกใน*ชุดข้อมูลต้นทาง* ส่วนต่างเป็นบวกใน LightGBM, XGBoost และ CatBoost
  - แต่ถ้าเทียบภายใน*ชุดข้อมูลปลายทาง* G_within ติดลบทั้ง 4 โมเดล (−0.07 ถึง −0.48) และติดลบทั้ง 20 ค่ารายseed
  - ส่วนต่างบวกแบบเดิมจึงมาจากการที่ข้อมูลมาจากต่างชุดข้อมูล ไม่ได้มาจากการทำนายผิด
- **Secondary finding (รายงานแบบระวัง):**
  - เมื่อใช้กลุ่ม SHAP-only 26 features ซึ่งไม่ใช่กลุ่มหลักที่ใช้ตัดสิน มี 2 กรณีผ่านเกณฑ์รายคลาส:
    - *XGBoost DoS* (G = +0.228, p = 0.0045) เมื่อตรวจแบบ within-target ได้ G_within = +0.073 (p = 0.21) ซึ่งไม่ผ่าน
    - *CatBoost DDoS* (G = +0.246, p = 0.0090) ตรวจแบบ within-target ไม่ได้ เพราะโมเดลทำนาย DDoS ใน CSE-CIC-IDS2018 ถูก 0 ระเบียน
  - รอบ 4 (pre-registered เช่นกัน) ใช้ 13 features ที่คลาสนั้นเลื่อนค่ามากที่สุดระหว่างสองชุดข้อมูลแทน F ผลรวมเป็น partial โดย DoS ผ่านเกณฑ์ใน 3 จาก 4 โมเดล แต่รอบนี้เทียบกับ caught ในชุดข้อมูลต้นทาง ซึ่ง within-target แสดงแล้วว่ายังปนผลของการต่างชุดข้อมูล จึงพูดได้แค่ว่า class-level shift *อาจ* มีส่วน และต้องตรวจซ้ำแบบ within-target ก่อนสรุป

Final conclusion (ใช้ใน paper ได้): ไม่พบหลักฐานว่ากลุ่ม dataset-fingerprint features ที่กำหนดไว้ล่วงหน้าเป็นสาเหตุโดยตรงของการทำนายระเบียนโจมตีเป็น Benign หลัง cross-dataset transfer

7) Limitations

1. **Capture-order ของ CICIDS2017 ไม่ใช่ true temporal split** ชุดข้อมูลรุ่นที่ใช้ไม่มี Timestamp จึงใช้ลำดับแถวในไฟล์ต้นฉบับแทน และตัดภายในกลุ่ม (ไฟล์, คลาส) ไม่ได้ตัดที่จุดเวลาเดียวทั้งคอร์ปัส
2. **องค์ประกอบของเครื่องมือโจมตีย่อยมีผลต่อการแบ่ง** คลาสที่มีหลายเครื่องมือทำงานต่อเนื่องกันจะได้ชุดฝึกต่างกันตามจุดที่ตัด งานนี้ทดสอบจุดตัดเพียง 2 จุด (60% และ 70%) และยังไม่ได้ทดลองเอา SSH-Patator ออกจากชุดฝึกโดยตรง
3. **SD จาก 5 seeds ของ capture-order วัดเฉพาะความสุ่มของโมเดล** เพราะ train/test เหมือนกันทุก seed ค่านี้จึงไม่สะท้อนความผันผวนของการแบ่งข้อมูล
4. **Infiltration มี support ต่ำ** CICIDS2017 มีเพียง 36 ระเบียน (test 11) จึงรายงาน F1 และทำ adversarial validation ของคลาสนี้ไม่ได้
5. **Recovery ขึ้นกับ ceiling ของแต่ละโมเดล** โมเดลที่ ceiling ต่ำ (เช่น LR) จะได้ Recovery สูงเกินจริง จึงต้องอ่านคู่กับ raw macro-F1 เสมอ
6. **มีเพียง 2 ชุดข้อมูล** ซึ่งมาจากผู้จัดทำเดียวกันและบันทึกห่างกันประมาณ 8 เดือน ข้อมูลชุดนี้แยกผลของเวลา ขั้นตอนการเก็บข้อมูล และเครื่องมือสร้าง features ออกจากกันไม่ได้
7. **ยังไม่ได้ทำ target adaptation หรือ joint training** ผลทั้งหมดจึงเป็นกรณีที่ไม่มีข้อมูลของเครือข่ายปลายทางเลย

8) Key findings

1. **Best macro-F1:**
   - *Capture-order:* 2017⟶2018 = **0.3368** (XGBoost; ceiling 0.8589) และ 2018⟶2017 = **0.4435** (LightGBM; ceiling 0.8767) เทียบกับ baseline ≈ 0.13
   - *Random:* 2017⟶2018 = 0.2850 (LightGBM) และ 2018⟶2017 = 0.3187 (Stacking)
2. **ใกล้ baseline:** ทิศ 2017⟶2018 มี 4/7 โมเดลที่ได้เพียง 0.15–0.18 (baseline 0.1337)
3. **Random vs capture-order:** random ทำให้ ceiling ของ CICIDS2017 สูงเกินจริง 0.9065 เทียบกับ 0.8073 (+0.099) ส่วน CSE-CIC-IDS2018 ต่างกันเพียง 0.012
4. **Asymmetry (70%):**
   - *Capture-order:* Recovery 28.2% เทียบกับ 14.4% = **13.8 จุด** (6/7 โมเดล)
   - *Random:* 15.2% เทียบกับ 10.6% = 4.6 จุด (4/7 โมเดล)
5. **Asymmetry 60% vs 70% (capture-order):** 33.6 ⟶ **13.8 จุด** และ ceiling เฉลี่ยของ CICIDS2017 0.649 ⟶ 0.807 (random: 4.3 ⟶ 4.6 จุด)
6. **SSH-Patator ใน train ของ CICIDS2017: 0 ⟶ 474 แถว** ขณะที่ test มี 2,745 แถวทั้งสองแบบ
7. **Brute Force F1 (2017⟶2018):** 0 ⟶ 0.77 (LightGBM), 0.79 (XGBoost), 0.93 (Stacking) Brute Force อธิบายการเพิ่มของ macro-F1 ได้ 82% ส่วนอีก 18% มาจาก Bot ซึ่งเป็น seed instability ไม่ใช่ผลของ split (F1 ของ Bot รายseed ≈1.0 หรือ 0)
8. **Transfer ต่ำ:**
   - *DDoS 2017⟶2018:* สูงสุด **0.011** ทั้งที่ ceiling ≈ 0.99
   - *Web Attack:* สูงสุด **0.002 / 0.018** ทั้งที่ ceiling 0.78–0.80

9. **Dataset fingerprint:**
    - *Cross-dataset AUC:* **0.999–1.000** ทุกคลาส
    - *Label-shuffle:* **≈ 0.50** (0.493–0.506)
    - *ภายในชุดข้อมูล:* 0.66–0.94
    - *Logistic Regression:* ≥ 0.948
    - *Exact duplicate:* 0
10. **SHAP within-target:** ผ่าน **0/11** กรณี (p ต่ำสุด 0.174) และ G_within ของ DoS 2017⟶2018 ติดลบทั้ง 4 โมเดล

9) Figures ที่ควรเสนอ

ไม่ต้องสร้างรูปใหม่ ทั้ง 4 รูปมีอยู่แล้วในเล่มรายงาน (รูป 4.7–4.10) ไฟล์อยู่ใน `round6_split_70_30/data/` ยกเว้นรูป D

#	รูป	ตอบคำถาม	ไฟล์ข้อมูล
A	**60% vs 70% split sensitivity**: แผงซ้ายคือ macro-F1 ทิศ 2017⟶2018 แผงขวาคือ Brute Force F1 (รูป 4.9)	องค์ประกอบของชุดฝึก (SSH-Patator 0⟶474) เปลี่ยนข้อสรุปได้แค่ไหน เป็นผลเด่นที่สุดของ paper	`summary_macro_f1_v2.csv`, `summary_macro_f1.csv`, `per_class_v3.csv`
B	**Random vs capture-order**: กราฟแท่ง macro-F1 ของ 7 โมเดล 2 ทิศ พร้อมเส้น baseline (รูป 4.7)	วิธีแบ่งข้อมูลมีผลต่อ transfer และ asymmetry หรือไม่	`summary_macro_f1.csv`, `summary_gap.csv`
C	**Per-class transfer**: heatmap ของ best F1 วาง ceiling คู่กับ transfer ทั้ง 2 ทิศ (รูป 4.8)	คลาสไหนส่งผ่านได้ (Brute Force, Benign) และคลาสไหนไม่ได้ (DDoS, Web Attack)	`summary_per_class.csv`
D	**Adversarial validation**: ช่วง AUC เรียงจาก label-shuffle ⟶ null ⟶ within ⟶ cross-dataset (รูป 4.10)	fingerprint มีจริงหรือไม่ และใช่ leakage หรือเปล่า	`round5_reliability_audit/data/diagnostics.json`, `within_dataset_control.json`, `tool_matched.json` (เทียบกับ JSON แล้ว: label-shuffle 0.4928–0.5055, null 0.4915–0.5273, tool-matched 0.9999–1.0000 ตรงกัน รูปเดิมพิมพ์ค่าสูงสุดของ null เป็น 0.5311 ซึ่งแก้แล้ว)

ถ้าพื้นที่จำกัดให้ใช้ A, B, C แล้วรายงาน D เป็นตารางสั้น (ข้อ 5) SHAP ไม่แนะนำให้ทำเป็นรูป เพราะผลเป็น null (0/11) เขียนเป็นประโยคพร้อมตัวเลขจะชัดกว่า