Cross-Dataset protocol_v3: ผลรายคลาส

เอกสารนี้แยกดู performance รายคลาสของ `protocol_v3` (train 70% / test 30%) เทียบกับ `protocol_v2` (train 60%) ว่าคะแนนเปลี่ยนเพราะคลาสไหน ไม่ดูแค่ macro-F1 รวม ทุกตัวเลขเฉลี่ยจาก 5 seeds ผลของ 7 โมเดล (lightgbm, xgboost, stacking, logistic regression, mlp, catboost, random forest) และไม่ได้ปรับ hyper-parameter ใช้ค่าเริ่มต้นของไลบรารี

macro-F1 คือค่าเฉลี่ยของ F1 ทั้ง 7 คลาสแบบน้ำหนักเท่ากัน (ตรวจกับทุกแถวของผลแล้ว ต่างกันไม่เกิน 0.0001 ซึ่งมาจากการปัดเศษ 4 ตำแหน่งของไฟล์ผล) ดังนั้นการเปลี่ยนของ macro-F1
แยกเป็นผลรวมของการเปลี่ยนรายคลาสได้เป๊ะ คลาสละ (F1 ที่เปลี่ยน / 7)
เอกสารนี้จึงตอบได้ว่าคะแนนรวมเปลี่ยนเพราะคลาสอะไร ตัวเลขทุกตัวเฉลี่ยจาก 5 seeds ค่า SD รายคลาสอยู่ในไฟล์ `data/per_class_v3.csv`

ขนาดของแต่ละคลาสใน test (โหมด chronological) ต้องดูประกอบ เพราะคลาสเล็กทำให้ F1 แกว่งง่าย

คลาส	แถว test ของ 2017	แถว test ของ 2018
Brute Force	2,745	738
DoS	6,961	1,539
DDoS	4,600	6,081
Bot	584	1,133
Web Attack	643	257
Infiltration	11	1,092
Benign	74,456	79,157

1.1 การเปลี่ยนจาก v2 เป็น v3 แยกตามคลาส (ส่วนของการเปลี่ยน macro-F1 ที่แต่ละคลาสเป็นเจ้าของ)

เฉลี่ยทั้ง 7 โมเดล โหมด chronological

คะแนนที่วัด	macro-F1 เปลี่ยน	Brute Force	DoS	DDoS	Bot	Web Attack	Benign + Infiltration
ceiling 2017	+0.158	+0.141	-0.000	+0.000	-0.000	+0.000	+0.017
2017 ไป 2018 (transfer)	+0.062	+0.051	-0.000	-0.000	+0.011	+0.000	+0.000
ceiling 2018	+0.002	+0.000	-0.000	+0.000	+0.000	+0.000	+0.002
2018 ไป 2017 (transfer)	-0.006	-0.001	+0.000	-0.004	-0.000	-0.001	-0.000

- ceiling 2017 เปลี่ยน +0.158 มาจาก Brute Force +0.141 (89%) ส่วนที่เหลือเกือบทั้งหมดคือ Infiltration +0.014 ซึ่งมี test แค่ 11 แถว จึงเป็นความแกว่งมากกว่าการเปลี่ยนจริง
- transfer 2017 ไป 2018 เปลี่ยน +0.062 มาจาก Brute Force +0.051 (82%) และ Bot +0.011 (18%) คลาสอื่นรวมกันไม่ถึง 0.001
- transfer 2018 ไป 2017 เปลี่ยน -0.006 เกือบศูนย์ แต่ไม่ได้แปลว่าไม่มีอะไรเปลี่ยน ใน stacking DDoS ลดจาก F1 0.324 เป็น 0.132 (-0.027 ของ macro) ขณะที่ DoS เพิ่มจาก 0.384 เป็น 0.493 (+0.015) สองคลาสหักล้างกัน macro-F1 จึงดูนิ่ง

• ceiling 2018 ไม่เปลี่ยน (+0.002)

โหมด random: การเปลี่ยนของ macro-F1 ทุกช่องอยู่ระหว่าง -0.006 ถึง +0.002 และไม่มีคลาสใดมีส่วนเกิน 0.004 (ตารางเต็มอยู่ในไฟล์ข้อมูล)

คะแนนที่วัด	macro-F1 เปลี่ยน	Brute Force	DoS	DDoS	Bot	Web Attack	Benign + Infiltration
ceiling 2017	+0.002	+0.000	-0.000	+0.000	+0.000	+0.000	+0.001
2017 ไป 2018 (transfer)	-0.006	-0.004	-0.003	-0.000	+0.000	+0.001	-0.000
ceiling 2018	+0.002	+0.000	-0.000	+0.000	+0.000	+0.002	-0.001
2018 ไป 2017 (transfer)	-0.005	-0.002	-0.002	-0.001	-0.002	+0.001	+0.000

1.2 รายโมเดล ทิศ 2017 ไป 2018 (chronological)

โมเดล	macro-F1 เปลี่ยน	Brute Force	DoS	DDoS	Bot	Web Attack	Benign + Infiltration
lightgbm	+0.107	+0.110	-0.003	+0.000	+0.000	+0.000	+0.000
xgboost	+0.166	+0.113	+0.001	+0.000	+0.051	+0.000	+0.001
stacking	+0.161	+0.133	+0.000	+0.000	+0.027	+0.000	+0.001
logistic regression	-0.001	-0.000	-0.000	+0.000	+0.000	+0.000	-0.001
mlp	-0.000	+0.000	+0.001	-0.001	+0.000	+0.000	-0.000
catboost	+0.001	+0.000	+0.001	+0.000	+0.000	+0.000	-0.000
random forest	+0.000	+0.000	+0.000	+0.000	+0.000	+0.000	-0.000

คะแนนเปลี่ยนเฉพาะ lightgbm, stacking และ xgboost ส่วนอีก 4 โมเดลเปลี่ยนไม่ถึง 0.002 (ทั้งบวกและลบ) ใน lightgbm การเปลี่ยนทั้งหมดมาจาก Brute Force (Bot ได้ F1 0.199 เท่าเดิมทั้ง v2 และ v3) ใน stacking กับ xgboost มี Bot เพิ่มด้วย (F1 0.000 เป็น 0.187 และ 0.000 เป็น 0.358) ที่ Bot เปลี่ยนนี้ผมยังอธิบายกลไกไม่ได้ Bot ของ 2017 ใน train เพิ่มจาก 1,169 เป็น 1,364 แถว แต่ไม่ได้ตรวจว่าเกี่ยวกับการเปลี่ยนนี้หรือไม่

1.3 v3 รายคลาส: คะแนน transfer มาจากคลาสไหน

F1 รายคลาส เฉลี่ย 5 seeds โหมด chronological

ทิศ 2017 ไป 2018

โมเดล	Brute Force	DoS	DDoS	Bot	Web Attack	Benign	macro-F1
lightgbm	0.773	0.279	0.000	0.200	0.000	0.941	0.313
xgboost	0.790	0.266	0.000	0.358	0.002	0.942	0.337
stacking	0.929	0.268	0.000	0.187	0.000	0.942	0.332
logistic regression	0.000	0.123	0.000	0.000	0.000	0.924	0.150

โมเดล	Brute Force	DoS	DDoS	Bot	Web Attack	Benign	macro-F1
mlp	0.000	0.279	0.011	0.000	0.000	0.937	0.175
catboost	0.000	0.278	0.000	0.000	0.000	0.937	0.174
random forest	0.000	0.265	0.000	0.000	0.000	0.937	0.172

ทิศ 2018 ไป 2017

โมเดล	Brute Force	DoS	DDoS	Bot	Web Attack	Benign	macro-F1
lightgbm	0.964	0.325	0.001	0.869	0.018	0.928	0.444
xgboost	0.969	0.445	0.120	0.000	0.016	0.915	0.352
stacking	0.968	0.493	0.132	0.000	0.013	0.891	0.357
logistic regression	0.745	0.237	0.518	0.000	0.001	0.954	0.351
mlp	0.880	0.274	0.025	0.000	0.004	0.920	0.301
catboost	0.052	0.590	0.002	0.000	0.003	0.877	0.218
random forest	0.004	0.192	0.001	0.000	0.008	0.937	0.163

ceiling เทียบกับ transfer แยกตามคลาส (เฉลี่ย 7 โมเดล และโมเดลที่ดีที่สุด)

คลาส	ceiling 2017	2017 ไป 2018 เฉลี่ย	2017 ไป 2018 สูงสุด	ceiling 2018	2018 ไป 2017 เฉลี่ย	2018 ไป 2017 สูงสุด
Brute Force	0.990	0.356	0.929 (stacking)	0.999	0.655	0.969 (xgboost)
DoS	0.910	0.251	0.279 (mlp)	0.939	0.365	0.590 (catboost)
DDoS	0.993	0.002	0.011 (mlp)	0.991	0.114	0.518 (logistic regression)
Bot	0.208	0.106	0.358 (xgboost)	0.998	0.124	0.869 (lightgbm)
Web Attack	0.803	0.000	0.002 (xgboost)	0.782	0.009	0.018 (lightgbm)
Benign	0.987	0.937	0.942 (xgboost)	0.991	0.918	0.954 (logistic regression)

1.4 อ่านทีละคลาส

Brute Force เป็นคลาสที่ทำให้ผลเปลี่ยนมากที่สุด ใน v2 train ของ 2017 ไม่มี SSH-Patator ceiling 2017 จึงต่ำและ transfer ไป 2018 เป็นศูนย์ ใน v3 ceiling กลับเป็น 0.97 ถึง 1.00 ทุกโมเดล ทิศ 2017 ไป 2018 มี 3 โมเดลที่ได้ F1 ตั้งแต่ 0.5 (lightgbm, xgboost, stacking) ที่เหลือยังเป็นศูนย์ ทิศ 2018 ไป 2017 มี 5 โมเดลที่ได้ตั้งแต่ 0.5 (lightgbm, xgboost, stacking, logistic regression, mlp) ส่วน catboost, random forest ได้ไม่ถึง 0.1 คือคลาสนี้ข้าม dataset ได้เมื่อโมเดลเป็นแบบ boosting เร็ว ๆ แต่ไม่ใช่ทุกโมเดล

DoS ได้ F1 ระดับต่ำถึงปานกลางในทั้งสองทิศ (2017 ไป 2018 อยู่ที่ 0.12 ถึง 0.28 และ 2018 ไป 2017 อยู่ที่ 0.19 ถึง 0.59) เทียบกับ ceiling 0.79 ถึง 0.98 ผลนี้แทบไม่เปลี่ยนระหว่าง v2 กับ v3 (ส่วนของ macro ไม่เกิน 0.005 ทั้งบวกและลบ ยกเว้นการหักล้างกับ DDoS ใน stacking ข้างต้น) DoS จึงเป็นคลาสโจมตีที่ transfer ได้ "บางส่วน" อย่างคงที่ ไม่ขึ้นกับสัดส่วน split

DDoS ceiling เกือบสมบูรณ์ (0.97 ถึง 1.00) แต่ transfer ทิศ 2017 ไป 2018 ได้ศูนย์เกือบทุกโมเดล (สูงสุด 0.011) และทิศ 2018 ไป 2017 มีแค่ logistic regression ที่ได้ 0.52 นอกนั้น 0.13 หรือต่ำกว่า DDoS จึงเป็นคลาสที่เสียมากที่สุดเมื่อเทียบ ceiling กับ transfer และเป็นหนึ่งในเหตุผลที่ transfer macro-F1 ต่ำ ไม่ได้ถูกกระทบจากการเปลี่ยน split

Bot ใน 2017 ยากแม้อยู่ใน dataset เดียวกัน ceiling 2017 อยู่ที่ 0.00 ถึง 0.27 (test 584 แถว) ขณะที่ ceiling 2018 อยู่ที่ 0.99 ถึง 1.00 ทิศ 2017 ไป 2018 มี 3 โมเดลที่ได้ F1 เกิน 0.05 (lightgbm, stacking, xgboost) และทิศ 2018 ไป 2017 มีโมเดลเดียวที่ได้เกิน 0.05 คือ lightgbm (0.87) ผลรายโมเดลของคลาสนี้จึงต่างกันมาก

Web Attack transfer เป็นศูนย์ในแทบทุกโมเดลและทั้งสองทิศ (สูงสุด 0.002 และ 0.018) ทั้งที่ ceiling สูง (0.83 ถึง 0.97 ไม่รวม logistic regression) และไม่เปลี่ยนระหว่าง v2 กับ v3

Benign ได้ F1 0.92 ถึง 0.94 (ทิศ 2017 ไป 2018) และ 0.88 ถึง 0.95 (ทิศ 2018 ไป 2017) ส่วนนี้อย่างเดียวให้ macro-F1 ราว 0.134 (57% ของคะแนนเฉลี่ย 0.236) ในทิศ 2017 ไป 2018 และ 0.131 (42% ของ 0.312) ในทิศ 2018 ไป 2017 คะแนน transfer ที่สูงกว่า baseline จึงมาจากคลาสโจมตีไม่กี่คลาส (Brute Force, DoS และ Bot ในบางโมเดล) ไม่ใช่จากการจำแนกได้ทั่วไป

1.5 ข้อจำกัดของการอ่านรายคลาส

- ผลรายคลาสขึ้นกับโมเดลมาก (Brute Force และ Bot ข้ามได้ใน 1 ถึง 5 จาก 7 โมเดลเท่านั้น) ค่าเฉลี่ยข้ามโมเดลจึงต้องอ่านคู่กับตารางรายโมเดล
- การแยกการเปลี่ยนของ macro-F1 เป็นรายคลาสบอกว่า "คลาสไหนเปลี่ยน" แต่ไม่ได้พิสูจน์สาเหตุ คำอธิบายเรื่อง SSH-Patator ของ Brute Force มีหลักฐานจากจำนวนแถวต่อ sub-type ส่วนการเปลี่ยนของ Bot และของ DDoS กับ DoS ใน stacking ยังไม่ได้ตรวจกลไก
- Infiltration (test 11 แถวใน 2017) วัดผลไม่ได้อย่างน่าเชื่อถือ ส่วนที่มันมีใน ceiling 2017 (+0.014) ไม่ควรตีความ
- คลาสเล็กแกว่งมากระหว่าง seed (SD รายคลาสอยู่ในไฟล์ข้อมูล) และโหมด chronological ไม่มีความแกว่งจากการแบ่ง จึงวัดได้เฉพาะความสุ่มของโมเดล