Cross-Dataset: ผลเมื่อเอา calibration ออกและแบ่ง train 70% / test 30% (protocol_v3)

วันที่ 6 ตุลาคม 2569

สรุปสั้น

1. ทำไมต้องรันใหม่ โปรโตคอลเดิมแบ่ง train 60% / calibration 10% / test 30% แต่ส่วน calibration 10% ไม่เคยถูกอ่านเลยในโค้ดที่รัน (โมเดลเทรนด้วย 60% และวัดผลด้วย 30% เท่านั้น) ข้อมูลส่วนนั้นจึงสูญเปล่า จึงตัดออกและแบ่งเป็น train 70% / test 30% (commit `e8447b9`) แล้วรันใหม่ทั้ง 7 โมเดล 5 seeds 2 โหมด เป็นชุด `protocol_v3` (280 แถวผล ใช้เวลา 61.7 นาที) ส่วนชุดเดิม `protocol_v2` ยังเก็บไว้เทียบ

2. โหมด random แทบไม่เปลี่ยน asymmetry เฉลี่ย 4.3 จุดเป็น 4.6 จุด ceiling และ Recovery ขยับไม่เกินระดับความผันผวนระหว่าง seed

3. โหมด chronological เปลี่ยนมาก asymmetry เฉลี่ยลดจาก 33.6 จุดเหลือ 13.8 จุด ทิศทางยังเหมือนเดิม (2018 ไป 2017 ได้กลับมากกว่า ใน 6 จาก 7 โมเดล) แต่ขนาดไม่คงที่

4. สาเหตุหลักคือคลาสเดียว ที่ 60% ส่วน train ของ 2017 ในคลาส Brute Force มีแต่ FTP-Patator ส่วน SSH-Patator ทั้งหมดอยู่นอก train พอตัดที่ 70% รอยตัดเลื่อนเข้าไปในช่วง SSH-Patator ทำให้มี SSH-Patator ใน train 474 แถว (ก่อนหน้านี้ 0 แถว) และตรงกับ SSH-Bruteforce ของ 2018 F1 ของ Brute Force ในทิศ 2017 ไป 2018 จึงกระโดดจาก 0 เป็น 0.77 ถึง 0.93 ใน 3 โมเดล คะแนน macro-F1 ที่เพิ่มขึ้นเฉลี่ย 7 โมเดลมาจาก Brute Force 82% และ Bot 18% (Bot เปลี่ยนใน stacking กับ xgboost) คลาสอื่นแทบไม่เปลี่ยน (รายละเอียดอยู่ในเอกสาร `protocol_v3_per_class`)

5. ข้อสรุปที่ไม่เปลี่ยน ทิศ 2018 ไป 2017 ยังได้กลับมากกว่าทิศตรงข้าม คะแนนจริงของ transfer ในทิศ 2018 ไป 2017 แทบไม่เปลี่ยน (เช่น stacking 0.3674 เป็น 0.3567) และข้อสรุป dataset fingerprint ไม่ถูกกระทบ เพราะมาจากการตรวจ AUC (รอบ 5) ซึ่งไม่ผูกกับสัดส่วน split นี้

1. ตั้งค่าการรัน

รายการ	ค่า
ชุดผล	`results/crossdataset/protocol_v3/`
สัดส่วนแบ่ง	train 70% / test 30% (บันทึกใน `split.json`)
โมเดล	7 ตัว: lightgbm, xgboost, stacking, logistic_regression, mlp, catboost, random_forest
โหมดแบ่ง	random และ chronological
seeds	5 ค่า (42 ถึง 46)
แถวข้อมูลต่อ dataset	300,000 แถว, 77 features, 7 คลาสร่วม
ผลที่ได้	280 แถว (2 โหมด × 5 seeds × 2 train × 2 test × 7 โมเดล)
สิ่งที่เปลี่ยนจาก v2	เฉพาะสัดส่วนแบ่ง (train 60% เป็น 70%) test 30% เท่าเดิม (โหมด chronological ใช้แถวท้าย 30% ของแต่ละกลุ่มเหมือนเดิม ต่างกันไม่เกิน 1 แถวต่อกลุ่มจากการปัดเศษ)

โมเดลไม่ได้ปรับ hyper-parameter ใช้ค่าเริ่มต้นของไลบรารีเหมือนกันทั้งสองฝั่ง เหมือนรอบก่อน baseline macro-F1 (ทำนาย Benign ทั้งหมด) คือ 0.1294 สำหรับ test 2017 และ 0.1337 สำหรับ test 2018

2. คะแนนของ protocol_v3

Recovery = (transfer – floor) / (ceiling – floor) ส่วน macro-F1 (SD)
คือค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานบน 5 seeds

2.1 โหมด chronological

โมเดล	2017 ไป 2018 macro-F1 (SD)	Recovery	2018 ไป 2017 macro-F1 (SD)	Recovery	ceiling 2017	ceiling 2018
lightgbm	0.3132 (SD 0.0569)	24.5%	0.4435 (SD 0.0041)	42.0%	0.8767	0.8675
xgboost	0.3368 (SD 0.0599)	28.0%	0.3524 (SD 0.0187)	30.4%	0.8617	0.8589
stacking	0.3322 (SD 0.0600)	28.6%	0.3567 (SD 0.0217)	30.9%	0.8648	0.8272
logistic regression	0.1496 (SD 0.0000)	2.6%	0.3506 (SD 0.0000)	50.1%	0.5706	0.7534
mlp	0.1753 (SD 0.0015)	6.1%	0.3005 (SD 0.0219)	27.5%	0.7511	0.8145
catboost	0.1735 (SD 0.0017)	5.5%	0.2176 (SD 0.0042)	11.9%	0.8711	0.8516
random forest	0.1717 (SD 0.0001)	5.3%	0.1631 (SD 0.0056)	4.6%	0.8550	0.8466

2.2 โหมด random

โมเดล	2017 ไป 2018 macro-F1 (SD)	Recovery	2018 ไป 2017 macro-F1 (SD)	Recovery	ceiling 2017	ceiling 2018
lightgbm	0.2850 (SD 0.0181)	20.6%	0.2860 (SD 0.0524)	18.4%	0.9795	0.8696
xgboost	0.2727 (SD 0.0633)	18.9%	0.2446 (SD 0.0179)	13.7%	0.9715	0.8676
stacking	0.2836 (SD 0.0094)	21.3%	0.3187 (SD 0.0296)	22.4%	0.9727	0.8383
logistic regression	0.1381 (SD 0.0007)	0.7%	0.2556 (SD 0.0271)	25.5%	0.6243	0.7811
mlp	0.1489 (SD 0.0068)	2.2%	0.2256 (SD 0.0173)	13.0%	0.8679	0.8326
catboost	0.1692 (SD 0.0073)	4.9%	0.2195 (SD 0.0176)	10.7%	0.9686	0.8547
random forest	0.1743 (SD 0.0086)	5.6%	0.1492 (SD 0.0024)	2.4%	0.9612	0.8625

ข้อควรระวังในการอ่าน SD ของโหมด chronological: การแบ่งข้อมูลเหมือนกันทุก seed
(เป็นฟังก์ชันของข้อมูลล้วน ๆ) SD จึงวัดได้เฉพาะความสุ่มของตัวโมเดล ไม่ได้วัดความผันผวนของการแบ่ง
logistic_regression ได้ SD 0.0000 เพราะ เป็นโมเดลที่ผลคงที่

3. เทียบ v2 (train 60%) กับ v3 (train 70%)

ตัวชี้วัด	v2 (train 60%)	v3 (train 70%)
Recovery เฉลี่ย 2017 ไป 2018 (chronological)	5.7%	14.4%
Recovery เฉลี่ย 2018 ไป 2017 (chronological)	39.3%	28.2%
asymmetry เฉลี่ย (chronological)	33.6 จุด	13.8 จุด
โมเดลที่เอนไปทาง 2018 ไป 2017 (chronological)	7/7	6/7
Recovery เฉลี่ย 2017 ไป 2018 (random)	11.5%	10.6%
Recovery เฉลี่ย 2018 ไป 2017 (random)	15.8%	15.2%
asymmetry เฉลี่ย (random)	4.3 จุด	4.6 จุด
โมเดลที่เอนไปทาง 2018 ไป 2017 (random)	3/7	4/7
ceiling 2017 chronological (เฉลี่ย 7 โมเดล)	0.6491	0.8073
ceiling 2017 random (เฉลี่ย 7 โมเดล)	0.9050	0.9065
ceiling 2018 chronological (เฉลี่ย 7 โมเดล)	0.8293	0.8314
ceiling 2018 random (เฉลี่ย 7 โมเดล)	0.8422	0.8438
inflation ของ ceiling 2017 (random – chronological)	0.2559	0.0993
inflation ของ ceiling 2018	0.0129	0.0124

อ่านตารางนี้ได้ 3 ข้อ

- ceiling 2017 แบบ chronological เพิ่มจาก 0.649 เป็น 0.807

ส่วน ceiling แบบ random แทบเท่าเดิม ช่องว่างระหว่างสองโหมด (inflation) ของ 2017 จึงหดจาก 0.256 เหลือ 0.099

- ceiling 2018 แทบไม่ขยับ (ต่างกันไม่ถึง 0.01)
- Recovery ของ 2018 ไป 2017 ลดลง (เฉลี่ย 39.3% เป็น

28.2%) โดยคะแนน transfer เกือบเท่าเดิม สิ่งที่เปลี่ยนคือตัวหาร (ceiling 2017 สูงขึ้น) ไม่ใช่ตัวโมเดล

4. ทำไม chronological เปลี่ยน: SSH-Patator

ใน CICIDS2017 แต่ละคลาสโจมตีอยู่ในไฟล์เดียว และคลาส Brute Force ประกอบด้วย 2 เครื่องมือต่อเนื่องกันในไฟล์เดียว (FTP-Patator แล้วตามด้วย SSH-Patator) การแบ่ง chronological ตัดที่เปอร์เซ็นต์ของแถวในกลุ่ม จึงตัดผ่านเครื่องมือเหล่านี้ ต่างกันตามสัดส่วน (ตัวเลขจากตารางองค์ประกอบ sub-type ของ `scripts/audit_chronological_split_2017.py`)

sub-type ใน Brute Force	train (60/10/30)	train (70/30)	test (ทั้งสองแบบ)
FTP-Patator	5,490	5,931	0
SSH-Patator	0	474	2,745

ที่ 60% โมเดลที่เทรนด้วย 2017 ไม่เคยเห็น SSH-Patator เลย ที่ 70% เห็น 474 แถว ผลคือ

โมเดล	macro-F1 2017 ไป 2018 (v2)	macro-F1 2017 ไป 2018 (v3)	Brute Force F1 (v2)	Brute Force F1 (v3)
lightgbm	0.2058	0.3132	0.0000	0.7729
xgboost	0.1712	0.3368	0.0000	0.7901
stacking	0.1715	0.3322	0.0000	0.9290
logistic regression	0.1508	0.1496	0.0024	0.0000
mlp	0.1755	0.1753	0.0000	0.0000
catboost	0.1726	0.1735	0.0000	0.0000
random forest	0.1717	0.1717	0.0000	0.0000

macro-F1 ที่เพิ่มขึ้นเทียบกับ F1 ของ Brute Force ที่เพิ่มขึ้นสอดคล้องกันเกือบเป๊ะ ตัวอย่าง lightgbm macro-F1 เพิ่ม 0.107 ส่วน Brute Force เพิ่ม 0.773 หารด้วย 7 คลาสได้ 0.110 ส่วน catboost, mlp, random_forest และ logistic_regression ซึ่งไม่ได้ Brute Force เพิ่มก็ไม่เปลี่ยน

ผลเดียวกันอธิบาย ceiling 2017 ด้วย ที่ 60% test มี SSH-Patator 2,745 แถวที่โมเดลไม่เคยเห็น Brute Force จึงได้ F1 ใกล้ 0 กดค่าเฉลี่ย ceiling ลง ที่ 70% มีตัวอย่างบางส่วนแล้ว ceiling จึงสูงขึ้น

5. ความหมายต่อข้อสรุปของโครงงาน

- ขนาดของ asymmetry ในโหมด chronological ไม่ควรรายงานเป็นตัวเลขเดียว ควรรายงานเป็นช่วง

14 ถึง 34 จุด ตามสัดส่วน split พร้อมระบุว่าความต่างมาจากรอยตัดผ่านเครื่องมือโจมตี

- ทิศทางยังเหมือนเดิม 2018 ไป 2017 ได้กลับมากกว่าใน 6 จาก 7 โมเดล (random_forest ต่างกันไม่ถึง 1 จุด)
- โหมด random เสถียร ตัวเลขใกล้เคียงเดิมทุกตัว ข้อสรุปจากโหมดนี้ไม่ผูกกับสัดส่วน 60 หรือ 70
- คะแนน transfer จริงยังต่ำ ทิศ 2017 ไป 2018 มี 4 โมเดลที่ยังอยู่ระดับ baseline (0.15 ถึง 0.18 เทียบ 0.1337)

และโมเดลที่ดีขึ้นก็ดีขึ้นเพราะ Brute Force เป็นหลัก (กับ Bot ใน stacking และ xgboost)
ไม่ได้หมายความว่าโมเดลข้าม dataset ได้ดีขึ้นโดยรวม คลาส DDoS และ Web Attack ยังได้ F1 ใกล้ศูนย์เกือบทุกโมเดล

- dataset fingerprint ไม่ถูกกระทบ หลักฐานหลักคือ adversarial validation AUC ใกล้ 1.0 ในรอบ 5

ซึ่งเทรนเพื่อแยก dataset ไม่ใช่แยกคลาสโจมตี จึงไม่ขึ้นกับสัดส่วน split

6. ข้อจำกัด

- ทดสอบรอยตัดแค่ 2 จุด (60% และ 70%) จึงยังสรุปเป็นเส้นโค้งไม่ได้ และยังไม่ได้ทดลองเอา SSH-Patator ออกจาก

train โดยตรง การอธิบายว่าเป็น SSH-Patator อาศัยตารางจำนวนแถวต่อ sub-type และรูปแบบ F1 ที่ตรงกัน

- ชุดควบคุม "ceiling 2017 ต้องทำซ้ำได้" ใช้เทียบ v2 กับ v3 ไม่ได้ เพราะ 2017 ถูกแบ่งใหม่ ต่างจากการเทียบ v1 กับ

v2 ที่ฝั่ง 2017 ไม่ถูกแตะ สคริปต์เทียบจึงข้ามส่วนนี้เมื่อเทียบคู่อื่น

- รันครั้งเดียวต่อสัดส่วน SD ที่รายงานคือความสุ่มของโมเดลบน 5 seeds
- ช่องว่างด้านเวลาและขั้นตอนเก็บข้อมูลระหว่าง 2017 กับ 2018 แก้ไม่ได้ เหมือนรอบก่อน
- ผลรอบ 1 ถึง 5 ยังเป็นผลที่ train 60% ซึ่งถูกต้องในตัวเอง (calibration ไม่เคยถูกอ่าน จึงไม่มีผลต่อตัวเลข) แต่

ไม่ใช่ 70/30 หากอ้างเป็น 70/30 ให้ใช้ชุดนี้

7. ไฟล์ที่เกี่ยวข้อง

ไฟล์	เนื้อหา
`results/crossdataset/protocol_v3/`	ผลรันดิบและตารางสรุป (`results.csv`, `summary_*.csv`, `split.json`, `run.log`)
`results/crossdataset/protocol_comparison_v2_v3/`	ผลเทียบ v2 กับ v3 (`comparison.json`, `per_model_recovered.csv`)
`data/` ในโฟลเดอร์รอบนี้	สำเนาตารางที่ใช้ในรายงานนี้
`scripts/run_crossdataset.py`	สคริปต์รัน (ค่าเริ่มต้นเป็น 70/30)
`scripts/compare_protocols.py --versions v2 v3`	สคริปต์เทียบ
`src/crossdataset/splits.py`	การแบ่ง train/test